

Fundamentos del aprendizaje automático

(Machine learning)

Joaquín Luque

Contenido

1. Introducción
2. Regresión
 - a) Regresión univariable
 - b) Regresión multivariable
3. Clasificación
 - a) Regresión logística
 - b) Máquinas de vectores soporte (SVM)
 - Forma dual de la optimización (regresión y SVM)
 - c) Funciones Kernel
 - d) Clasificación multiclase
4. Segmentación
5. Reducción de dimensionalidad
6. Deep learning (introducción)

Regresión univariable

- Muestreo
 - Hold-out
 - Cros-validación
- Hipótesis
 - Regresión lineal (sin *offset*)
 - Regresión lineal
 - Regresión polinómica
- Función de coste
 - Cuadrática
 - Regularización (regresión de arista)
- Optimización
 - Ecuación normal
 - Gradiente descendente
- Evaluación
 - Bootstrap

Ejemplo en el sector eléctrico

- Una compañía eléctrica tiene una extensa base de datos con información muy diversa sobre sus clientes. Se desea explotar dicha información para dar respuesta a 3 cuestiones:
 - ¿Que energía demandará un nuevo cliente?
(predicción)
 - ¿Es potencial comprador de un vehículo eléctrico?
(clasificación)

Ejemplo en el sector eléctrico


Predicción

- En el momento de hacer un contrato con un cliente nuevo, la empresa realiza un perfil del usuario para lo que le solicita diversos datos.
 - Con esa información y en base a la experiencia acumulado sobre otros clientes, desea conocer el consumo previsto de energía a lo largo de un año.
 - Ello le permitirá realizar una mejor planificación y gestión de la red eléctrica

Población y muestra

1. Extracción de una muestra

Población $\mathcal{P}$




Muestra $\mathcal{M}$
(dataset)



Clientes


Pasos del *machine learning*



Elementos de la muestra y objetivos

2. Determinación de *features*

Muestra $\mathcal{M}$
(dataset)



n elementos

i -ésimo elemento

Caracterizado por 1 feature (rasgo):

- $x^{(i)}$: ingresos anuales

Valor del objetivo (target) :

- $y^{(i)}$: consumo anual de electricidad

$$x = \begin{bmatrix} x^{(1)} \\ x^{(2)} \\ \vdots \\ x^{(n)} \end{bmatrix}$$

$$y^{(i)} = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix}$$

Elementos de la muestra y objetivos

2. Determinación de *features*

Cliente	Ingresos anuales (miles de €) $x^{(i)}$	Consumo anual de electricidad (MW-h) $y^{(i)}$
1	44.6	9.81
2	73.4	12.4
3	5.0	1.63
4	33.7	8.17
5	18.9	4.87
⋮	⋮	⋮


Elementos de la muestra y objetivos

2. Determinación de *features*


			f	φ	K	X
Rule-based systems		$y = f(X)$	Manual	-	-	Manual
Machine Learning	Basic ML	$y = f(X)$	Automatic	-	-	Manual
	Feature-based ML	$y = f[\varphi(X)]$	Automatic	Manual	-	Raw
	Kernel-based ML	$y = f[K(X)]$	Automatic	Automatic	Manual	Raw
	Deep Learning	$y = f(\varphi(X))$	Automatic	Automatic	-	Raw

Elementos de la muestra y objetivos

2. Determinación de *features*



Pasos del *machine learning*




Regresión univariable

- Muestreo
 - Hold-out
 - Cros-validación
- **Hipótesis**
 - **Regresión lineal (sin *offset*)**
 - Regresión lineal
 - Regresión polinómica
- Función de coste
 - Cuadrática
 - Regularización (regresión de arista)
- Optimización
 - Ecuación normal
 - Gradiente descendente
- Evaluación
 - Bootstrap

Regresión lineal (sin *offset*)

3. Formulación de hipótesis




La posición de la recta depende del parámetro w

$$\text{Hipótesis } h_w(x) = wx$$

Recta que pasa por el origen

Pasos del *machine learning*




Regresión univariable

- Muestreo
 - Hold-out
 - Cros-validación
- Hipótesis
 - Regresión lineal (sin *offset*)
 - Regresión lineal
 - Regresión polinómica
- **Función de coste**
 - **Cuadrática**
 - Regularización (regresión de arista)
- Optimización
 - Ecuación normal
 - Gradiente descendente
- Evaluación
 - Bootstrap

Error cuadrático medio

4. Elección de la función de coste



$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

Error cuadrático medio

4. Elección de la función de coste

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

The diagram shows the cost function $J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (w x^{(i)} - y^{(i)})^2$ with annotations. A blue label "Datos (constantes)" has arrows pointing to the $x^{(i)}$ and $y^{(i)}$ terms, which are enclosed in blue boxes. A red label "Parámetro (variable)" has an arrow pointing to the w term, which is enclosed in a red box.

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (\boxed{w} \boxed{x^{(i)}} - \boxed{y^{(i)}})^2$$

Datos (constantes)

Parámetro (variable)


Error cuadrático medio

4. Elección de la función de coste

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (w x^{(i)} - y^{(i)})^2$$

Datos (constantes)

Parámetro (variable)




$x^{(i)}$	$y^{(i)}$
44.6	9.81
73.4	12.4
5.0	1.63
33.7	8.17
18.9	4.87
$\vdots$	$\vdots$

$$J(h_w(x), y) = \frac{1}{n} \left[\begin{aligned} &(w \cdot 44.6 - 9.81)^2 + \\ &(w \cdot 73.4 - 12.4)^2 + \\ &(w \cdot 5.0 - 1.63)^2 + \\ &(w \cdot 33.7 - 8.17)^2 + \\ &(w \cdot 18.9 - 4.87)^2 + \\ &\vdots \end{aligned} \right]$$


Error cuadrático medio

4. Elección de la función de coste



$$J(h_w(x), y) = J(w) = \frac{1}{n} \sum_{i=1}^n (wx^{(i)} - y^{(i)})^2$$

Pasos del *machine learning*



Regresión univariable

- Muestreo
 - Hold-out
 - Cros-validación
- Hipótesis
 - Regresión lineal (sin *offset*)
 - Regresión lineal
 - Regresión polinómica
- Función de coste
 - Cuadrática
 - Regularización (regresión de arista)
- **Optimización**
 - **Ecuación normal**
 - Gradiente descendente
- Evaluación
 - Bootstrap

Normal Equation

5. Optimización del coste

$$w^* = \arg \min_w J(h_w(x), y) = \arg \min_w \frac{1}{n} \sum_{i=1}^n (wx^{(i)} - y^{(i)})^2$$

$$\frac{d}{dw} J(h_w(x), y) = 0$$

$$\frac{d}{dw} \frac{1}{n} \sum_{i=1}^n (wx^{(i)} - y^{(i)})^2 = 0$$

Normal Equation

5. Optimización del coste


$$\frac{1}{n} \sum_{i=1}^n \frac{d}{dw} \left(wx^{(i)} - y^{(i)} \right)^2 = 0$$

$$\sum_{i=1}^n 2 \left(w^* x^{(i)} - y^{(i)} \right) x^{(i)} = 0$$

$$w^* \sum_{i=1}^n x^{(i)2} - \sum_{i=1}^n x^{(i)} y^{(i)} = 0$$

Normal Equation


5. Optimización del coste



$$w^* = \frac{\sum_{i=1}^n x^{(i)} y^{(i)}}{\sum_{i=1}^n x^{(i)2}} = 0.20 \rightarrow J = 1.30$$


Normal Equation

5. Optimización del coste



Algunas funciones de coste pueden ser NO CONVEXAS
El error cuadrático medio es una función de coste CONVEXA


Pasos del *machine learning*



Generalización

6. Evaluación del resultado

Población $\mathcal{P}$



Habitantes
 N

Muestra $\mathcal{M}$
(dataset)



Cientes
 n

Generalización

6. Evaluación del resultado

Riesgo: $R_{\mathcal{P}}[h] = E_{\mathcal{P}}[J(h(x), y)] = \frac{1}{N} \sum_{i=1}^N J(h(x_i), y_i)$

Riesgo experimental

$$R_{\mathcal{M}}[h] = E_{\mathcal{M}}[J(h(x), y)] = \frac{1}{n} \sum_{i=1}^n J(h(x_i), y_i)$$

$$R_{\mathcal{P}}[h] = (R_{\mathcal{P}}[h] - R_{\mathcal{M}}[h]) + R_{\mathcal{M}}[h]$$

Riesgo

Error de
generalización

Riesgo
experimental

Generalización

6. Evaluación del resultado

$$R_{\mathcal{P}}[h] = (R_{\mathcal{P}}[h] - R_{\mathcal{M}}[h]) + R_{\mathcal{M}}[h]$$

$$R_{\mathcal{P}}[h] = R_{\mathcal{M}}[h] + \varepsilon_{gen}[h]$$

Riesgo
experimental

Error de
generalización

$\sim$ Test
error

Training
error

Bias

Variance

Regresión univariable

- Muestreo
 - Hold-out
 - Cros-validación
- Hipótesis
 - Regresión lineal (sin *offset*)
 - Regresión lineal
 - Regresión polinómica
- Función de coste
 - Cuadrática
 - Regularización (regresión de arista)
- Optimización
 - Ecuación normal
 - Gradiente descendente
- **Evaluación**
 - **Bootstrap**

Análisis bootstrap

6. Evaluación del resultado



Cliente	Ingresos x	Consumo y
1	44.6	9.81
2	73.4	12.4
3	5.0	1.63
4	33.7	8.17
5	18.9	4.87
6	13.8	3.54
7	22.7	5.94
8	37.8	8.59
9	42.7	9.47
10	56.2	11.1


$$J = 1.30$$

Cliente	Ingresos x	Consumo y
6	13.8	3.54
9	42.7	9.47
6	13.8	3.54
1	44.6	9.81
1	44.6	9.81
2	73.4	12.4
8	37.8	8.59
7	22.7	5.94
3	5.0	1.63
4	33.7	8.17

$$J = 1.29$$


Análisis bootstrap

6. Evaluación del resultado




Análisis bootstrap

6. Evaluación del resultado




Análisis bootstrap

6. Evaluación del resultado




$n = 10$



$n = 100$

Análisis bootstrap


6. Evaluación del resultado



$$n = 100$$

Análisis bootstrap


6. Evaluación del resultado



Análisis bootstrap

6. Evaluación del resultado

Learning curve




$$R_{\mathcal{P}}[h] = R_{\mathcal{M}}[h] + \varepsilon_{gen}[h]$$

Regresión univariable

- **Muestreo**
 - **Hold-out**
 - Cros-validación
- Hipótesis
 - Regresión lineal (sin *offset*)
 - Regresión lineal
 - Regresión polinómica
- Función de coste
 - Cuadrática
 - Regularización (regresión de arista)
- Optimización
 - Ecuación normal
 - Gradiente descendente
- Evaluación
 - Bootstrap


Pasos del *machine learning*



Hold-out

1. Extracción de una muestra

Población $\mathcal{P}$



Muestra $\mathcal{M}$
(dataset)



Hold-out
(reserva)


Hold-out

1. Extracción de una muestra

Muestra $\mathcal{M}$
(dataset)




Hold-out
(reserva)



Evaluación de
resultados


Hold-out

6. Evaluación del resultado




Hold-out

6. Evaluación del resultado



Hold-out

6. Evaluación del resultado




Regresión univariable

- Muestreo
 - Hold-out
 - Cros-validación
- Hipótesis
 - Regresión lineal (sin *offset*)
 - Regresión lineal
 - Regresión polinómica
- Función de coste
 - Cuadrática
 - Regularización (regresión de arista)
- **Optimización**
 - Ecuación normal
 - **Gradiente descendente**
- Evaluación
 - Bootstrap

Pasos del *machine learning*

Gradient Descent



Gradient Descent (GD)

5. Optimización del coste

- Problemas de la optimización por Normal Equation
 - El tiempo de cálculo crece con el número de features
 - No es aplicable a todas las funciones de coste
 - A veces no hay solución analítica a la ecuación:

$$\frac{d}{dw} J(h_w(x), y) = 0$$

Gradient Descent (GD)

5. Optimización del coste

- Alternativa: Gradient Descent (GD)


$$w^{(t+1)} \leftarrow w^{(t)} - \alpha \frac{d}{dw} J(h_w(x), y)$$

$$w^{(t+1)} \leftarrow w^{(t)} - \alpha \frac{d}{dw} J(w)$$

α : learning rate

Gradient Descent (GD)

5. Optimización del coste



$\alpha = 2 \cdot 10^{-4}$: (learning rate) pequeño

Gradient Descent (GD)

5. Optimización del coste

$$\frac{d}{dw}J(w) = \frac{d}{dw} \frac{1}{n} \sum_{i=1}^n (wx^{(i)} - y^{(i)})^2$$

$$\frac{d}{dw}J(w) = \frac{1}{n} \sum_{i=1}^n \frac{d}{dw} (wx^{(i)} - y^{(i)})^2$$

$$\frac{d}{dw}J(w) = \frac{1}{n} \sum_{i=1}^n 2(wx^{(i)} - y^{(i)})x^{(i)}$$

$$\frac{d^2}{dw^2}J(w) = \frac{2}{n} \sum_{i=1}^n x^{(i)2}$$

Positiva
(y constante)

Gradient Descent (GD)

5. Optimización del coste

- Repetir hasta convergencia

Es decir, hasta alcanzar un mínimo de $J(w)$


Derivada de la función de
coste correspondiente
al i -ésimo punto

$$w^{(t+1)} \leftarrow w^{(t)} - \alpha \underbrace{\frac{1}{n} \sum_{i=1}^n \overbrace{2(w x^{(i)} - y^{(i)}) x^{(i)}}^{\text{Derivada de la función de coste correspondiente al } i\text{-ésimo punto}}}_{\text{Media de la derivada de la función de coste para todos los puntos}}$$

Media de la derivada
de la función de coste
para todos los puntos

Gradient Descent (GD)


5. Optimización del coste



$\alpha = 2 \cdot 10^{-4}$:(learning rate) pequeño

Gradient Descent (GD)


5. Optimización del coste



$\alpha = 5 \cdot 10^{-4}$: (learning rate) grande

Gradient Descent (GD)

5. Optimización del coste



$\alpha = 5 \cdot 10^{-4}$: (learning rate) grande

Stochastic Gradient Descent (SGD)

5. Optimización del coste

- Repetir hasta convergencia
 - Ordenar aleatoriamente los pares $(x^{(i)}, y^{(i)})$
 - Para $i = 1, 2, \dots, n$ hacer


$$w^{(t+1)} \leftarrow w^{(t)} - \alpha \underbrace{2(w x^{(i)} - y^{(i)}) x^{(i)}}_{\text{Aproximación a la derivada de la función de coste correspondiente a un único punto}} \quad \left. \vphantom{\underbrace{2(w x^{(i)} - y^{(i)}) x^{(i)}}} \right\} \text{Una época}$$

Aproximación a la derivada
de la función de coste

Correspondiente a
un único punto


Stochastic Gradient Descent (SGD)

5. Optimización del coste



Stochastic Gradient Descent (SGD)

5. Optimización del coste



Batch Gradient Descent (BGD)

5. Optimización del coste

- Repetir hasta convergencia
 - Ordenar aleatoriamente los pares $(x^{(i)}, y^{(i)})$
 - Establecer m tandas de datos de dimensión b
 - Para tanda = $1, 2, \dots, m$ hacer

$$w^{(t+1)} \leftarrow w^{(t)} - \alpha \underbrace{\frac{1}{b} \sum_{i=1}^b 2(w x^{(i)} - y^{(i)}) x^{(i)}}_{\text{Aproximación a la derivada de la función de coste}}$$


Una época

Aproximación a la derivada
de la función de coste

Media correspondiente a
una tanda de puntos


Batch Gradient Descent (SGD)

5. Optimización del coste



Batch Gradient Descent (SGD)


5. Optimización del coste



Regresión univariable


- Muestreo
 - Hold-out
 - Cros-validación
- **Hipótesis**
 - Regresión lineal (sin *offset*)
 - **Regresión lineal**
 - Regresión polinómica
- Función de coste
 - Cuadrática
 - Regularización (regresión de arista)
- Optimización
 - Ecuación normal
 - Gradiente descendente
- Evaluación
 - Bootstrap

Pasos del *machine learning*



Regresión lineal

3. Formulación de hipótesis



La posición de la recta depende de los parámetros w_0 y w_1

$$\text{Hipótesis } h_w(x) = w_0 + w_1x$$

Regresión lineal

3. Formulación de hipótesis

$$h_w(x) = w_0 + w_1 x$$


$$x = \begin{bmatrix} x^{(1)} \\ x^{(2)} \\ \vdots \\ x^{(n)} \end{bmatrix} \Rightarrow \mathbb{X} = \begin{bmatrix} 1 & x^{(1)} \\ 1 & x^{(2)} \\ \vdots & \vdots \\ 1 & x^{(n)} \end{bmatrix}$$

$$w = [w_0 \quad w_1]; \quad w^T = \begin{bmatrix} w_0 \\ w_1 \end{bmatrix}$$

$$h_w(x) = \mathbb{X}w^T$$

Regresión lineal

4. Elección de la función de coste




Error
cuadrático
medio

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

Regresión lineal

4. Elección de la función de coste



Error
cuadrático
medio

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

Regresión lineal

4. Elección de la función de coste

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

$$h_w(x) = w_0 + w_1 x$$

$$y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix}$$

Regresión lineal

4. Elección de la función de coste

$$\mathbb{X}w^T - y = \begin{bmatrix} w_0 + w_1 x^{(1)} \\ w_0 + w_1 x^{(2)} \\ \vdots \\ w_0 + w_1 x^{(n)} \end{bmatrix} - \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix} = \begin{bmatrix} w_0 + w_1 x^{(1)} - y^{(1)} \\ w_0 + w_1 x^{(2)} - y^{(2)} \\ \vdots \\ w_0 + w_1 x^{(n)} - y^{(n)} \end{bmatrix}$$

$$(\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y) = \sum_{i=1}^n (w_0 + w_1 x^{(i)} - y^{(i)})^2$$

$$J(h_w(x), y) = \frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y)$$

Regresión lineal

5. Optimización mediante Normal Equation

$$w^* = \arg \min_w J(h_w(x), y)$$

$$w^* = \arg \min_w \left[\frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y) \right]$$

$$\frac{\partial}{\partial w_j} J(h_w(x), y) = 0, \forall j$$

∇ : operador nabla

∇J : gradiente

$$\nabla J(h_w(x), y) \equiv \begin{bmatrix} \frac{\partial J}{\partial w_0} \\ \frac{\partial J}{\partial w_1} \end{bmatrix} = 0$$

Regresión lineal

5. Optimización mediante Normal Equation



$$\nabla J \equiv \begin{bmatrix} \frac{\partial J}{\partial w_0} \\ \frac{\partial J}{\partial w_1} \end{bmatrix}$$

Jacobiano

$$H \equiv \nabla^2 J \equiv \begin{bmatrix} \frac{\partial^2 J}{\partial w_0^2} & \frac{\partial^2 J}{\partial w_0 \partial w_1} \\ \frac{\partial^2 J}{\partial w_1 \partial w_0} & \frac{\partial^2 J}{\partial w_1^2} \end{bmatrix}$$

Hessiano

Regresión lineal

5. Optimización mediante Normal Equation

$$J = \frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y)$$

$$J = \frac{1}{n} [(\mathbb{X}w^T)^T - y^T] (\mathbb{X}w^T - y)$$

$$J = \frac{1}{n} (w\mathbb{X}^T - y^T) (\mathbb{X}w^T - y)$$

$$J = \frac{1}{n} (w\mathbb{X}^T \mathbb{X}w^T - w\mathbb{X}^T y - y^T \mathbb{X}w^T + y^T y)$$

Regresión lineal

5. Optimización mediante Normal Equation

$$\begin{matrix} & \begin{matrix} (1+2) & (2+n) & (n+1) \end{matrix} \\ (1 \times 1) & w \mathbb{X}^T y = (w \mathbb{X}^T y)^T = y^T (w \mathbb{X}^T)^T = y^T \mathbb{X} w^T & \begin{matrix} (1+n) & (n+2) & (2+1) \end{matrix} \\ & & (1 \times 1) \end{matrix}$$

$$J = \frac{1}{n} (w \mathbb{X}^T \mathbb{X} w^T - 2w \mathbb{X}^T y + y^T y)$$

$$\mathbb{X} = \begin{bmatrix} 1 & x^{(1)} \\ 1 & x^{(2)} \\ \vdots & \vdots \\ 1 & x^{(n)} \end{bmatrix}; y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix}$$

$$w = [w_0 \quad w_1]; \quad w^T = \begin{bmatrix} w_0 \\ w_1 \end{bmatrix}$$

Regresión lineal

5. Optimización mediante Normal Equation

$$\mathbb{X}^T \mathbb{X} = \begin{bmatrix} 1 & 1 & \dots & 1 \\ x^{(1)} & x^{(2)} & \dots & x^{(n)} \end{bmatrix} \begin{bmatrix} 1 & x^{(1)} \\ 1 & x^{(2)} \\ \vdots & \vdots \\ 1 & x^{(n)} \end{bmatrix}$$

$$\mathbb{X}^T \mathbb{X} = \begin{bmatrix} 1^2 + 1^2 + \dots + 1^2 & x^{(1)} + x^{(2)} + \dots + x^{(n)} \\ x^{(1)} + x^{(2)} + \dots + x^{(n)} & x^{(1)^2} + x^{(2)^2} + \dots + x^{(n)^2} \end{bmatrix}$$

Regresión lineal

5. Optimización mediante Normal Equation

$$\mathbb{X}^T \mathbb{X} = \begin{bmatrix} \sum_{i=1}^n 1^2 & \sum_{i=1}^n x^{(i)} \\ \sum_{i=1}^n x^{(i)} & \sum_{i=1}^n x^{(i)2} \end{bmatrix}$$

$$\mathbb{X}^T \mathbb{X} \mathbf{w}^T = \begin{bmatrix} \sum_{i=1}^n 1^2 & \sum_{i=1}^n x^{(i)} \\ \sum_{i=1}^n x^{(i)} & \sum_{i=1}^n x^{(i)2} \end{bmatrix} \begin{bmatrix} w_0 \\ w_1 \end{bmatrix}$$

Regresión lineal

5. Optimización mediante Normal Equation

$$\mathbb{X}^T \mathbb{X} \mathbf{w}^T = \begin{bmatrix} w_0 \sum_{i=1}^n 1^2 + w_1 \sum_{i=1}^n x^{(i)} \\ w_0 \sum_{i=1}^n x^{(i)} + w_1 \sum_{i=1}^n x^{(i)^2} \end{bmatrix}$$

$$\mathbf{w} \mathbb{X}^T \mathbb{X} \mathbf{w}^T = [w_0 \quad w_1] \mathbb{X}^T \mathbb{X} \mathbf{w}^T = w_0 w_0 \sum_{i=1}^n 1^2 + w_0 w_1 \sum_{i=1}^n x^{(i)} + w_1 w_0 \sum_{i=1}^n x^{(i)} + w_1 w_1 \sum_{i=1}^n x^{(i)^2}$$

Regresión lineal

5. Optimización mediante Normal Equation

$$wX^T X w^T = w_0^2 \sum_{i=1}^n 1^2 + 2w_0 w_1 \sum_{i=1}^n x^{(i)} + w_1^2 \sum_{i=1}^n x^{(i)2}$$

$$wX^T y = [w_0 \quad w_1] \begin{bmatrix} 1 & 1 & \dots & 1 \\ x^{(1)} & x^{(2)} & \dots & x^{(n)} \end{bmatrix} y$$

$$wX^T y = [w_0 + w_1 x^{(1)} \quad w_0 + w_1 x^{(2)} \quad \dots \quad w_0 + w_1 x^{(n)}] y$$

$$wX^T y = (w_0 + w_1 x^{(1)})y^{(1)} + (w_0 + w_1 x^{(1)})y^{(2)} + \dots + (w_0 + w_1 x^{(1)})y^{(n)}$$

Regresión lineal

5. Optimización mediante Normal Equation

$$wX^T y = \sum_{i=1}^n (w_0 + w_1 x^{(i)}) y^{(i)}$$

$$y^T y = \sum_{i=1}^n y^{(i)2}$$

$$nJ = w_0^2 \sum_{i=1}^n 1^2 + 2w_0w_1 \sum_{i=1}^n x^{(i)} + w_1^2 \sum_{i=1}^n x^{(i)2} -$$
$$2 \sum_{i=1}^n (w_0 + w_1 x^{(i)}) y^{(i)} + \sum_{i=1}^n y^{(i)2}$$

Regresión lineal

5. Optimización mediante Normal Equation

$$\frac{\partial J}{\partial \mathbf{w}} = \begin{bmatrix} \frac{\partial J}{\partial w_0} \\ \frac{\partial J}{\partial w_1} \end{bmatrix}$$

$$n \left(\frac{\partial J}{\partial \mathbf{w}} \right) = \begin{bmatrix} 2w_0 \sum_{i=1}^n 1^2 + 2w_1 \sum_{i=1}^n x^{(i)} - 2 \sum_{i=1}^n y^{(i)} \\ 2w_1 \sum_{i=1}^n x^{(i)2} + 2w_0 \sum_{i=1}^n x^{(i)} - 2 \sum_{i=1}^n x^{(i)} y^{(i)} \end{bmatrix}$$

Regresión lineal

5. Optimización mediante Normal Equation

$$\frac{\partial J}{\partial w_0} = \frac{2}{n} \sum_{i=1}^n (w_0 + w_1 x^{(i)} - y^{(i)})$$

$$\frac{\partial J}{\partial w_1} = \frac{2w_1}{n} \sum_{i=1}^n x^{(i)2} + \frac{2w_0}{n} \sum_{i=1}^n x^{(i)} - \frac{2}{n} \sum_{i=1}^n x^{(i)} y^{(i)}$$

$$\frac{\partial J}{\partial w_1} = \frac{2}{n} \sum_{i=1}^n (w_0 + w_1 x^{(i)} - y^{(i)}) x^{(i)}$$

Regresión lineal

5. Optimización mediante Normal Equation

$$\left(\frac{\partial J}{\partial \mathbf{w}}\right) = \begin{bmatrix} \frac{\partial J}{\partial w_0} \\ \frac{\partial J}{\partial w_1} \end{bmatrix}$$

$$n \left(\frac{\partial J}{\partial \mathbf{w}}\right) = 2 \begin{bmatrix} w_0 \sum_{i=1}^n 1^2 + w_1 \sum_{i=1}^n x^{(i)} \\ w_1 \sum_{i=1}^n x^{(i)2} + w_0 \sum_{i=1}^n x^{(i)} \end{bmatrix} - 2 \begin{bmatrix} \sum_{i=1}^n y^{(i)} \\ \sum_{i=1}^n x^{(i)} y^{(i)} \end{bmatrix}$$

Regresión lineal

5. Optimización mediante Normal Equation

$$\mathbb{X}^T \mathbf{y} = \begin{bmatrix} 1 & 1 & \dots & 1 \\ x^{(1)} & x^{(2)} & \dots & x^{(n)} \end{bmatrix} \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n y^{(i)} \\ \sum_{i=1}^n x^{(i)} y^{(i)} \end{bmatrix}$$

$$n \left(\frac{\partial J}{\partial \mathbf{w}} \right) = 2 \mathbb{X}^T \mathbb{X} \mathbf{w}^T - 2 \mathbb{X}^T \mathbf{y}$$

$$\nabla J = \frac{\partial J}{\partial \mathbf{w}} = \frac{2}{n} (\mathbb{X}^T \mathbb{X} \mathbf{w}^T - \mathbb{X}^T \mathbf{y}) = 0$$

Regresión lineal

5. Optimización mediante Normal Equation

$$\nabla J = \frac{2}{n} (\mathbb{X}^T \mathbb{X} w^T - \mathbb{X}^T y)^T$$

$$\nabla J = \frac{2}{n} [(\mathbb{X}^T \mathbb{X} w^T)^T - (\mathbb{X}^T y)^T]$$

$$\nabla J = \frac{2}{n} [w(\mathbb{X}^T \mathbb{X})^T - y^T \mathbb{X}]$$

$$\nabla J = \frac{2}{n} (w \mathbb{X}^T \mathbb{X} - y^T \mathbb{X}) = 0$$

$$w^* \mathbb{X}^T \mathbb{X} = y^T \mathbb{X}$$

$$w^* = y^T \mathbb{X} (\mathbb{X}^T \mathbb{X})^{-1}$$

Regresión lineal

5. Optimización mediante Normal Equation

$$H \equiv \nabla^2 J = \begin{bmatrix} \frac{\partial^2 J}{\partial w_0^2} & \frac{\partial^2 J}{\partial w_0 \partial w_1} \\ \frac{\partial^2 J}{\partial w_1 \partial w_0} & \frac{\partial^2 J}{\partial w_1^2} \end{bmatrix}$$

Condición de convexidad:

El Hessiano es una matriz semidefinida positiva

$$z = \begin{bmatrix} z_0 \\ z_1 \end{bmatrix} \in \mathbb{R}^2$$

$$z^T H z \geq 0$$

Regresión lineal

5. Optimización mediante Normal Equation

$$\frac{\partial J}{\partial w_0} = \frac{2}{n} \sum_{i=1}^n (w_0 + w_1 x^{(i)} - y^{(i)})$$

$$\frac{\partial^2 J}{\partial w_0^2} = \frac{2}{n} \sum_{i=1}^n 1 = 2$$

$$\frac{\partial^2 J}{\partial w_1 \partial w_0} = \frac{2}{n} \sum_{i=1}^n x^{(i)}$$

Regresión lineal

5. Optimización mediante Normal Equation

$$\frac{\partial J}{\partial w_1} = \frac{2}{n} \sum_{i=1}^n (w_0 + w_1 x^{(i)} - y^{(i)}) x^{(i)}$$

$$\frac{\partial^2 J}{\partial w_0 \partial w_1} = \frac{2}{n} \sum_{i=1}^n x^{(i)}$$

$$\frac{\partial^2 J}{\partial w_1^2} = \frac{2}{n} \sum_{i=1}^n x^{(i)2}$$

Regresión lineal

5. Optimización mediante Normal Equation

$$H \equiv \nabla^2 J = \frac{2}{n} \begin{bmatrix} n & \sum_{i=1}^n x^{(i)} \\ \sum_{i=1}^n x^{(i)} & \sum_{i=1}^n x^{(i)2} \end{bmatrix} = \frac{2}{n} \mathbb{X}^T \mathbb{X}$$

Condición de convexidad:

El Hessiano es una matriz semidefinida positiva

$$z = \begin{bmatrix} z_0 \\ z_1 \end{bmatrix} \in \mathbb{R}^2$$

$$z^T H z \geq 0$$

Regresión lineal

5. Optimización mediante Normal Equation

$$z^T H z = [z_0 \quad z_1] \frac{2}{n} \begin{bmatrix} n & \sum_{i=1}^n x^{(i)} \\ \sum_{i=1}^n x^{(i)} & \sum_{i=1}^n x^{(i)2} \end{bmatrix} \begin{bmatrix} z_0 \\ z_1 \end{bmatrix}$$

$$z^T H z = \frac{2}{n} \begin{bmatrix} z_0 n + z_1 \sum_{i=1}^n x^{(i)} & z_0 \sum_{i=1}^n x^{(i)} + z_1 \sum_{i=1}^n x^{(i)2} \end{bmatrix} \begin{bmatrix} z_0 \\ z_1 \end{bmatrix}$$

$$z^T H z = \frac{2}{n} \left(z_0^2 n + z_0 z_1 \sum_{i=1}^n x^{(i)} + z_1 z_0 \sum_{i=1}^n x^{(i)} + z_1^2 \sum_{i=1}^n x^{(i)2} \right)$$

Regresión lineal

5. Optimización mediante Normal Equation

$$z^T H z = \frac{2}{n} \left(z_0^2 \sum_{i=1}^n 1 + 2z_0 z_1 \sum_{i=1}^n x^{(i)} + z_1^2 \sum_{i=1}^n x^{(i)2} \right)$$

$$z^T H z = \frac{2}{n} \left(\sum_{i=1}^n z_0^2 + \sum_{i=1}^n 2z_0 z_1 x^{(i)} + \sum_{i=1}^n z_1^2 x^{(i)2} \right)$$

$$z^T H z = \frac{2}{n} \sum_{i=1}^n \left(z_0^2 + 2z_0 z_1 x^{(i)} + z_1^2 x^{(i)2} \right)$$

Regresión lineal

5. Optimización mediante Normal Equation


$$z^T H z = \frac{2}{n} \sum_{i=1}^n \left(z_0 + z_1 x^{(i)} \right)^2$$

$$\left(z_0 + z_1 x^{(i)} \right)^2 \geq 0, \forall z, x^{(i)} \in \mathbb{R}^2$$

$$z^T H z \geq 0$$

Regresión lineal


5. Optimización mediante Normal Equation



$$w^* = y^T X (X^T X)^{-1} = [1.75 \quad 0.17]$$

Regresión lineal

5. Optimización mediante Gradient Descent




$$w_0^{(t+1)} \leftarrow w_0^{(t)} - \alpha \frac{\partial J(w)}{\partial w_0}$$

$$w_1^{(t+1)} \leftarrow w_1^{(t)} - \alpha \frac{\partial J(w)}{\partial w_1}$$


Regresión lineal

5. Optimización mediante Gradient Descent

SGD




BGD



Regresión univariable

- Muestreo
 - Hold-out
 - Cros-validación
- **Hipótesis**
 - Regresión lineal (sin *offset*)
 - Regresión lineal
 - **Regresión polinómica**
- Función de coste
 - Cuadrática
 - Regularización (regresión de arista)
- Optimización
 - Ecuación normal
 - Gradiente descendente
- Evaluación
 - Bootstrap

Pasos del *machine learning*



Regresión polinómica

2. Determinación de *features*

Cliente	$x^{(i)}$ $\varphi_1^{(i)}$	$x^{(i)2}$ $\varphi_2^{(i)}$	$x^{(i)3}$ $\varphi_3^{(i)}$	...	$y^{(i)}$
1	44.6	1991	88818	...	9.81
2	73.4	5392	395945	...	12.4
3	5.0	25	125	...	1.63
4	33.7	1137	38346	...	8.17
5	18.9	359	6796	...	4.87
⋮	⋮	⋮	⋮	⋮	⋮


Regresión polinómica

2. Determinación de *features*

			f	φ	K	X
Rule-based systems		$y = f(X)$	Manual	-	-	Manual
Machine Learning	Basic ML	$y = f(X)$	Automatic	-	-	Manual
	Feature-based ML	$y = f[\varphi(X)]$	Automatic	Manual	-	Raw
	Kernel-based ML	$y = f[K(X)]$	Automatic	Automatic	Manual	Raw
	Deep Learning	$y = f(\varphi(X))$	Automatic	Automatic	-	Raw

Regresión polinómica

3. Formulación de hipótesis



La hipótesis depende del vector de parámetros w

$$h_w(x) = \sum_{j=0}^r w_j x^j$$

Regresión polinómica en x y lineal en w

Regresión polinómica

3. Formulación de hipótesis

$$h_w(x) = \sum_{j=0}^r w_j x^j$$

Regresión
polinómica en x
y lineal en w

$$h_w(x) = w_0 x^0 + w_1 x^1 + w_2 x^2 + \dots + w_r x^r$$

$$h_w(x^{(i)}) = w_0 x^{(i)0} + w_1 x^{(i)1} + w_2 x^{(i)2} + \dots + w_r x^{(i)r}$$

Regresión polinómica

3. Formulación de hipótesis

$$h_w(x^{(i)}) = w_0 x^{(i)0} + w_1 x^{(i)1} + w_2 x^{(i)2} + \dots + w_r x^{(i)r}$$

$$\begin{array}{c} \leftarrow d \rightarrow d = r + 1 \\ \mathbb{X}^{(i)} \equiv \begin{bmatrix} x^{(i)0} & x^{(i)1} & x^{(i)2} & \dots & x^{(i)r} \end{bmatrix} \quad (1 \times d) \end{array}$$

$$w^T = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_r \end{bmatrix} \begin{array}{c} \uparrow \\ d \\ \downarrow \end{array} \quad (d \times 1)$$

$$h_w(x^{(i)}) = \mathbb{X}^{(i)} w^T \quad (1 \times d)(d \times 1) = (1 \times 1)$$

Regresión polinómica

4. Elección de la función de coste

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

$$h_w(x^{(i)}) = \mathbb{X}^{(i)} w^T$$

$$y^{(i)} = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix}$$

Regresión polinómica

4. Elección de la función de coste

$$\mathbb{X} = \begin{bmatrix} \mathbb{X}^{(1)} \\ \mathbb{X}^{(2)} \\ \vdots \\ \mathbb{X}^{(n)} \end{bmatrix} = \begin{bmatrix} x^{(1)0} & x^{(1)1} & \dots & x^{(1)r} \\ x^{(2)0} & x^{(2)1} & \dots & x^{(2)r} \\ \vdots & \vdots & \ddots & \vdots \\ x^{(n)0} & x^{(n)1} & \dots & x^{(n)r} \end{bmatrix} \quad \begin{matrix} (n \times d) \\ w^T = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_r \end{bmatrix} \\ (d \times 1) \end{matrix}$$

$$\mathbb{X}w^T = \begin{bmatrix} w_0 x^{(1)0} + w_1 x^{(1)1} + \dots + w_r x^{(1)r} \\ w_0 x^{(2)0} + w_1 x^{(2)1} + \dots + w_r x^{(2)r} \\ \vdots \\ w_0 x^{(n)0} + w_1 x^{(n)1} + \dots + w_r x^{(n)r} \end{bmatrix} = \begin{bmatrix} h(x^{(1)}) \\ h(x^{(2)}) \\ \vdots \\ h(x^{(n)}) \end{bmatrix} \quad \begin{matrix} (n \times 1) \end{matrix}$$

Regresión polinómica

4. Elección de la función de coste

$$\mathbb{X}w^T - y = \begin{bmatrix} h(x^{(1)}) \\ h(x^{(2)}) \\ \vdots \\ h(x^{(n)}) \end{bmatrix} - \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix} = \begin{bmatrix} h(x^{(1)}) - y^{(1)} \\ h(x^{(2)}) - y^{(2)} \\ \vdots \\ h(x^{(n)}) - y^{(n)} \end{bmatrix} \quad (n \times 1)$$

$$\begin{matrix} (1 \times n) & & (n \times 1) & & (1 \times 1) \\ (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y) = & (h(x^{(1)}) - y^{(1)})^2 + \\ & (h(x^{(2)}) - y^{(2)})^2 + \\ & \vdots \\ & (h(x^{(n)}) - y^{(n)})^2 + \end{matrix}$$

Regresión polinómica

4. Elección de la función de coste

$$(\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y) = \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

$$J(h_w(x), y) = \frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y)$$

Regresión polinómica

5. Optimización mediante Normal Equation

$$\begin{array}{c} (1 \times n) \quad (d \times n) \\ \downarrow \quad \downarrow \\ (1 \times d) \quad w^* = y^T \mathbb{X} (\mathbb{X}^T \mathbb{X})^{-1} \\ \uparrow \quad \uparrow \\ (n \times d) \quad (n \times d) \end{array}$$

$$\begin{array}{c} (1 \times d) \quad \boxed{w^* = y^T \mathbb{X} \underbrace{(\mathbb{X}^T \mathbb{X})^{-1}}_{(d \times d)}} \end{array}$$

Regresión polinómica


5. Optimización mediante Normal Equation

- Problemas de la optimización por Normal Equation
 - El tiempo de cálculo crece con el número de features
 - No es aplicable a todas las funciones de coste
 - A veces no hay solución analítica

$$w^* = y^T \underbrace{X(X^T X)^{-1}}_{(d \times d)}$$

Regresión polinómica


5. Optimización mediante Gradient Descent



Regresión polinómica

6. Evaluación del resultado

$$R_{\mathcal{P}}[h] = R_{\mathcal{M}}[h] + \varepsilon_{gen}[h]$$



$R_{\mathcal{M}}$: bias

ε_{gen} : variance


$R_{\mathcal{P}} \approx \text{test error}$

Bias-variance tradeoff
Fitting-stability tension

Regresión univariable

- **Muestreo**
 - Hold-out
 - **Cros-validación**
- Hipótesis
 - Regresión lineal (sin *offset*)
 - Regresión lineal
 - Regresión polinómica
- Función de coste
 - Cuadrática
 - Regularización (regresión de arista)
- Optimización
 - Ecuación normal
 - Gradiente descendente
- Evaluación
 - Bootstrap

Pasos del *machine learning*



Cross-validation

1. Extracción de una muestra

Muestra $\mathcal{M}$
(dataset)




Hold-out
(reserva)



Elección de
hiperparámetros


Cross-validation

3. Formulación de hipótesis



Cross-validation


1. Extracción de una muestra



Cross-validation

Cross-validation


6. Evaluación del modelo ante nuevos datos



Regresión univariable


- Muestreo
 - Hold-out
 - Cros-validación
- Hipótesis
 - Regresión lineal (sin *offset*)
 - Regresión lineal
 - Regresión polinómica
- **Función de coste**
 - Cuadrática
 - **Regularización (regresión de arista)**
- Optimización
 - Ecuación normal
 - Gradiente descendente
- Evaluación
 - Bootstrap

Pasos del *machine learning*




Regularización (Ridge Regression)

4. Elección de la función de coste



Regularización (Ridge Regression)

Fenómeno de Runge




$$y = \frac{1}{1 + 25x^2}$$

Epperson, J. F. (1987). On the Runge example. *The American Mathematical Monthly*, 94(4).

<http://www.math.drexel.edu/~tolya/epperson.pdf>


Regularización (Ridge Regression)

Fenómeno de Runge




Regularización (Ridge Regression)

Fenómeno de Runge



Regularización (Ridge Regression)


Fenómeno de Runge



Los w_i mayores son los de los términos de menor orden y crecen con el orden del polinomio

Regularización (Ridge Regression)


Fenómeno de Runge



$\|w\|$ crece con el orden del polinomio


Regularización (Ridge Regression)

4. Elección de la función de coste



Regularización (Ridge Regression)


4. Elección de la función de coste



Los w_i mayores son los de los términos de menor orden
y crecen con el orden del polinomio

Regularización (Ridge Regression)

4. Elección de la función de coste



$\|w\|$ crece
con el orden
del polinomio

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

Regularización (Ridge Regression)

4. Elección de la función de coste

Regularización de Tikhonov


$$J_o(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

$$w^* = \arg \min_w J_o(h_w(x), y) \\ \text{st. } \|w\|_2^2 \leq R^2$$

$$\|w\|_2^2 \equiv \sum_{i=1}^d w_i^2$$

Regularización (Ridge Regression)


4. Elección de la función de coste



$$w^* = \arg \min_w J_o(h_w(x), y)$$

Regularización (Ridge Regression)

4. Elección de la función de coste




$$w^* = \arg \min_w J_o(h_w(x), y)$$
$$\text{st. } \|w\|_2^2 \leq R^2$$

Regularización (Ridge Regression)


4. Elección de la función de coste

Ridge



Lasso

Least Absolute Shrinkage and Selection Operator



$$\|w\|_2^2 = \sum_{i=1}^d w_i^2 \leq R^2$$

$$\|w\|_1 = \sum_{i=1}^d |w_i| \leq R$$

Regularización (Ridge Regression)

4. Elección de la función de coste

$$w^* = \arg \min_w J_o(h_w(x), y) \text{ st. } \|w\|_2^2 \leq R^2$$

$$w^* = \arg \min_w J_o(h_w(x), y) \text{ st. } \|w\|_2^2 - R^2 \leq 0$$

Multiplicadores de Lagrange

$$J(h_w(x), y) = J_o(h_w(x), y) + \lambda(\|w\|_2^2 - R^2)$$

$$w^* = \arg \min_w J(h_w(x), y)$$

Regularización (Ridge Regression)

4. Elección de la función de coste

$$w^* = \arg \min_w J(h_w(x), y)$$

$$w^* = \arg \min_w [J_0(h_w(x), y) + \lambda(\|w\|_2^2 - R^2)]$$



$$w^* = \arg \min_w [J_0(h_w(x), y) + \lambda\|w\|_2^2 - \lambda R^2]$$

$$w^* = \arg \min_w [J_0(h_w(x), y) + \lambda\|w\|_2^2]$$

Regularización (Ridge Regression)

4. Elección de la función de coste

Función de coste en escala lineal



$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

Regularización (Ridge Regression)

4. Elección de la función de coste

Regularización de Tikhonov

$$J(h_w(x), y) = J_o(h_w(x), y) + \lambda \sum_{i=1}^d w_i^2$$

Error
cuadrático
medio

$$J_o(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{i=1}^d w_i^2$$

Regularización (Ridge Regression)

4. Elección de la función de coste

$$h_w(x) = \sum_{j=1}^d w_j x^j$$

Regresión
polinómica en x
y lineal en w

$$J_o(h_w(x), y) = \frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y)$$

Regresión de arista (ridge regression)

$$J(h_w(x), y) = \frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y) + \lambda \|w\|_2^2$$

Regularización (Ridge Regression)

5. Optimización mediante Normal Equation

$$J(h_w(x), y) = \frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y) + \lambda \|w\|_2^2$$

$$w^* = \min_w J(h_w(x), y)$$

$$w^* = \min_w \frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y) + \lambda \|w\|_2^2$$

$$\nabla J(h_w(x), y) = 0$$

$$\nabla \left[\frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y) + \lambda \|w\|_2^2 \right] = 0$$

Regularización (Ridge Regression)

5. Optimización mediante Normal Equation

$$\nabla J = \frac{2}{n} (w \mathbb{X}^T \mathbb{X} - y^T \mathbb{X}) + 2\lambda w = 0$$

$$w^* \mathbb{X}^T \mathbb{X} - y^T \mathbb{X} + n\lambda w^* = 0$$


$$w^* (\mathbb{X}^T \mathbb{X} + n\lambda I_d) - y^T \mathbb{X} = 0$$

$$w^* (\mathbb{X}^T \mathbb{X} + n\lambda I_d) = y^T \mathbb{X}$$

$$w^* = y^T \mathbb{X} (\mathbb{X}^T \mathbb{X} + n\lambda I_d)^{-1}$$

Regularización (Ridge Regression)


4. Elección de la función de coste




$$J(h_w(x), y) = \frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y) + \lambda \|w\|_2^2$$

Regularización (Ridge Regression)

4. Elección de la función de coste



$$\lambda = 0$$




$$\lambda = 100$$


$$J(h_w(x), y) = \frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y) + \lambda \|w\|_2^2$$

Regularización (Ridge Regression)

4. Elección de la función de coste



$\lambda = 0$




$\lambda = 100$

$$J(h_w(x), y) = \frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y) + \lambda \|w\|_2^2$$

Regularización (Ridge Regression)

4. Elección de la función de coste

$\|H\|$



$$H = \nabla^2 J = \frac{2}{n} \mathbb{X}^T \mathbb{X} + 2\lambda I_d$$

Regularización (Ridge Regression)

5. Optimización mediante Gradient Descent

Una
dimensión

$$w^{(t+1)} \leftarrow w^{(t)} - \alpha \frac{d}{dw} J(h_w(x), y)$$


Dos (o más) dimensiones

$$\begin{bmatrix} w_0^{(t+1)} \\ w_1^{(t+1)} \end{bmatrix} \leftarrow \begin{bmatrix} w_0^{(t)} \\ w_1^{(t)} \end{bmatrix} - \alpha \begin{bmatrix} \frac{\partial J(h_w(x), y)}{\partial w_0} \\ \frac{\partial J(h_w(x), y)}{\partial w_1} \end{bmatrix}$$

$$w^{(t+1)T} \leftarrow w^{(t)T} - \alpha \nabla J$$


Regularización (Ridge Regression)

5. Optimización mediante Gradient Descent




Regularización (Ridge Regression)

6. Evaluación del resultado



Regularización (Ridge Regression)

6. Evaluación del resultado



λ

$R_{\mathcal{M}}$: training error (bias)

$R_{\mathcal{P}} \approx$ test error

Regularización

Ventajas

- Aumenta convexidad función de coste
 - Optimización más rápida mediante GD
- Permite obviar la “navaja de Ockham”
 - Entia non sunt multiplicanda praeter necessitatem
 - A igualdad de condiciones, elegir los modelos más simples
 - Se deja crecer mucho el número de features (d)
 - Se restringe el valor de cada w_j , quedándonos sólo con los valores necesarios
- Sintoniza el bias-variance tradeoff (fitting-stability tension)

Regularización

Ventajas

- Si el número de elementos (n) es menor que el número de features (d), el sistema de ecuaciones $y = Xw^T$ tiene más incógnitas que ecuaciones y, por tanto, existe un número infinito de soluciones para w .
 - Con la regularización resolvemos la indeterminación eligiendo el valor de w que minimiza su norma

Regularización

Ventajas

- El cálculo de w mediante la normal equation se realiza con la expresión $w = y^T \mathbb{X}(\mathbb{X}^T \mathbb{X})^{-1}$. La matriz $\mathbb{X}^T \mathbb{X}$ es de dimensión $d \times d$. Sin embargo, si alguno de los features está correlado con otros, entonces el rango de la matriz es $r < d$ y resulta no invertible.
 - En el caso de usar regularización, la expresión para el cálculo de w^* es $w^* = y^T \mathbb{X}(\mathbb{X}^T \mathbb{X} + n\lambda I_d)^{-1}$. En esa expresión I_d es de rango d y, por tanto $(\mathbb{X}^T \mathbb{X} + n\lambda I_d)$ es también de rango d y, por tanto, invertible