

Fundamentos del aprendizaje automático

(Machine learning)

Joaquín Luque

Contenido

1. Introducción
2. Regresión
 - a) Regresión univariable
 - b) **Regresión multivariable**
3. Clasificación
 - a) Regresión logística
 - b) Máquinas de vectores soporte (SVM)
 - Forma dual de la optimización (regresión y SVM)
 - c) Funciones Kernel
 - d) Clasificación multiclase
4. Segmentación
5. Reducción de dimensionalidad
6. Deep learning (introducción)

Regresión multivariable

- Representación gráfica multivariable
- Codificación 1-hot
- Normalización de variables
- Descomposición en Valores Singulares
 - Matrices de covarianza y Gramm
 - Autovalores y autovectores
 - Definición de la SVD
 - Obtención de la SVD
 - Aplicación a la solución de la Normal Equation

Regresión multivariable


Ejemplo en el sector eléctrico

- En otra zona en la que opera la empresa los datos disponibles de los clientes para hacer la predicción de su consumo de energía son los siguientes:
 1. Ingresos anuales (€)
 2. Número de habitantes en la vivienda (promedio anual de personas)
 3. Potencia contratada (kW)
 4. Tipo de vivienda (piso, adosado, casa)
 5. Superficie de la vivienda (m²)
 6. Horas de ocupación en invierno (horas/día)
 7. Horas de ocupación en verano (horas/día)
 8. Edad (años)
 9. Estado civil (soltero, casado, separado, viudo)
 10. Nivel de estudios alcanzado (sin estudios, primaria, secundaria, bachiller, grado, máster, doctor)

Regresión multivariable

2. Determinación de *features*

Muestra $\mathcal{M}$
(dataset)



n elementos

i -ésimo elemento

Caracterizado por d features (rasgos):

- $x^{(i)}$: vector fila con d features

Valor del objetivo (target) :

- $y^{(i)}$: consumo anual de electricidad

$$(n \times d) \quad X = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \cdots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(n)} & x_2^{(n)} & \cdots & x_d^{(n)} \end{bmatrix} \quad (n \times 1) \quad y^{(i)} = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix}$$


2. Determinación de *features*

[illegible]


Regresión multivariable

- Representación gráfica multivariable
- Codificación 1-hot
- Normalización de variables
- Descomposición en Valores Singulares
 - Matrices de covarianza y Gramm
 - Autovalores y autovectores
 - Definición de la SVD
 - Obtención de la SVD
 - Aplicación a la solución de la Normal Equation


Representación multivariable




Representación multivariable




Representación multivariable




Representación multivariable



Representación multivariable



Representación multivariable



Regresión multivariable

- Representación gráfica multivariable
- **Codificación 1-hot**
- Normalización de variables
- Descomposición en Valores Singulares
 - Matrices de covarianza y Gramm
 - Autovalores y autovectores
 - Definición de la SVD
 - Obtención de la SVD
 - Aplicación a la solución de la Normal Equation

Regresión multivariable

2. Determinación de *features*

- Estructurados
 - Numéricos
 - Continuos
 - Discretos
 - Categóricos
 - Ordinales
 - Nominales
- Series temporales
- Imagen
- Vídeo
- Audio
- Texto


Regresión multivariable

2. Determinación de *features*

Range of potential AI value impact by data type

% of total value potential

Range



SOURCE: McKinsey Global Institute analysis

Aplicar ML a distintos sectores productivos supone una mejora económica (reducción de costes, etc.) con un determinado valor total (€).

La gráfica representa el porcentaje que en dicha mejora global juega cada tipo de datos.

Regresión multivariable

2. Determinación de *features*

- Numérica
 - Continua
 - Ingresos; promedio de habitantes; superficie; horas invierno; horas verano; edad
 - Discreta
 - Potencia
- Categórica
 - Ordinal (con orden; tiene sentido la media)
 - Estudios
 - Nominal (sin orden; no tiene sentido la media)
 - Tipo de vivienda; estado civil
 - 1-hot encoding

1-hot encoding

Tipo de vivienda	Piso	Adosado	Casa
Piso	1	0	0
Adosado	0	1	0
Casa	0	0	1

Estado civil	Soltero	Casado	Separado	Viudo
Soltero	1	0	0	0
Casado	0	1	0	0
Separado	0	0	1	0
Viudo	0	0	0	1

1-hot encoding

[illegible]

Regresión multivariable

3. Formulación de hipótesis

$$h_w(x) = w_1x_1 + w_2x_2 + \cdots + w_dx_d$$

$$X = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \cdots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(n)} & x_2^{(n)} & \cdots & x_d^{(n)} \end{bmatrix} \quad w = [w_1 \quad w_2 \quad \cdots \quad w_d]$$

Regresión multivariable

4. Elección de la función de coste

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

$$Xw^T - y = \begin{bmatrix} w_1 x_1^{(1)} + w_2 x_2^{(1)} + \cdots + w_d x_d^{(1)} - y^{(1)} \\ w_1 x_1^{(2)} + w_2 x_2^{(2)} + \cdots + w_d x_d^{(2)} - y^{(2)} \\ \vdots \\ w_1 x_1^{(n)} + w_2 x_2^{(n)} + \cdots + w_d x_d^{(n)} - y^{(n)} \end{bmatrix}$$

Regresión multivariable

4. Elección de la función de coste

$$(X - y)^T (Xw^T - y) = \sum_{i=1}^n \left(w_1 x_1^{(i)} + w_2 x_2^{(i)} + \dots + w_d x_d^{(i)} - y^{(1)} \right)^2$$

$$J(h_w(x), y) = \frac{1}{n} (X - y)^T (Xw^T - y)$$

$$J(h_w(x), y) = \frac{1}{n} (X - y)^T (Xw^T - y) + \lambda \|w\|_2^2$$

Regresión multivariable

5. Optimización mediante Normal Equation

$$\nabla J(h_w(x), y) = 0$$

$$\nabla \left[\frac{1}{n} (X - y)^T (Xw^T - y) + \lambda \|w\|_2^2 \right] = 0$$

$$\nabla J(h_w(x), y) = \frac{2}{n} (wX^T X - y^T X) + 2\lambda w = 0$$

$$w^* = y^T X (X^T X + n\lambda I_d)^{-1}$$

Regresión multivariable

5. Optimización mediante Gradient Descent


$$\begin{bmatrix} w_1^{(t+1)} \\ \vdots \\ w_d^{(t+1)} \end{bmatrix} \leftarrow \begin{bmatrix} w_1^{(t)} \\ \vdots \\ w_d^{(t)} \end{bmatrix} - \alpha \begin{bmatrix} \frac{\partial J(h_w(x), y)}{\partial w_1} \\ \vdots \\ \frac{\partial J(h_w(x), y)}{\partial w_d} \end{bmatrix}$$

$$w^{(t+1)T} \leftarrow w^{(t)T} - \alpha \nabla J$$

$$w^{(t+1)T} \leftarrow w^{(t)T} - \alpha \left(\frac{2}{n} (wX^T X - y^T X) + 2\lambda w \right)$$

Regresión multivariable


6. Evaluación del resultado





Regresión multivariable

- Representación gráfica multivariable
- Codificación 1-hot
- **Normalización de variables**
- Descomposición en Valores Singulares
 - Matrices de covarianza y Gramm
 - Autovalores y autovectores
 - Definición de la SVD
 - Obtención de la SVD
 - Aplicación a la solución de la Normal Equation

Normalización de variables



Normalización de variables



Coste escala logarítmica

$$\lambda = 0$$

Normalización de variables

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (w_1 x_1^{(i)} + w_2 x_2^{(i)} - y^{(i)})^2$$

Orden de magnitud: $O_m(\cdot)$

$$O_m(w_1) = \frac{O_m(y)}{O_m(x_1)}; O_m(w_2) = \frac{O_m(y)}{O_m(x_2)}; O_m(J) = (O_m(y))^2$$

10^3 10^0 10^1 10^2 10^6 10^3

Normalización de variables

$$\frac{\partial J}{\partial w_1} = \frac{1}{n} \sum_{i=1}^n \frac{\partial}{\partial w_1} \left(w_1 x_1^{(i)} + w_2 x_2^{(i)} - y^{(i)} \right)^2$$

$$\frac{\partial J}{\partial w_1} = \frac{2}{n} \sum_{i=1}^n x_1^{(i)} \left(w_1 x_1^{(i)} + w_2 x_2^{(i)} - y^{(i)} \right)$$

$$\frac{\partial J}{\partial w_2} = \frac{2}{n} \sum_{i=1}^n x_2^{(i)} \left(w_1 x_1^{(i)} + w_2 x_2^{(i)} - y^{(i)} \right)$$

Normalización de variables

$$\begin{bmatrix} w_1^{(t+1)} \\ w_2^{(t+1)} \end{bmatrix} \leftarrow \begin{bmatrix} w_1^{(t)} \\ w_2^{(t)} \end{bmatrix} - \alpha \begin{bmatrix} \frac{\partial J(h_w(x), y)}{\partial w_1} \\ \frac{\partial J(h_w(x), y)}{\partial w_2} \end{bmatrix}$$

$$\begin{bmatrix} \Delta w_1^{(t)} \\ \Delta w_2^{(t)} \end{bmatrix} = -\alpha \begin{bmatrix} \frac{\partial J(h_w(x), y)}{\partial w_1} \\ \frac{\partial J(h_w(x), y)}{\partial w_2} \end{bmatrix}$$

Normalización de variables

$$O_m \left(\Delta w_1^{(t)} \right) = O_m(\alpha) O_m \left(\frac{\partial J}{\partial w_1} \right) = O_m(\alpha) O_m(x_1) O_m(y)$$

10^2 10^{-1} 10^3 10^{-1} 10^0 10^3

$$O_m \left(\frac{\Delta w_1^{(t)}}{w_1} \right) = \frac{O_m(\alpha) O_m(x_1) O_m(y)}{\frac{O_m(y)}{O_m(x_1)}} = O_m(\alpha) O_m(x_1)^2$$

10^2 10^3 10^{-1} $(10^0)^2$

Normalización de variables

$$O_m \left(\Delta w_2^{(t)} \right) = O_m(\alpha) O_m \left(\frac{\partial J}{\partial w_2} \right) = O_m(\alpha) O_m(x_2) O_m(y)$$

10^4 10^{-1} 10^5 10^{-1} 10^2 10^3

$$O_m \left(\frac{\Delta w_2^{(t)}}{w_2} \right) = \frac{O_m(\alpha) O_m(x_2) O_m(y)}{\frac{O_m(y)}{O_m(x_2)}} = O_m(\alpha) O_m(x_2)^2$$

10^4 10^1 10^{-1} $(10^2)^2$


Normalización de variables

$$\frac{10^{-1} O_m \left(\frac{\Delta w_1^{(t)}}{w_1} \right)}{10^3 O_m \left(\frac{\Delta w_2^{(t)}}{w_2} \right)} = \frac{O_m(\alpha) O_m(x_1)^2}{O_m(\alpha) O_m(x_2)^2}$$


$$\frac{O_m \left(\frac{\Delta w_1^{(t)}}{w_1} \right)}{O_m \left(\frac{\Delta w_2^{(t)}}{w_2} \right)} = \frac{(10^0)^2}{(10^2)^2} = 10^{-4}$$

Normalización de variables

Coste escala logarítmica
 $\lambda = 100$




x




$$\frac{x - \mu}{\sigma}$$

Normalización de variables




$\lambda = 100$

x




$x - \mu$

Coste escala logarítmica




x
 σ




$\frac{x - \mu}{\sigma}$

Normalización de variables




$$\lambda = 0$$

x




$x - \mu$

Coste escala logarítmica




x
 σ




$\frac{x - \mu}{\sigma}$

Normalización de variables



Normalización de variables



Normalización de variables

z-score

Media nula

Varianza unitaria

$$x' = \frac{x - \mu_x}{\sigma_x}$$

Media nula

$$x' = \frac{x - \mu_x}{\max(x) - \min(x)}$$

Reescalado
min-max

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Reescalado
por rango



$$x' = \frac{x - \mu_x}{\text{rango}(x)}$$

Regresión multivariable

- Representación gráfica multivariable
- Codificación 1-hot
- Normalización de variables
- **Descomposición en Valores Singulares**
 - Matrices de covarianza y Gramm
 - Autovalores y autovectores
 - Definición de la SVD
 - Obtención de la SVD
 - Aplicación a la solución de la Normal Equation

Descomposición en Valores Singulares

Justificación



Tiempo de cálculo de la Normal Equation: $O(n \times d^2)$

Objetivo de la SVD: $O(n \times d^2) \rightarrow O(n \times d)$

Descomposición en Valores Singulares

Justificación



Model

33 años



Model

55 años

Descomposición en Valores Singulares

Justificación

100

140




$$d = 140 \times 100 = 14,000$$

$x_{1,1}^{(i)}$	$x_{1,2}^{(i)}$	$\dots$	$x_{1,100}^{(i)}$	$x_{2,1}^{(i)}$	$\dots$	$x_{2,100}^{(i)}$	$\dots$	$x_{140,1}^{(i)}$	$\dots$	$x_{140,100}^{(i)}$
-----------------	-----------------	---------	-------------------	-----------------	---------	-------------------	---------	-------------------	---------	---------------------

Descomposición en Valores Singulares

Justificación



$$d = 140 \times 100 = 14,000$$


Descomposición en Valores Singulares

Justificación

- Interés de estudiar la SVD
 - Primario
 - Permite un cálculo más rápido de la ecuación normal
 - Secundario
 - Introduce conceptos útiles:
 - Matriz de covarianza y Gramm
 - Autovectores y autovalores
 - Base de otras técnicas:
 - Optimización dual
 - Kernels
 - Análisis de componentes principales (PCA)
 - ...

Descomposición en Valores Singulares

Justificación



Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)



$$\underset{(n \times d)}{X} = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \cdots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(n)} & x_2^{(n)} & \cdots & x_d^{(n)} \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{bmatrix}$$

Matriz de diseño ($n \times d$):

- n elementos
- d features

Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)



$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{bmatrix}$$

Diagram illustrating the matrix X structure and its relationship to the scatter plots:

- The matrix X is partitioned into two main sections: a brown section for features (Ingresos and Habitantes) and a blue section for clients (Cliente 1 and Cliente 2).
- An orange arrow points from the brown section of the matrix to the scatter plot of Ingresos vs. Habitantes.
- A blue arrow points from the blue section of the matrix to the scatter plot of Cliente 1 vs. Cliente 2.

Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)

$$\underset{(d \times d)}{C} \equiv X^T X = \underset{(d \times n)}{\begin{bmatrix} x_1^{(1)} & x_1^{(2)} & \cdots & x_1^{(n)} \\ x_2^{(1)} & x_2^{(2)} & \cdots & x_2^{(n)} \\ \vdots & \vdots & \ddots & \vdots \\ x_d^{(1)} & x_d^{(2)} & \cdots & x_d^{(n)} \end{bmatrix}} \underset{(n \times d)}{\begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \cdots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(n)} & x_2^{(n)} & \cdots & x_d^{(n)} \end{bmatrix}}$$

$$c_{ij} = \sum_{k=1}^n x_i^{(k)} x_j^{(k)}$$

~covarianza: similitud entre features

Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)

$$\mu_i \equiv E[x_i] = \frac{1}{n} \sum_{k=1}^n x_i^{(k)}$$

$$\sigma_i^2 = \sigma_{ii} \equiv E[(x_i - \mu_i)^2] = \frac{1}{n} \sum_{k=1}^n \left(x_i^{(k)} - \mu_i \right)^2$$

$$\sigma_{ij} \equiv E[(x_i - \mu_i)(x_j - \mu_j)] = \frac{1}{n} \sum_{k=1}^n \left(x_i^{(k)} - \mu_i \right) \left(x_j^{(k)} - \mu_j \right)$$

Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)

$$\sigma_{ij} = \frac{1}{n} \sum_{k=1}^n \left(x_i^{(k)} x_j^{(k)} - \mu_i x_j^{(k)} - \mu_j x_i^{(k)} + \mu_i \mu_j \right)$$

$$\sigma_{ij} = \left(\frac{1}{n} \sum_{k=1}^n x_i^{(k)} x_j^{(k)} \right) - \mu_i \left(\frac{1}{n} \sum_{k=1}^n x_j^{(k)} \right) - \mu_j \left(\frac{1}{n} \sum_{k=1}^n x_i^{(k)} \right) + \left(\frac{1}{n} \sum_{k=1}^n \mu_i \mu_j \right)$$

Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)

$$\sigma_{ij} = \left(\frac{1}{n} \sum_{k=1}^n x_i^{(k)} x_j^{(k)} \right) - \mu_i \mu_j - \mu_j \mu_i + \mu_i \mu_j$$

$$c_{ij} = \sum_{k=1}^n x_i^{(k)} x_j^{(k)}$$

$$\sigma_{ij} = \frac{1}{n} c_{ij} - \mu_i \mu_j$$

Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)

Matriz de
covarianza

$$K \equiv \begin{matrix} & \begin{matrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1d} \end{matrix} \\ \begin{matrix} \sigma_{21} \\ \vdots \\ \sigma_{d1} \end{matrix} & \begin{bmatrix} \sigma_{22} & \cdots & \sigma_{2d} \\ \vdots & \ddots & \vdots \\ \sigma_{d2} & \cdots & \sigma_{dd} \end{bmatrix} \end{matrix}$$

$(d \times d)$

Vector de
medias

$$\mu \equiv [\mu_1 \quad \mu_2 \quad \cdots \quad \mu_d]$$

$(1 \times d)$

$$C = \frac{1}{n}K - \mu^T \mu$$

$$\text{Si } \mu = 0 \Rightarrow C = \frac{1}{n}K$$

Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)

$$c_{ij} = \sum_{k=1}^n x_i^{(k)} x_j^{(k)}$$

$$c_{ji} = \sum_{k=1}^n x_j^{(k)} x_i^{(k)} = c_{ij} \quad C \text{ es simétrica}$$

$$C = C^T$$

Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)



$$G \equiv XX^T = \begin{matrix} \begin{matrix} (n \times n) \end{matrix} & \begin{matrix} \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \cdots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(n)} & x_2^{(n)} & \cdots & x_d^{(n)} \end{bmatrix} \end{matrix} & \begin{matrix} \begin{matrix} (n \times d) \end{matrix} \end{matrix} \\ \begin{matrix} \begin{bmatrix} x_1^{(1)} & x_1^{(2)} & \cdots & x_1^{(n)} \\ x_2^{(1)} & x_2^{(2)} & \cdots & x_2^{(n)} \\ \vdots & \vdots & \ddots & \vdots \\ x_d^{(1)} & x_d^{(2)} & \cdots & x_d^{(n)} \end{bmatrix} \end{matrix} & \begin{matrix} \begin{matrix} (d \times n) \end{matrix} \end{matrix} \end{matrix}$$

$$g_{ij} = \sum_{k=1}^d x_k^{(i)} x_k^{(j)} = \langle x^{(i)}, x^{(j)} \rangle$$

~ similitud entre elementos de la muestra

Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)



Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)

$$\rho_{ij} = \frac{\sigma_{ij}}{\sqrt{\sigma_{ii}\sigma_{jj}}} = \frac{\frac{1}{n}c_{ij} - \mu_i\mu_j}{\sqrt{\left(\frac{1}{n}c_{ii} - \mu_i^2\right)\left(\frac{1}{n}c_{jj} - \mu_j^2\right)}}$$

Correlación de
features


$$\kappa_{ij} = \frac{c_{ij}}{\sqrt{c_{ii}c_{jj}}}$$

Correlación de
elementos

$$\gamma_{ij} = \frac{g_{ij}}{\sqrt{g_{ii}g_{jj}}}$$

Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)



Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)

$$x^{(i)} = [x_1^{(i)} \quad x_2^{(i)} \quad \dots \quad x_d^{(i)}]; x_j = \begin{bmatrix} x_j^{(1)} \\ x_j^{(2)} \\ \vdots \\ x_j^{(n)} \end{bmatrix}$$

Si las filas i y j son linealmente independientes:

$$x^{(i)} \neq kx^{(j)}$$

Si las columnas i y j son linealmente independientes:

$$x_i \neq kx_j$$

Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)

$$\text{Rn}(X) = r$$

Número de filas linealmente independientes

Número de columnas linealmente independientes

$$\text{Rn}(C) = \text{Rn}(X^T X) = \text{Rn}(X) = r$$

$$\text{Rn}(G) = \text{Rn}(X X^T) = \text{Rn}(X) = r$$

Descomposición en Valores Singulares

1. Matrices de covarianza y de Gram (cont.)

Cliente	Ingresos (k€)	Habitantes	Potencia (kW)	Piso	Adosado	Casa	Superficie (m ²)	Horas invierno	Horas verano	Edad	Soltero	Casado	Separado	Viudo	Estudios	Consumo (MW-h)
i	$x_1^{(i)}$	$x_2^{(i)}$	$x_3^{(i)}$	$x_4^{(i)}$	$x_5^{(i)}$	$x_6^{(i)}$	$x_7^{(i)}$	$x_8^{(i)}$	$x_9^{(i)}$	$x_{10}^{(i)}$	$x_{11}^{(i)}$	$x_{12}^{(i)}$	$x_{13}^{(i)}$	$x_{14}^{(i)}$	$x_{15}^{(i)}$	$y^{(i)}$
1	68.4	2	7.5	0	1	0	136	6.5	4.1	26.3	0	0	1	0	6	9.81
2	38.1	3	4.8	1	0	0	101	17.1	6.5	23.1	0	1	0	0	4	12.4
3	39.2	3	4.6	0	0	1	82	15.6	7.1	75.3	0	0	0	1	4	1.63
4	31.8	4	3.9	1	0	0	72	16.7	7.2	21.7	1	0	0	0	3	8.17
5	58.1	2	5.5	1	0	0	132	13.2	5.2	32.4	0	1	0	0	3	4.87
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

$$\text{Rn}(X) = r = 13$$

Regresión multivariable

- Representación gráfica multivariable
- Codificación 1-hot
- Normalización de variables
- **Descomposición en Valores Singulares**
 - Matrices de covarianza y Gramm
 - Autovalores y autovectores
 - Definición de la SVD
 - Obtención de la SVD
 - Aplicación a la solución de la Normal Equation

Descomposición en Valores Singulares

2. Autovalores y autovectores

$$\underset{(d \times d)}{C} \equiv \underset{(d \times n)}{X^T} \underset{(n \times d)}{X} = \begin{bmatrix} x_{11} & x_{21} & \cdots & x_{d1} \\ x_{12} & x_{22} & \cdots & x_{d2} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1n} & x_{2n} & \cdots & x_{dn} \end{bmatrix} \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{bmatrix}$$

$$C = \begin{bmatrix} c_{11} & c_{12} & \cdots & c_{1d} \\ c_{21} & c_{22} & \cdots & c_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ c_{d1} & c_{d2} & \cdots & c_{dd} \end{bmatrix}$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

$$C v_i = \lambda_i v_i$$

$$\|v_i\| = 1$$

v_i : autovector de C

λ_i : autovalor de C

$$\begin{bmatrix} c_{11} & c_{12} & \cdots & c_{1d} \\ c_{21} & c_{22} & \cdots & c_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ c_{d1} & c_{d2} & \cdots & c_{dd} \end{bmatrix} \begin{bmatrix} v_{1i} \\ v_{2i} \\ \vdots \\ v_{di} \end{bmatrix} = \lambda_i \begin{bmatrix} v_{1i} \\ v_{2i} \\ \vdots \\ v_{di} \end{bmatrix}$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

Matriz de autovectores de C

$$(d \times d) \quad V \equiv [v_1 \quad v_2 \quad \cdots \quad v_d] = \begin{bmatrix} v_{11} & v_{12} & \cdots & v_{1d} \\ v_{21} & v_{22} & \cdots & v_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ v_{d1} & v_{d2} & \cdots & v_{dd} \end{bmatrix}$$

$$(d \times d) \quad \Lambda \equiv \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_d \end{bmatrix}$$

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > \lambda_{r+1} = \cdots = \lambda_d = 0$$

$$C v_i = \lambda_i v_i, \forall i \in [1, d] \Rightarrow \boxed{CV = V\Lambda}$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

$$\Lambda = \begin{matrix} (d \times d) \end{matrix} \begin{bmatrix} \lambda_1 & 0 & \dots & 0 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_r & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 & 0 & \dots & 0 \end{bmatrix} = \begin{matrix} \begin{matrix} (r \times r) \\ ((d-r) \times r) \end{matrix} \begin{bmatrix} \Lambda_r & 0 \\ 0 & 0 \end{bmatrix} \begin{matrix} (r \times (d-r)) \\ ((d-r) \times (d-r)) \end{matrix} \end{matrix}$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

$$Cv_i = \lambda_i v_i$$

$$\|v_i\| = 1$$

$$\begin{cases} c_{11}v_{1i} + c_{12}v_{2i} + \cdots + c_{1d}v_{di} = \lambda_i v_{1i} \\ c_{21}v_{1i} + c_{22}v_{2i} + \cdots + c_{2d}v_{di} = \lambda_i v_{2i} \\ \vdots \\ c_{d1}v_{1i} + c_{d2}v_{2i} + \cdots + c_{dd}v_{di} = \lambda_i v_{di} \\ v_{1i}^2 + v_{2i}^2 + \cdots + v_{di}^2 = 1 \end{cases}$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

$$C v_i = \lambda_i v_i$$

$$(C - \lambda_i I_d) v_i = 0$$

$$v_i = (C - \lambda_i I_d)^{-1} \cdot 0 \Rightarrow \begin{cases} v_i = 0 \\ \nexists (C - \lambda_i I_d)^{-1} \end{cases}$$

$$\nexists (C - \lambda_i I_d)^{-1} \Rightarrow |C - \lambda_i I_d| = 0$$

$$|C - \lambda_i I_d| = (\lambda_i - \lambda_1)(\lambda_i - \lambda_1) \cdots (\lambda_i - \lambda_d) = 0$$

El determinante de una matriz $d \times d$ tiene d raíces

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

Los autovectores son ortonormales (ortogonales y unitarios)

$$C v_i = \lambda_i v_i$$

$$(C v_i)^T = (\lambda_i v_i)^T \Rightarrow v_i^T C^T = \lambda_i v_i^T$$

$$v_i^T C^T = \lambda_i v_i^T$$

$$C^T = C$$

Por simetría de C

$$v_i^T C = \lambda_i v_i^T$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

Los autovectores son ortonormales (cont.)

$$v_i^T C v_j = \lambda_i v_i^T v_j$$

$$v_i^T \lambda_j v_j = \lambda_i v_i^T v_j$$

$$\lambda_j v_i^T v_j = \lambda_i v_i^T v_j$$

$$(\lambda_j - \lambda_i) v_i^T v_j = 0$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

Los autovectores son ortonormales (cont.)

$$\text{Si } \lambda_i \neq \lambda_j \Rightarrow \lambda_j - \lambda_i \neq 0$$

$$v_i^T v_j = [v_{1i} \quad v_{2i} \quad \cdots \quad v_{di}] \begin{bmatrix} v_{1j} \\ v_{2j} \\ \vdots \\ v_{dj} \end{bmatrix} = 0$$

$$\langle v_i, v_j \rangle = v_{1i}v_{1j} + v_{2i}v_{2j} + \cdots + v_{di}v_{dj} = 0$$

$$v_i \perp v_j$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

Los autovectores son ortonormales (cont.)

$$V^T = \begin{bmatrix} v_{11} & v_{21} & \cdots & v_{d1} \\ v_{12} & v_{22} & \cdots & v_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ v_{1d} & v_{2d} & \cdots & v_{dd} \end{bmatrix} = \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_d^T \end{bmatrix}$$

$$V^T V = \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_d^T \end{bmatrix} [v_1 \quad v_2 \quad \cdots \quad v_d]$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

Los autovectores son ortonormales (cont.)

$$V^T V = \begin{bmatrix} v_1^T v_1 & v_1^T v_2 & \cdots & v_1^T v_d \\ v_2^T v_1 & v_2^T v_2 & \cdots & v_2^T v_d \\ \vdots & \vdots & \ddots & \vdots \\ v_d^T v_1 & v_d^T v_2 & \cdots & v_d^T v_d \end{bmatrix} = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} = I_d$$

$$V V^T = (V^T)^T (V)^T = (V V^T)^T = (I_d)^T = I_d$$

$$\left. \begin{array}{l} V^T V = I_d \\ V^{-1} V = I_d \end{array} \right\} \Rightarrow V^{-1} = V^T$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (ejemplo)

$$C = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

$$|C - \lambda_i I_d| = \begin{vmatrix} 2 - \lambda_i & 1 \\ 1 & 2 - \lambda_i \end{vmatrix} = 0$$

$$(2 - \lambda_i)(2 - \lambda_i) - 1 \cdot 1 = 0$$

$$4 + \lambda_i^2 - 4\lambda_i - 1 = 0$$

$$\lambda_i^2 - 4\lambda_i + 3 = 0$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (ejemplo)

$$\lambda_i = \frac{4 \pm \sqrt{4^2 - 4 \cdot 1 \cdot 3}}{2 \cdot 1} = \frac{4 \pm 2}{2} \Rightarrow \begin{cases} \lambda_1 = 3 \\ \lambda_2 = 1 \end{cases}$$

Forma alternativa de cálculo de los autovalores

$$\begin{cases} c_{11}v_{1i} + c_{12}v_{2i} = \lambda_i v_{1i} \\ c_{21}v_{1i} + c_{22}v_{2i} = \lambda_i v_{2i} \end{cases}$$

$$\begin{cases} 2 \cdot v_{1i} + 1 \cdot v_{2i} = \lambda_i v_{1i} \\ 1 \cdot v_{1i} + 2 \cdot v_{2i} = \lambda_i v_{2i} \end{cases}$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (ejemplo)

$$\begin{cases} (2 - \lambda_i)v_{1i} + v_{2i} = 0 \\ v_{1i} + (2 - \lambda_i)v_{2i} = 0 \end{cases} \Rightarrow v_{1i} = -(2 - \lambda_i)v_{2i}$$

$$(2 - \lambda_i)(-(2 - \lambda_i)v_{2i}) + v_{2i} = 0$$

$$-(2 - \lambda_i)^2 v_{2i} + v_{2i} = 0$$

$$[1 - (4 + \lambda_i^2 - 4\lambda_i)]v_{2i} = 0$$

$$\lambda_i^2 - 4\lambda_i + 3 = 0 \Rightarrow \begin{cases} \lambda_1 = 3 \\ \lambda_2 = 1 \end{cases}$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (ejemplo)

Cálculo de los autovectores

$$\begin{cases} c_{11}v_{1i} + c_{12}v_{2i} = \lambda_i v_{1i} \\ v_{1i}^2 + v_{2i}^2 = 1 \end{cases}$$

$$\begin{cases} 2 \cdot v_{1i} + 1 \cdot v_{2i} = \lambda_i v_{1i} \\ v_{1i}^2 + v_{2i}^2 = 1 \end{cases}$$

$$\begin{cases} (2 - \lambda_i)v_{1i} + v_{2i} = 0 \\ v_{1i}^2 + v_{2i}^2 = 1 \end{cases} \Rightarrow v_{1i} = (\lambda_i - 2)v_{2i}$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (ejemplo)

$$(\lambda_i - 2)^2 v_{2i}^2 + v_{2i}^2 = 1$$

$$[(\lambda_i - 2)^2 + 1] v_{2i}^2 = 1$$

$$v_{2i} = \frac{1}{\sqrt{(\lambda_i - 2)^2 + 1}} \Rightarrow \begin{cases} \lambda_1 = 3; v_{21} = \frac{1}{\sqrt{2}} \\ \lambda_2 = 1; v_{22} = \frac{1}{\sqrt{2}} \end{cases}$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (ejemplo)

$$v_{1i} = (\lambda_i - 2)v_{2i}$$

$$\left\{ \begin{array}{l} \lambda_1 = 3; v_{11} = v_{21} = \frac{1}{\sqrt{2}}; v_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ 1 \\ \frac{1}{\sqrt{2}} \end{bmatrix} \\ \lambda_2 = 1; v_{12} = -v_{22} = \frac{-1}{\sqrt{2}}; v_2 = \begin{bmatrix} \frac{-1}{\sqrt{2}} \\ 1 \\ \frac{1}{\sqrt{2}} \end{bmatrix} \end{array} \right.$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (ejemplo)

$$\Lambda = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}$$

$$V = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \\ 1 & 1 \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

$$G \equiv \underset{(n \times n)}{XX^T} = \underset{(n \times d)}{\begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{bmatrix}} \underset{(d \times n)}{\begin{bmatrix} x_{11} & x_{21} & \cdots & x_{d1} \\ x_{12} & x_{22} & \cdots & x_{d2} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1n} & x_{2n} & \cdots & x_{dn} \end{bmatrix}}$$

$$G = \begin{bmatrix} g_{11} & g_{12} & \cdots & g_{1n} \\ g_{21} & g_{22} & \cdots & g_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ g_{n1} & g_{n2} & \cdots & g_{nn} \end{bmatrix}$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

$$Gu_i = \gamma_i u_i$$

$$\|u_i\| = 1; u_i \perp u_j, \forall i, j$$

$$\begin{bmatrix} g_{11} & g_{12} & \cdots & g_{1n} \\ g_{21} & g_{22} & \cdots & g_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ g_{n1} & g_{n2} & \cdots & g_{nn} \end{bmatrix} \begin{bmatrix} u_{1i} \\ u_{2i} \\ \vdots \\ u_{ni} \end{bmatrix} = \gamma_i \begin{bmatrix} u_{1i} \\ u_{2i} \\ \vdots \\ u_{ni} \end{bmatrix}$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

Matriz de autovectores de G

$$(n \times n) \ U \equiv [u_1 \quad u_2 \quad \cdots \quad u_n] = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ u_{21} & u_{22} & \cdots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ u_{n1} & u_{n2} & \cdots & u_{nn} \end{bmatrix}$$

Por ser ortonormales

$$UU^T = I_n$$

$$U^{-1} = U^T$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

$$(n \times n) \ U \equiv [u_1 \quad u_2 \quad \cdots \quad u_n] = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ u_{21} & u_{22} & \cdots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ u_{n1} & u_{n2} & \cdots & u_{nn} \end{bmatrix}$$

$$(n \times n) \ \Gamma \equiv \begin{bmatrix} \gamma_1 & 0 & \cdots & 0 \\ 0 & \gamma_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \gamma_n \end{bmatrix}$$

$$Gu_i = \gamma_i u_i, \forall i \in [1, n] \Rightarrow GU = U\Gamma$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

$$Gu_i = \gamma_i u_i$$

$$XX^T u_i = \gamma_i u_i$$

$$XX^T u_i u_i^T = \gamma_i u_i u_i^T$$

$$XX^T I_n = \gamma_i I_n$$

$$XX^T X = \gamma_i I_n X$$

Descomposición en Valores Singulares

2. Autovalores y autovectores (cont.)

$$XC = \gamma_i X$$

$$X \mathbf{C} \mathbf{v}_i = \gamma_i X \mathbf{v}_i$$

$$X \lambda_i \mathbf{v}_i = \gamma_i X \mathbf{v}_i$$

$$\lambda_i X \mathbf{v}_i = \gamma_i X \mathbf{v}_i$$

$$\gamma_i = \lambda_i$$

Descomposición en Valores Singulares



2. Autovalores y autovectores (cont.)

$$\Gamma_{(n \times n)} = \begin{bmatrix} \lambda_1 & 0 & \dots & 0 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_r & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 & 0 & \dots & 0 \end{bmatrix} = \begin{bmatrix} \Lambda_r & 0 \\ 0 & 0 \end{bmatrix}$$

$(r \times r)$ $(r \times (n-r))$
 $((n-r) \times r)$ $\begin{pmatrix} (n-r) \times (n-r) \\ (n-r) \end{pmatrix}$


Descomposición en Valores Singulares

2. Autovalores y autovectores (interpretación)




Descomposición en Valores Singulares

2. Autovalores y autovectores (interpretación)




Descomposición en Valores Singulares

2. Autovalores y autovectores (interpretación)



Descomposición en Valores Singulares

2. Autovalores y autovectores (interpretación)



Regresión multivariable

- Representación gráfica multivariable
- Codificación 1-hot
- Normalización de variables
- **Descomposición en Valores Singulares**
 - Matrices de covarianza y Gramm
 - Autovalores y autovectores
 - Definición de la SVD
 - Obtención de la SVD
 - Aplicación a la solución de la Normal Equation

Descomposición en Valores Singulares

3. Definición de la SVD

$$\overset{(n+d)}{X} = \overset{(n+d)}{A} \overset{(n+n)}{S} \overset{(d+d)}{B}^T$$

Vector singular
izquierdo

Matriz singular izquierda

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} = [a_1 \quad a_2 \quad \cdots \quad a_n]; a_i \equiv \begin{bmatrix} a_{i1} \\ a_{i2} \\ \vdots \\ a_{in} \end{bmatrix}$$

$$\|a_i\| = 1; a_i \perp a_j, \forall i, j \Rightarrow AA^T = I_n$$

Descomposición en Valores Singulares

3. Definición de la SVD (cont.)

$$X = ASB^T$$

(n+d) *(n+n)* *(d+d)*

Vector
singular
derecho

Matriz singular derecha

$$B = \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1d} \\ b_{21} & b_{22} & \cdots & b_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ b_{d1} & b_{d2} & \cdots & b_{dd} \end{bmatrix} = [b_1 \quad b_2 \quad \cdots \quad b_d]; b_i \equiv \begin{bmatrix} b_{i1} \\ b_{i2} \\ \vdots \\ b_{id} \end{bmatrix}$$

$$\|b_i\| = 1; b_i \perp b_j, \forall i, j \Rightarrow BB^T = I_d$$

Descomposición en Valores Singulares

3. Definición de la SVD (cont.)

$$X = ASB^T$$

$(n+d)$ $(n+n)$ $(d+d)$
 $(n+d)$ $(n+d)$

$$S = \begin{bmatrix} s_1 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & s_2 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & s_r & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & 0 & \cdots & 0 \end{bmatrix} = \begin{bmatrix} S_r & 0 \\ 0 & 0 \end{bmatrix}$$

$(n \times d)$ $(r \times r)$ $((n-r) \times r)$ $(r \times (d-r))$
 s_i : valor singular

Regresión multivariable

- Representación gráfica multivariable
- Codificación 1-hot
- Normalización de variables
- **Descomposición en Valores Singulares**
 - Matrices de covarianza y Gramm
 - Autovalores y autovectores
 - Definición de la SVD
 - **Obtención de la SVD**
 - Aplicación a la solución de la Normal Equation

Descomposición en Valores Singulares

4. Obtención de la SVD

$$X = ASB^T$$

$$X^T X = (ASB^T)^T (ASB^T) = B(AS)^T ASB^T = B \mathbf{S}^T \mathbf{A}^T ASB^T$$

$$\mathbf{X}^T \mathbf{X} = B \mathbf{S} I_d \mathbf{S} B^T = BS^2 B^T$$

$$\mathbf{S}^2 \equiv \text{diag}(s_i^2)$$

$$\mathbf{C} = BS^2 B^T$$

Descomposición en Valores Singulares

4. Obtención de la SVD (cont.)

$$CB = (BS^2B^T)B$$

$$CB = BS^2 \mathbf{B^T B} = BS^2 I_d = BS^2$$

$$CB = BS^2$$

$$CV = V\Lambda$$

$$\begin{cases} B = V \\ S^2 = \Lambda \end{cases}$$

Descomposición en Valores Singulares

4. Obtención de la SVD (cont.)

$$X = ASB^T = A\sqrt{\Lambda}V^T$$

$$XX^T = (A\sqrt{\Lambda}V^T)(A\sqrt{\Lambda}V^T)^T = A\sqrt{\Lambda}\mathbf{V}^T\mathbf{V}\sqrt{\Lambda^T}A^T$$

$$XX^T = A\sqrt{\Lambda}I_n\sqrt{\Lambda}A^T = A\Lambda A^T$$

$$GA = A\Lambda$$

$$GU = U\Lambda$$

$$A = U$$

Descomposición en Valores Singulares

4. Obtención de la SVD (cont.)

$$X = USV^T$$

U : Matriz singular izquierda; autovectores de G

V : Matriz singular derecha; autovectores de C

$S = \sqrt{\Lambda}$: Matriz de valores singulares;

Λ : autovectores de C y G

$$S = \sqrt{\Lambda} = \text{diag}(\sqrt{\lambda_i})$$

Regresión multivariable

- Representación gráfica multivariable
- Codificación 1-hot
- Normalización de variables
- **Descomposición en Valores Singulares**
 - Matrices de covarianza y Gramm
 - Autovalores y autovectores
 - Definición de la SVD
 - Obtención de la SVD
 - Aplicación a la solución de la Normal Equation

Descomposición en Valores Singulares

5. Aplicación a la solución de la Normal Equation

$$J = \frac{1}{n} (Xw^T - y)^T (Xw^T - y) + \lambda \|w\|_2^2$$

$$J = \frac{1}{n} \|Xw^T - y\|_2^2 + \lambda \|w\|_2^2$$

Para $\lambda = 0$

$$J = \frac{1}{n} \|Xw^T - y\|_2^2$$

$$w^* = \arg \min_w \frac{1}{n} \|Xw^T - y\|_2^2$$

Normal equation $w^* = \arg \min_w \|Xw^T - y\|_2^2$

Descomposición en Valores Singulares

5. Aplicación a la solución de la Normal Equation (cont.)

$$w^* = \arg \min_w \|Xw^T - y\|_2^2$$

$$X = XI_d = X(VV^T)$$

$$w^* = \arg \min_w \|XVV^T w^T - y\|_2^2$$

Para cualquier vector a de dimensión $(n \times 1)$

$$\|U^T a\|_2^2 = (U^T a)^T (U^T a) = a^T U U^T a = a^T I_n a$$

$$\|U^T a\|_2^2 = a^T I_n a = a^T a = \|a\|_2^2$$

Descomposición en Valores Singulares

5. Aplicación a la solución de la Normal Equation (cont.)

$$w^* = \arg \min_w \|XVV^T w^T - y\|_2^2$$

$$w^* = \arg \min_w \|U^T (XVV^T w^T - y)\|_2^2$$

$$X = USV^T$$

$$w^* = \arg \min_w \|U^T (USV^T VV^T w^T - y)\|_2^2$$

$$w^* = \arg \min_w \|U^T USV^T VV^T w^T - U^T y\|_2^2$$

Descomposición en Valores Singulares

5. Aplicación a la solución de la Normal Equation (cont.)

$$w^* = \arg \min_w \|I_n S I_d V^T w^T - U^T y\|_2^2$$

$$w^* = \arg \min_w \|S V^T w^T - U^T y\|_2^2$$

$$(d \times 1) \quad z \equiv V^T w^T = \begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_d \end{bmatrix}$$

$(d+1)$ $(d+1)$

$$z^* = \arg \min_z \|S z - U^T y\|_2^2$$

Descomposición en Valores Singulares

5. Aplicación a la solución de la Normal Equation (cont.)

$$\begin{array}{c} (n \times 1) \\ SZ = \end{array} \begin{array}{c} (n \times d) \end{array} \begin{bmatrix} s_1 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & s_2 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & s_r & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & 0 & \cdots & 0 \end{bmatrix} \begin{array}{c} (d \times 1) \\ \begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_d \end{bmatrix} \end{array} = \begin{bmatrix} s_1 z_1 \\ s_2 z_2 \\ \vdots \\ s_r z_r \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

Descomposición en Valores Singulares

5. Aplicación a la solución de la Normal Equation (cont.)

$$\begin{matrix} & & (n \times n) & & (n \times 1) \\ U^T y = & \begin{bmatrix} u_{11} & u_{21} & \cdots & u_{n1} \\ u_{12} & u_{22} & \cdots & u_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ u_{1n} & u_{2n} & \cdots & u_{nn} \end{bmatrix} & \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} & = & \begin{bmatrix} \sum_{i=1}^n u_{i1} y_i \\ \sum_{i=1}^n u_{i2} y_i \\ \vdots \\ \sum_{i=1}^n u_{in} y_i \end{bmatrix} & = & \begin{bmatrix} u_1^T y \\ u_2^T y \\ \vdots \\ u_n^T y \end{bmatrix} \\ (n \times 1) & & & & & & & & \end{matrix}$$

Descomposición en Valores Singulares

5. Aplicación a la solución de la Normal Equation (cont.)

$$SZ - U^T y = \begin{bmatrix} s_1 z_1 \\ s_2 z_2 \\ \vdots \\ s_r z_r \\ 0 \\ \vdots \\ 0 \end{bmatrix} - \begin{bmatrix} u_1^T y \\ u_2^T y \\ \vdots \\ u_n^T y \end{bmatrix} = \begin{bmatrix} s_1 z_1 - u_1^T y \\ s_2 z_2 - u_2^T y \\ \vdots \\ s_r z_r - u_r^T y \\ -u_{r+1}^T y \\ \vdots \\ -u_d^T y \end{bmatrix}$$

$$\|SZ - U^T y\|_2^2 = \sum_{i=1}^r (s_i z_i - u_i^T y)^2 + \sum_{i=r+1}^d (u_i^T y)^2$$

Descomposición en Valores Singulares

5. Aplicación a la solución de la Normal Equation (cont.)

$$z^* = \arg \min_z \|Sz - U^T y\|_2^2$$

$$z^* = \arg \min_z \left(\sum_{i=1}^r (s_i z_i - u_i^T y)^2 + \sum_{i=r+1}^d (u_i^T y)^2 \right)$$

$$\begin{cases} z_i^* = \frac{u_i^T y}{s_i}, \forall 1 \leq i \leq r \\ z_i^* = \text{arbitrario}, \forall i > r \end{cases}$$

Descomposición en Valores Singulares

5. Aplicación a la solución de la Normal Equation (cont.)

$$z \equiv V^T w^T$$



$$w^T = (V^T)^{-1} z = V z \quad V^{-1} = V^T$$

$$w^T = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_d \end{bmatrix} = \begin{bmatrix} v_{11} & v_{12} & \cdots & v_{1d} \\ v_{21} & v_{22} & \cdots & v_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ v_{d1} & v_{d2} & \cdots & v_{dd} \end{bmatrix} \begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_d \end{bmatrix}$$

$$w_i^* = \sum_{j=1}^d v_{ij} z_j^* = \sum_{j=1}^d v_{ij} \frac{u_j^T y}{s_j}$$

Descomposición en Valores Singulares

5. Aplicación a la solución de la Normal Equation (cont.)



Tiempo de cálculo de la NE: $O(n \times d^2)$

Tiempo de cálculo de la SVD: $O(n \times d)$

Descomposición en Valores Singulares

Justificación

- Interés de estudiar la SVD
 - Primario
 - Permite un cálculo más rápido de la ecuación normal
 - Secundario
 - Introduce conceptos útiles:
 - Matriz de covarianza y Gramm
 - Autovectores y autovalores
 - Base de otras técnicas:
 - Optimización dual
 - Kernels
 - Análisis de componentes principales (PCA)
 - ...