

Fundamentos del aprendizaje automático

(Machine learning)

Joaquín Luque

Contenido

1. Introducción
2. Regresión
 - a) Regresión univariable
 - b) Regresión multivariable
3. Clasificación
 - a) **Regresión logística**
 - b) Máquinas de vectores soporte (SVM)
 - Forma dual de la optimización (regresión y SVM)
 - c) Funciones Kernel
 - d) Clasificación multiclase
4. Segmentación
5. Reducción de dimensionalidad
6. Deep learning (introducción)

Clasificación

Enfoques

- Extensión de la regresión
 - Regresión logística (logistic regression)
- Maximización de la separación entre clases
 - Máquinas de Vectores Soporte (Support Vector Machines)
- Minimización de la distancia a clases
 - K-medias (K-means)
 - K-vecinos más próximos (K-Nearest Neighbours)
- Modelos arbóreos (tree-like)
 - Árbol de decisión (decision tree)
 - Bosques aleatorios (random forest)

Regresión logística

- Hipótesis
 - Función signo
 - Función logística
- Función de coste
 - 0-1
 - Logística
- Evaluación
 - Matriz de confusión y métricas derivadas
 - Análisis ROC
 - Curva de aprendizaje

Clasificación

Ejemplo en el sector eléctrico

- La empresa está impulsando la transición al vehículo eléctrico. Para ello tiene una política de marketing que se dirige captar nuevos usuarios entre sus clientes.
 - Dado el coste de dicha política, la acción comercial no se dirige a todos los clientes de manera universal, sino sólo a aquéllos que son potenciales compradores.
 - ¿El nuevo cliente es uno de ellos?
- Para dilucidarlo se plantea distintas cuestiones previas


Clasificación

Ejemplo en el sector eléctrico

- La primera cuestión es saber si el cliente tiene o no garaje propio. Ese dato no consta en sus bases de datos, por lo que realiza un muestreo entre sus clientes.
- De este muestreo obtiene dos datos
 1. Superficie de la vivienda (m²)
 2. Tiene garaje (Si/No)
- Con esa información quiere inferir si un determinado cliente tiene garaje en función del tamaño de su vivienda (dato que sí consta en sus bases de datos)


Regresión logística

3. Formulación de hipótesis



Regresión logística

3. Formulación de hipótesis




w_0, w_1
calculados
por regresión
lineal

$$h_w(x) = w_0 + w_1x$$

Regresión logística

3. Formulación de hipótesis




w_0, w_1
calculados
por regresión
lineal

$$h_w(x) = w_0 + w_1x$$

Regresión logística

3. Formulación de hipótesis



$$w_0 = -100$$

$$h_w(x) = \frac{1 + \text{sign}(x + w_0)}{2}$$

Regresión logística

5. Optimización del coste


$$h_w(x) = \frac{1 + \text{sign}(x + w_0)}{2}$$

$$\frac{d}{dw} J(h_w(x), y) = 0$$

La función $\text{sign}(x)$ no es derivable (en el origen)

Regresión logística

3. Formulación de hipótesis



$$\frac{w_0}{w_1} = -100$$

Función
logística

$$h_w(x) = \frac{1}{1 + e^{-z}}$$

$$z \equiv w_0 + w_1 x$$

Regresión logística

3. Formulación de hipótesis

Cuota (odds) $o \equiv \frac{p}{1-p}$ p : probabilidad de que tenga garaje

Log-odds $Ln(o) = z = w_0 + w_1x$ Unida de medida: logit (logistic unit)


Puede usarse otra función no lineal $z = f(x)$ (p.e. polinómica)

$$o = e^z = e^{(w_0 + w_1x)}$$

$$p = \frac{o}{1+o} = \frac{1}{1+o^{-1}} = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-(w_0+w_1x)}}$$

Regresión logística

3. Formulación de hipótesis



$$\frac{w_0}{w_1} = -100$$

Otras
sigmoides

$$h_w(x) = \frac{1}{2} + \frac{\text{atan}(z)}{\pi}$$

$$z \equiv w_0 + w_1 x$$


Regresión logística

- Hipótesis
 - Función signo
 - Función logística
- **Función de coste**
 - 0-1
 - Logística
- Evaluación
 - Matriz de confusión y métricas derivadas
 - Análisis ROC
 - Curva de aprendizaje

Regresión logística

4. Elección de la función de coste

Hipótesis:
Función
logística



$$w_1 = 1$$


Coste
cuadrático
No convexo

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

Regresión logística

4. Elección de la función de coste

Hipótesis:
Función
logística



$w_0 = -100$

Coste
cuadrático
No convexo

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

Regresión logística

4. Elección de la función de coste

Función de coste 0-1

$$\hat{y} = \begin{cases} 1, & h_w(x) \geq t_h \\ 0, & h_w(x) < t_h \end{cases} \quad t_h = 0.5$$



$$I(u) \equiv \begin{cases} 1, & u = \textit{True} \\ 0, & u = \textit{False} \end{cases}$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n I(\hat{y}^{(i)} \neq y^{(i)}) = ACC$$

$$ACC \equiv \frac{\text{\#aciertos}}{n}$$

Regresión logística

4. Elección de la función de coste



Coste 0-1

No convexo

Regresión logística

4. Elección de la función de coste

Función de coste logística (cros-entropía)


$$e(h_w(x), y) = |h_w(x) - y|$$

$$L(h_w(x), y) = -Ln(1 - e)$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n L(h_w(x^{(i)}), y^{(i)})$$

Regresión logística

4. Elección de la función de coste



$$L(h_w(x), y) = -\ln(1 - e)$$

Regresión logística

4. Elección de la función de coste

Función de coste logística (cros-entropía)

$$e = |h_w(x) - y| = \begin{cases} 1 - h_w(x), & \forall y = 1 \\ h_w(x), & \forall y = 0 \end{cases}$$


$$L(h_w(x), y) = -\text{Ln}(1 - e) = \begin{cases} -\text{Ln}(h_w(x)), & \forall y = 1 \\ -\text{Ln}(1 - h_w(x)), & \forall y = 0 \end{cases}$$

$$L(h_w(x), y) = -y\text{Ln}(h_w(x)) - (1 - y)\text{Ln}(1 - h_w(x))$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n L(h_w(x^{(i)}), y^{(i)})$$

Regresión logística



4. Elección de la función de coste



$$L(h_w(x), y) = -y \ln(h_w(x)) - (1 - y) \ln(1 - h_w(x))$$

Regresión logística

4. Elección de la función de coste




Función de coste logística (cros-entropía)

CONVEXA

Regresión logística

4. Elección de la función de coste



Función de coste logística (cros-entropía)

CONVEXA

Regresión logística

4. Elección de la función de coste

Función de coste logística con regularización

$$L(h_w(x), y) = -y \ln(h_w(x)) - (1 - y) \ln(1 - h_w(x))$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n L(h_w(x^{(i)}), y^{(i)}) + \lambda \|w\|_2^2$$

Regresión logística

5. Optimización del coste

Normal Equation

$$w^* = \arg \min_w J(h_w(x), y)$$

$$\nabla_w J(h_w(x), y) = 0$$

$$\nabla_w \frac{1}{n} \sum_{i=1}^n \text{Loss}(h_w(x^{(i)}), y^{(i)}) = 0$$

$$\sum_{i=1}^n \nabla_w \text{Loss}(h_w(x^{(i)}), y^{(i)}) = 0$$

Regresión logística

5. Optimización del coste

Normal Equation

$$\sum_{i=1}^n \nabla_w - \text{Ln} \left(1 + (2y^{(i)} - 1)(h_w(x^{(i)}) - y^{(i)}) \right) = 0$$

$$\sum_{i=1}^n \frac{(2y^{(i)} - 1)(\nabla_w h_w(x^{(i)}) - y^{(i)})}{1 + (2y^{(i)} - 1)(h_w(x^{(i)}) - y^{(i)})} = 0$$

$$h_w(x) = \frac{1}{1 + e^{-(w_0 + w_1 x)}}$$

Regresión logística

5. Optimización del coste

Normal Equation

$$\nabla_w h_w = \begin{bmatrix} \frac{\partial h_w}{\partial w_0} & \frac{\partial h_w}{\partial w_1} \end{bmatrix}$$

$$\frac{\partial h_w}{\partial w_0} = \frac{-1}{(1 + e^{-(w_0 + w_1 x)})^2} e^{-(w_0 + w_1 x)} (-1)$$

$$\frac{\partial h_w}{\partial w_1} = \frac{-1}{(1 + e^{-(w_0 + w_1 x)})^2} e^{-(w_0 + w_1 x)} (-x)$$

Regresión logística

5. Optimización del coste

Normal Equation

$$\begin{cases} \sum_{i=1}^n \frac{(2y^{(i)} - 1) \left(\frac{\partial h_w(x^{(i)})}{\partial w_0} - y^{(i)} \right)}{1 + (2y^{(i)} - 1)(h_w(x^{(i)}) - y^{(i)})} = 0 \\ \sum_{i=1}^n \frac{(2y^{(i)} - 1) \left(\frac{\partial h_w(x^{(i)})}{\partial w_1} - y^{(i)} \right)}{1 + (2y^{(i)} - 1)(h_w(x^{(i)}) - y^{(i)})} = 0 \end{cases}$$

Regresión logística

5. Optimización del coste

Normal Equation

$$\left\{ \begin{array}{l} \sum_{i=1}^n \frac{(2y^{(i)} - 1) \left(\frac{e^{-(w_0 + w_1 x^{(i)})}}{(1 + e^{-(w_0 + w_1 x^{(i)})})^2} - y^{(i)} \right)}{1 + (2y^{(i)} - 1) \left(\frac{1}{1 + e^{-(w_0 + w_1 x^{(i)})}} - y^{(i)} \right)} = 0 \\ \sum_{i=1}^n \frac{(2y^{(i)} - 1) \left(\frac{x^{(i)} e^{-(w_0 + w_1 x^{(i)})}}{(1 + e^{-(w_0 + w_1 x^{(i)})})^2} - y^{(i)} \right)}{1 + (2y^{(i)} - 1) \left(\frac{1}{1 + e^{-(w_0 + w_1 x^{(i)})}} - y^{(i)} \right)} = 0 \end{array} \right.$$

Regresión logística

5. Optimización del coste


Normal Equation

$$\left\{ \begin{array}{l} \sum_{i=1}^n \frac{(2y^{(i)} - 1) \left(\frac{e^{-(w_0 + w_1 x^{(i)})}}{(1 + e^{-(w_0 + w_1 x^{(i)})})} - y^{(i)} \right)}{1 + (2y^{(i)} - 1) \left(\frac{e^{-(w_0 + w_1 x^{(i)})}}{(1 + e^{-(w_0 + w_1 x^{(i)})})} - y^{(i)} \right)} = 0 \\ \sum_{i=1}^n \frac{(2y^{(i)} - 1) \left(\frac{e^{-(w_0 + w_1 x^{(i)})}}{(1 + e^{-(w_0 + w_1 x^{(i)})})^2} - y^{(i)} \right)}{1 + (2y^{(i)} - 1) \left(\frac{1}{1 + e^{-(w_0 + w_1 x^{(i)})}} - y^{(i)} \right)} = 0 \end{array} \right.$$

Sin solución analítica

Regresión logística

5. Optimización del coste



$$w_0^* = -15.2$$
$$w_1^* = 0.155$$

Gradient Descent

Regresión logística

- Hipótesis
 - Función signo
 - Función logística
- Función de coste
 - 0-1
 - Logística
- Evaluación
 - Matriz de confusión y métricas derivadas
 - Análisis ROC
 - Curva de aprendizaje

Regresión logística

6. Evaluación del resultado

$$n_{train} = 10$$

$$t_h = 0.5$$

Cliente	Superficie (m ²) $x^{(i)}$	Garaje $y^{(i)}$	Predicción $h^{(i)}$	Garaje $\hat{y}^{(i)}$
11	139	S	0.998	S
12	54	N	0.001	N
13	96	S	0.428	N
14	95	N	0.372	N
15	132	S	0.994	S
⋮	⋮	⋮	⋮	⋮

$$h_w(x) = \frac{1}{1 + e^{-(w_0 + w_1 x)}}$$

$$\hat{y} = \begin{cases} 0, & \forall h_w(x) < t_h \\ 1, & \forall h_w(x) \geq t_h \end{cases}$$

Regresión logística

6. Evaluación del resultado

Matriz de confusión

		Clase calculada		Elementos
		P	N	
Clase real	P	TP	FN	n_P
	N	FP	TN	n_N
Estimaciones		e_P	e_N	n

		Clase calculada		Elementos
		P	N	
Clase real	P	545	46	591
	N	77	322	399
Estimaciones		622	368	990


Regresión logística

6. Evaluación del resultado

Nombre	Acrónimo	Expresión	Valor
Sensitivity	SNS	$\frac{TP}{TP + FN}$	0.9222
Specificity	SPC	$\frac{TN}{TN + FP}$	0.8070
Precision	PRC	$\frac{TP}{TP + FP}$	0.8762
Negative Predictive Value	NPV	$\frac{TN}{TN + FN}$	0.8750
Accuracy	ACC	$\frac{TP + TN}{TP + TN + FP + FN}$	0.8758
F ₁ Score	F ₁	$2 \frac{SNS \cdot PRC}{SNS + PRC}$	0.8986
Geometric Mean	GM	$\sqrt{SNS \cdot SPC}$	0.8627



Regresión logística

6. Evaluación del resultado




Regresión logística

6. Evaluación del resultado




Regresión logística

6. Evaluación del resultado



Regresión logística


6. Evaluación del resultado



Receiver operating characteristic (ROC)

Regresión logística

6. Evaluación del resultado




Area Under Curve (AUC)

$$AUC = 0.9519$$

Regresión logística


6. Evaluación del resultado



Elección del umbral de decisión
Datos de validación

Regresión logística


6. Evaluación del resultado



Elección del umbral de decisión
Datos de validación

Regresión logística

6. Evaluación del resultado



Curva de aprendizaje

Contenido


1. Introducción
2. Regresión
 - a) Regresión univariable
 - b) Regresión multivariable
3. Clasificación
 - a) Regresión logística
 - b) Máquinas de vectores soporte (SVM)**
 - Forma dual de la optimización (regresión y SVM)
 - c) Funciones Kernel
 - d) Clasificación multiclase
4. Segmentación
5. Reducción de dimensionalidad
6. Deep learning (introducción)

Maquina de vectores soporte (SVM)

- Frontera de decisión
 - Margen
- Función de coste
 - Función bisagra (hinge loss)
- Clasificación multivariable

Maquina de vectores soporte (SVM)


3. Formulación de hipótesis



Hipótesis + Umbral de decisión = Frontera de decisión

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis



Hipótesis + Umbral de decisión = Frontera de decisión

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis

Frontera

$$h_w(x_b) = \frac{1}{1 + e^{-z_b}} = t_h$$

$$e^{-z_b} = \frac{1}{t_h} - 1$$

$$z_b = -Ln \left(\frac{1}{t_h} - 1 \right)$$

$$z_b = wx_b + b$$

Puede usarse otra función no lineal $z_b = f(x_b)$ (p.e. polinómica)

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis

Frontera

$$z_b = wx_b + b = -Ln\left(\frac{1}{t_h} - 1\right)$$

$$x_b = \frac{-b - Ln\left(\frac{1}{t_h} - 1\right)}{w}$$

$$t_h = \frac{1}{2} \Rightarrow z_b = 0$$

$$x_b = \frac{-b}{w}$$

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis

Frontera

Hipótesis: formulación original

$$\begin{cases} y = 1, \forall h_w(x) \geq t_h \\ y = 0, \forall h_w(x) < t_h \end{cases}$$

$$h_w(x) = \frac{1}{1 + e^{-(wx+b)}}$$

Hipótesis: formulación alternativa

$$\begin{cases} y = 1, \forall x \geq x_b \\ y = 0, \forall x < x_b \end{cases}$$


$$x_b = \frac{-b}{w}$$

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis

Margen

$$m = \frac{1}{w}$$



$$z_b = 0$$

$$z_p = 1$$

$$z_n = -1$$

$$z_p = w(x_b + m) + b = w\left(\frac{-b}{w} + m\right) + b = w m = w \frac{1}{w} = 1$$

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis

Frontera dura (Hard Margin)

Hipótesis: formulación original

$$\begin{cases} y = 1, \forall h_w(x) \geq t_h \\ y = 0, \forall h_w(x) < t_h \end{cases}$$

$$h_w(x) = \frac{1}{1 + e^{-(wx+b)}}$$

Hipótesis: formulación alternativa

$$\begin{cases} y = 1, \forall x \geq x_b + m \\ y = 0, \forall x \leq x_b - m \end{cases}$$

$$x_b = \frac{-b}{w}; m = \frac{1}{w}$$

Maquina de vectores soporte (SVM)

5. Optimización del coste

Frontera dura (Hard Margin)

Optimización: formulación original

$$w^* = \arg \min_w J(h_w(x), y)$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n L(h_w(x^{(i)}), y^{(i)})$$

$$L(h_w(x), y) = -y \ln(h_w(x)) - (1 - y) \ln(1 - h_w(x))$$

Optimización: formulación alternativa

$$\arg \max_{w,b} m : \begin{cases} x \geq x_b + m, \forall y = 1 \\ x \leq x_b - m, \forall y = 0 \end{cases}$$

Maquina de vectores soporte (SVM)

5. Optimización del coste

Frontera dura (Hard Margin)

Optimización : formulación alternativa


$$\arg \max_{w,b} m : \begin{cases} x \geq x_b + m, \forall y = 1 \\ x \leq x_b - m, \forall y = 0 \end{cases}$$

$$x_b = \frac{-b}{w}; m = \frac{1}{w}$$

$$\arg \max_{w,b} \frac{1}{w} : \begin{cases} x \geq \frac{-b + 1}{w}, \forall y = 1 \\ x \leq \frac{-b - 1}{w}, \forall y = 0 \end{cases}$$

Maquina de vectores soporte (SVM)


5. Optimización del coste



Margen máximo

Maquina de vectores soporte (SVM)


3. Formulación de hipótesis Frontera suave (soft margin)



$$h_w(x) = \begin{cases} y = 1, \forall x \geq x_b \\ y = 0, \forall x < x_b \end{cases}$$

Maquina de vectores soporte (SVM)

4. Elección de la función de coste



$$z_b = 0$$

$$z_p = 1$$

$$z_n = -1$$

Maquina de vectores soporte (SVM)

- Frontera de decisión
 - Margen
- **Función de coste**
 - Función bisagra (hinge loss)
- Clasificación multivariable

Maquina de vectores soporte (SVM)

4. Elección de la función de coste

Función de coste logística (cros-entropía)


$$L(h_w(x), y) = -y \ln(h_w(x)) - (1 - y) \ln(1 - h_w(x))$$

$$L(h_w(x), y) = -y \ln\left(\frac{1}{1 + e^{-z}}\right) - (1 - y) \ln\left(1 - \frac{1}{1 + e^{-z}}\right)$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n L(h_w(x^{(i)}), y^{(i)})$$

Maquina de vectores soporte (SVM)


4. Elección de la función de coste



$$L(h_w(x), y) = -y \ln \left(\frac{1}{1 + e^{-z}} \right) - (1 - y) \ln \left(1 - \frac{1}{1 + e^{-z}} \right)$$

Maquina de vectores soporte (SVM)

4. Elección de la función de coste



$$y \in \{0,1\}$$
$$\mathcal{Y} \in \{-1,1\}$$



$$\mathcal{Y} \equiv 2y - 1$$

Función de coste bisagra (hinge loss)

$$L(h_w(x), y) = \max(0, 1 - yz)$$

Maquina de vectores soporte (SVM)

4. Elección de la función de coste




Función de coste bisagra (hinge loss)

CONVEXA

Maquina de vectores soporte (SVM)

4. Elección de la función de coste



Función de coste bisagra (hinge loss)

CONVEXA

Maquina de vectores soporte (SVM)

4. Elección de la función de coste


Función de coste bisagra (hinge loss) con regularización

$$L(h_w(x), y) = \max(0, 1 - yz)$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n L(h_w(x^{(i)}), y^{(i)}) + \lambda \|w\|_2^2$$

Maquina de vectores soporte (SVM)

5. Optimización del coste



$$b^* = -16.7$$
$$w^* = 0.160$$

$$x_b^* = 104.22$$
$$m^* = 6.24$$

Gradient Descent

Maquina de vectores soporte (SVM)

6. Evaluación del resultado

$$n_{train} = 10$$

Cliente	Superficie (m ²) $x^{(i)}$	Garaje $y^{(i)}$	Garaje $\hat{y}^{(i)}$
11	139	S	S
12	54	N	N
13	96	S	N
14	95	N	N
15	132	S	S
⋮	⋮	⋮	⋮

$$\hat{y} = \begin{cases} 1, \forall x \geq x_b^* \\ 0, \forall x < x_b^* \end{cases}$$

$$x_b^* = 104.22$$

Maquina de vectores soporte (SVM)

6. Evaluación del resultado

Matriz de confusión

$$n_{train} = 10$$

		Clase calculada		Elementos
		<i>P</i>	<i>N</i>	
Clase real	<i>P</i>	477	114	591
	<i>N</i>	32	367	399
Estimaciones		509	481	990


Maquina de vectores soporte (SVM)

6. Evaluación del resultado

Nombre	Acrónimo	Expresión	Valor
Sensitivity	SNS	$\frac{TP}{TP + FN}$	0.8071
Specificity	SPC	$\frac{TN}{TN + FP}$	0.9198
Precision	PRC	$\frac{TP}{TP + FP}$	0.9371
Negative Predictive Value	NPV	$\frac{TN}{TN + FN}$	0.7629
Accuracy	ACC	$\frac{TP + TN}{TP + TN + FP + FN}$	0.8525
F ₁ Score	F ₁	$2 \frac{SNS \cdot PRC}{SNS + PRC}$	0.8672
Geometric Mean	GM	$\sqrt{SNS \cdot SPC}$	0.8616

Maquina de vectores soporte (SVM)

6. Evaluación del resultado



Curva de aprendizaje

Maquina de vectores soporte (SVM)

- Frontera de decisión
 - Margen
- Función de coste
 - Función bisagra (hinge loss)
- Clasificación multivariable

Clasificación multivariable

Ejemplo en el sector eléctrico

- En el programa de impulso para la transición al vehículo eléctrico, la segunda cuestión es saber si el cliente tiene o no vehículo (no eléctrico). Ese dato no consta en sus bases de datos, por lo que realiza un muestreo entre sus clientes.
- De este muestreo obtiene 3 datos
 1. Ingresos anuales (€)
 2. Edad (años)
 3. Tiene vehículo (Si/No)
- Con esa información quiere inferir si un determinado cliente tiene vehículo, en función de sus ingresos y su edad (datos que sí constan en sus bases de datos)

Clasificación multivariable

2. Determinación de *features*

Cliente	Ingresos (m€) $x_1^{(i)}$	Edad (años) $x_2^{(i)}$	Vehículo $y^{(i)}$
1	97.17	26.6	S
2	44.67	32.3	N
3	46.64	26.7	N
4	33.84	23.7	N
5	79.35	27.0	S
⋮	⋮	⋮	⋮


x_1 y x_2 tienen un rango similar

No necesitan normalización

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis

$$w \equiv [w_1 \quad w_2]$$
$$x \equiv [x_1 \quad x_2]$$



$$z \equiv w_1 x_1 + w_2 x_2 + b = xw^T + b$$


Puede usarse otra función no lineal $z = f(x)$ (p.e. polinómica)

Función logística

$$h_w(x) = \frac{1}{1 + e^{-z}}$$

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis



$$h_w(x_b) = \frac{1}{1 + e^{-z_b}} = t_h$$

Frontera

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis

Frontera

$$h_w(x_b) = \frac{1}{1 + e^{-z_b}} = t_h$$

Frontera lineal

$$e^{-z_b} = e^{-(x_b w^T + b)} = \frac{1}{t_h} - 1$$

Para 2 features ($d = 2$)

$$z_b = x_b w^T + b = w_1 x_{1b} + w_2 x_{2b} + b = -\ln \left(\frac{1}{t_h} - 1 \right)$$

Recta frontera

$$x_{2b} = \frac{-w_1}{w_2} x_{1b} + \frac{-b - \ln \left(\frac{1}{t_h} - 1 \right)}{w_2}$$

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis

Frontera lineal para d features (caso general)

$$z_b = x_b w^T + b = -Ln \left(\frac{1}{t_h} - 1 \right)$$

$$x_b w^T = -b - Ln \left(\frac{1}{t_h} - 1 \right)$$

$$t_h = \frac{1}{2} \Rightarrow z_b = 0 \quad x_b w^T = -b$$

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis

Margen para 2 features ($d = 2$)

2 rectas paralelas
(misma pendiente)

$$\begin{cases} r_1: y = ax + c_1 \\ r_2: y = ax + c_2 \end{cases}$$

Distancia entre las
2 rectas paralelas

$$d(r_1, r_2) = \frac{|c_1 - c_2|}{\sqrt{1 + a^2}}$$

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis

Margen para 2 features ($d = 2$)

$$z_p = x_p w^T + b = w_1 x_{1p} + w_2 x_{2p} + b = 1$$

Margen
superior

$$r_s: x_{2p} = \frac{-w_1}{w_2} x_{1p} + \frac{1 - b}{w_2}$$

Frontera lineal

$$r_f: x_{2b} = \frac{-w_1}{w_2} x_{1b} + \frac{-b}{w_2}$$

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis

Margen para 2 features ($d = 2$)

$$m = d(r_s, r_f) = \frac{|c_1 - c_2|}{\sqrt{1 + a^2}} = \frac{\left| \frac{1-b}{w_2} - \frac{-b}{w_2} \right|}{\sqrt{1 + \left(\frac{-w_1}{w_2} \right)^2}} = \frac{1}{w_2 \sqrt{1 + \frac{w_1^2}{w_2^2}}}$$

$$m = \frac{1}{\sqrt{w_1^2 + w_2^2}}$$

Margen para frontera
lineal con d features

$$m = \frac{1}{\|w\|}$$

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis

Frontera lineal con margen

Hipótesis: formulación original


$$\begin{cases} y = 1, \forall h_w(x) \geq t_h \\ y = 0, \forall h_w(x) < t_h \end{cases} \quad h_w(x) = \frac{1}{1 + e^{-(xw^T + b)}}$$

Hipótesis: formulación alternativa

$$\begin{cases} y = 1, \forall xw^T + b \geq 0 \\ y = 0, \forall xw^T + b < 0 \end{cases}$$

Maquina de vectores soporte (SVM)

3. Formulación de hipótesis



Maquina de vectores soporte (SVM)

4. Elección de la función de coste

Función de coste bisagra (hinge loss)



$$L(h_w(x), y) = \max(0, 1 - yz)$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n L(h_w(x^{(i)}), y^{(i)})$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n L(h_w(x^{(i)}), y^{(i)}) + \lambda \|w\|_2^2$$

Maquina de vectores soporte (SVM)

4. Elección de la función de coste




Función de coste bisagra (hinge loss)

CONVEXA

Maquina de vectores soporte (SVM)


5. Optimización del coste



Gradient Descent

Maquina de vectores soporte (SVM)

5. Optimización del coste



$$b^* = -52.0$$

$$w_1^* = 0.410$$

$$w_2^* = 0.624$$

$$m^* = 0.75$$

Gradient Descent

Maquina de vectores soporte (SVM)

6. Evaluación del resultado

$n_{train} = 200$ Optimización: `scikit-learn.svm`

Cliente	Ingresos (m€) $x_1^{(i)}$	Edad (años) $x_2^{(i)}$	Vehículo $y^{(i)}$	Vehículo $\hat{y}^{(i)}$
201	40.94	42.6	N	N
202	57.53	53.7	S	S
203	38.75	49.4	N	N
204	72.85	46.9	S	S
205	28.32	45.7	N	N
⋮	⋮		⋮	⋮

$$\begin{cases} y = 1, \forall x w^T + b \geq 0 \\ y = 0, \forall x w^T + b < 0 \end{cases}$$

Maquina de vectores soporte (SVM)

6. Evaluación del resultado

Matriz de confusión

		Clase calculada		Elementos
		<i>P</i>	<i>N</i>	
Clase real	<i>P</i>	284	73	357
	<i>N</i>	50	393	443
Estimaciones		334	466	800


Maquina de vectores soporte (SVM)

6. Evaluación del resultado

Nombre	Acrónimo	Expresión	Valor
Sensitivity	SNS	$\frac{TP}{TP + FN}$	0.7955
Specificity	SPC	$\frac{TN}{TN + FP}$	0.8871
Precision	PRC	$\frac{TP}{TP + FP}$	0.8503
Negative Predictive Value	NPV	$\frac{TN}{TN + FN}$	0.8433
Accuracy	ACC	$\frac{TP + TN}{TP + TN + FP + FN}$	0.8463
F ₁ Score	F ₁	$2 \frac{SNS \cdot PRC}{SNS + PRC}$	0.8220
Geometric Mean	GM	$\sqrt{SNS \cdot SPC}$	0.8401

Maquina de vectores soporte (SVM)


6. Evaluación del resultado



$$n_{train} = 200$$

Maquina de vectores soporte (SVM)


6. Evaluación del resultado



$$n_{train} = 200$$

Maquina de vectores soporte (SVM)

6. Evaluación del resultado



Curva de aprendizaje