

Fundamentos del aprendizaje automático

(Machine learning)

Joaquín Luque


Contenido

1. Introducción
2. Regresión
 - a) Regresión univariable
 - b) Regresión multivariable
3. Clasificación
 - a) Regresión logística
 - b) Máquinas de vectores soporte (SVM)**
 - Forma dual de la optimización (regresión y SVM)
 - c) Funciones Kernel
 - d) Clasificación multiclase
4. Segmentación
5. Reducción de dimensionalidad
6. Deep learning (introducción)


Forma dual de la optimización

Introducción

Regresión logística



SVM



x_1 : ingresos
 x_2 : edad

$x: (x_1, x_2)$

$$h_w(x) = \frac{1}{1 + e^{-z}}; \quad z = xw^T$$

Forma dual de la optimización

Introducción


			f	φ	K	X
Rule-based systems		$y = f(X)$	Manual	-	-	Manual
Machine Learning	Basic ML	$y = f(X)$	Automatic	-	-	Manual
	Feature-based ML	$y = f[\varphi(X)]$	Automatic	Manual	-	Raw
	Kernel-based ML	$y = f[K(X)]$	Automatic	Automatic	Manual	Raw
	Deep Learning	$y = f(\varphi(X))$	Automatic	Automatic	-	Raw

Los features X son elegidos de forma manual de entre los disponibles
No existe ninguna transformación de los features


Forma dual de la optimización

Introducción

Regresión logística



SVM



x_1 : ingresos
 x_2 : edad


$x: (x_1, x_2)$

$$h_w(x) = \frac{1}{1 + e^{-z}}; \quad z = xw^T$$


Forma dual de la optimización

Introducción

Regresión logística



SVM



x_1 : ingresos

x_2 : edad

$x: (x_1, x_2)$

$\varphi(x): (x_1^2, x_2^2, x_1x_2, x_1, x_2, 1)$

$$h_w(x) = \frac{1}{1 + e^{-z}}; \quad z = \varphi w^T$$

Forma dual de la optimización

Introducción


			f	φ	K	X
Rule-based systems		$y = f(X)$	Manual	-	-	Manual
Machine Learning	Basic ML	$y = f(X)$	Automatic	-	-	Manual
	Feature-based ML	$y = f[\varphi(X)]$	Automatic	Manual	-	Raw
	Kernel-based ML	$y = f[K(X)]$	Automatic	Automatic	Manual	Raw
	Deep Learning	$y = f(\varphi(X))$	Automatic	Automatic	-	Raw

Los features $\varphi(X)$ son contruidos
mediante operaciones matemáticas elegidas de forma manual
a partir de los datos originales disponibles X


Forma dual de la optimización

Introducción

Regresión logística (orden 2)



Regresión logística (orden 4)



x_1 : ingresos

x_2 : edad

$x: (x_1, x_2)$


$\varphi(x): (x_1^2, x_2^2, x_1x_2, x_1, x_2)$

$\varphi(x): (x_1^4, x_1^3x_2, x_1^2x_2^2, x_1x_2^3, x_2^4, x_1^3, x_1^2x_2, x_1x_2^2, x_2^3, x_1^2, x_2^2, x_1x_2, x_1, x_2)$


Forma dual de la optimización

Introducción

Regresión logística (orden 4)



Regresión logística (orden 7)




Zona de abundantes errores de clasificación

Similares resultados con SVM

Forma dual de la optimización

Introducción



Forma dual de la optimización

Introducción

- Limitaciones del ML basado en la construcción de features $\varphi(X)$
 - Funciones polinómicas. Órdenes de polinomio alto implican:
 - Gran número de coeficientes
 - Mayor esfuerzo computacional
 - Problemas numéricos (overflow o underflow)
 - Otras funciones:
 - ¿Cuáles? ¿Cómo elegir las?

Forma dual de la optimización

Introducción

			f	φ	K	X
Rule-based systems		$y = f(X)$	Manual	-	-	Manual
Machine Learning	Basic ML	$y = f(X)$	Automatic	-	-	Manual
	Feature-based ML	$y = f[\varphi(X)]$	Automatic	Manual	-	Raw
	Kernel-based ML	$y = f[K(X)]$	Automatic	Automatic	Manual	Raw
	Deep Learning	$y = f(\varphi(X))$	Automatic	Automatic	-	Raw


Los features $\varphi(X)$ son contruidos de manera automática (no explícita) mediante el uso de funciones kernel $K(X)$ elegidas de forma manual a partir de los datos originales disponibles X

Forma dual de la optimización

- Forma dual de la regresión
 - Problema primal
 - Lagrangiana
 - Optimización de la Lagrangiana
 - Con respecto a w
 - Con respecto a e
 - Con respecto a μ
 - Predicción ante nuevos datos
- Forma dual de la SVM


Forma dual de la regresión

Introducción




Forma dual de la regresión

Introducción




Forma dual de la regresión

Introducción



Forma dual de la regresión


Introducción



Forma dual de la regresión

Introducción

Modelado




Predicción

The diagram illustrates the prediction step. It shows the input vector $x^{[t]}$ with dimensions 1 and d , and the output vector $y^{[t]}$ with dimensions 1 and 1 . The output $y^{[t]}$ is calculated as $y^{[t]} = x^{[t]} w^T$.

Forma dual de la regresión

Introducción



Forma dual de la regresión

1. Problema primal

$$w^* = \arg \min_w J(h_w(x), y)$$

$$w^* = \arg \min_w \left[\frac{1}{n} (Xw^T - y)^T (Xw^T - y) + \lambda \|w\|_2^2 \right]$$

Solución mediante Normal Equation

$$w^* = y^T X (X^T X + n\lambda I_d)^{-1}$$

Solución mediante SVD

$$w^* = \arg \min_w \|SV^T w^T - U^T y\|_2^2$$

$$X = USV^T$$

Forma dual de la regresión

1. Problema primal (cont.)

Predicción ante nuevos datos

$$y^{[t]} = x^{[t]} w^T$$

$$w = y^T X (X^T X + n\lambda I_d)^{-1}$$

$$\begin{matrix} (1 \times 1) & y^{[t]} = x^{[t]} & \begin{matrix} \overset{(1+d)}{\uparrow} & \overset{(1+n)}{\uparrow} & \overset{(n+d)}{\uparrow} & \overset{(d+n)}{\uparrow} & \overset{(n+d)}{\uparrow} \\ [y^T X (X^T X + n\lambda I_d)^{-1}]^T \end{matrix} \\ & & \underset{(d \times d)}{\downarrow} \end{matrix}$$

Forma dual de la regresión

1. Problema primal

$$w^* = \arg \min_w \left[\frac{1}{n} (Xw^T - y)^T (Xw^T - y) + \lambda \|w\|_2^2 \right]$$

$$w^* = \arg \min_w [(Xw^T - y)^T (Xw^T - y) + n\lambda \|w\|_2^2]$$

$$C \equiv \frac{1}{2n\lambda}$$

$$w^* = \arg \min_w \left[(Xw^T - y)^T (Xw^T - y) + \frac{1}{2C} \|w\|_2^2 \right]$$


$$a \equiv \frac{1}{2C} = n\lambda$$

$$w^* = \arg \min_w [(Xw^T - y)^T (Xw^T - y) + a \|w\|_2^2]$$

Forma dual de la optimización

- Forma dual de la regresión
 - Problema primal
 - Lagrangiana
 - Optimización de la Lagrangiana
 - Con respecto a w
 - Con respecto a e
 - Con respecto a μ
 - Predicción ante nuevos datos
- Forma dual de la SVM

Forma dual de la optimización



Forma dual de la regresión

2. Lagrangiana

$$\arg \min_w [(Xw^T - y)^T (Xw^T - y) + a\|w\|_2^2]$$

$$\arg \min_{w,e} \left[a\|w\|_2^2 + \sum_{i=1}^n e^{(i)2} \right] : e^{(i)} = y^{(i)} - x^{(i)}w^T$$

$$\min_{\omega} f(\omega) : g^{(i)}(\omega) = 0$$

$$f(\omega) = a\|w\|_2^2 + \sum_{i=1}^n e^{(i)2} \quad \omega = (w, e)$$

$$g^{(i)}(\omega) = y^{(i)} - x^{(i)}w^T - e^{(i)}$$

Forma dual de la regresión

2. Lagrangiana

$$\min_{\omega} f(\omega) : g(\omega) = 0$$

Lagrangiana $\mathcal{L}(\omega, \mu) \equiv f(\omega) + \mu g(\omega)$
 μ : Multiplicadores de Lagrange

Solución mediante Lagrangiana

$$\omega^* = \arg \min_{\omega} \mathcal{L}(\omega, \mu)$$

$$\nabla_{\omega, \mu} \mathcal{L}(\omega^*, \mu^*) = 0$$

Forma dual de la regresión

2. Lagrangiana (cont.)

Condiciones en el óptimo

1. $\nabla_{\omega} \mathcal{L}(\omega^*, \mu^*) = 0$

$$\nabla_{\omega} \mathcal{L}(\omega^*, \mu^*) = \nabla_{\omega} f(\omega^*) + \mu^* \nabla_{\omega} g(\omega^*) = 0$$

$$\nabla_{\omega} f(\omega^*) = -\mu^* \nabla_{\omega} g(\omega^*)$$

En el óptimo los gradientes de f y g son paralelos


2. $\nabla_{\mu} \mathcal{L}(\omega^*, \mu^*) = 0$

$$\nabla_{\mu} \mathcal{L}(\omega^*, \mu^*) = g(\omega^*) = 0$$

En el óptimo se cumplen las restricciones
impuestas por la función g

Forma dual de la regresión


2. Lagrangiana (ejemplo)



$$f(x, y) = \ln(1 + x^2 + y^2)$$

Forma dual de la regresión


2. Lagrangiana (ejemplo)



$$g(x, y) = \frac{\ln(x + 4) - y}{2}$$

Forma dual de la regresión


2. Lagrangiana (ejemplo)



$$g(x, y) = \frac{\text{Ln}(x + 4) - y}{2} = 0$$

Forma dual de la regresión


2. Lagrangiana (ejemplo)



$$g(x, y) = \frac{\ln(x + 4) - y}{2} = 0$$

Forma dual de la regresión


2. Lagrangiana (ejemplo)



$$f(x, y) = \ln(1 + x^2 + y^2) \quad g(x, y) = \frac{\ln(x + 4) - y}{2} = 0$$

Forma dual de la regresión


2. Lagrangiana (ejemplo)



$$f(x,y) = \text{Ln}(1 + x^2 + y^2)$$

Forma dual de la regresión


2. Lagrangiana (ejemplo)



$$g(x, y) = \frac{\ln(x + 4) - y}{2} = 0$$

Forma dual de la regresión

2. Lagrangiana (ejemplo)



$$\nabla_x f = -\mu \nabla_x g$$

$$\nabla_y f = -\mu \nabla_y g$$

$$x_{min} = -0.31$$

$$y_{min} = 1.31$$

$$f_{min} = 1.03$$

$$f(x,y) = \ln(1 + x^2 + y^2) \quad g(x,y) = \frac{\ln(x + 4) - y}{2} = 0$$

Forma dual de la regresión

2. Lagrangiana (ejemplo)

$$\begin{cases} \nabla_x f(x, y) = -\mu \nabla_x g(x, y) \\ \nabla_y f(x, y) = -\mu \nabla_y g(x, y) \\ g(x, y) = 0 \end{cases}$$

$$\mathcal{L}(x, y, \mu) \equiv f(x, y) + \mu g(x, y)$$

$$\begin{cases} \nabla_x \mathcal{L} = 0 \Rightarrow \nabla_x f(x, y) + \mu \nabla_x g(x, y) = 0 \\ \nabla_y \mathcal{L} = 0 \Rightarrow \nabla_y f(x, y) + \mu \nabla_y g(x, y) = 0 \\ \nabla_\mu \mathcal{L} = 0 \Rightarrow g(x, y) = 0 \end{cases}$$

$$\nabla_{x,y,\mu} \mathcal{L}(x, y, \mu) = 0$$

Forma dual de la regresión

2. Lagrangiana (ejemplo)

$$f(x, y) = \text{Ln}(1 + x^2 + y^2)$$

$$g(x, y) = \frac{\text{Ln}(x + 4) - y}{2} = 0$$

$$\mathcal{L}(x, y, \mu) \equiv f(x, y) + \mu g(x, y)$$

$$\mathcal{L}(x, y, \mu) = \text{Ln}(1 + x^2 + y^2) + \mu \frac{\text{Ln}(x + 4) - y}{2}$$

$$\nabla_{x,y,\mu} \mathcal{L}(x, y, \mu) = 0$$

Forma dual de la regresión

2. Lagrangiana (ejemplo)

$$\mathcal{L}(x, y, \mu) = \text{Ln}(1 + x^2 + y^2) + \mu \frac{\text{Ln}(x + 4) - y}{2}$$

$$\nabla_x \mathcal{L} = \frac{\partial \mathcal{L}}{\partial x} = \frac{2x}{1 + x^2 + y^2} + \mu \frac{1}{2(x + 4)}$$

$$\nabla_y \mathcal{L} = \frac{\partial \mathcal{L}}{\partial y} = \frac{2y}{1 + x^2 + y^2} - \frac{\mu}{2} = 0 \Rightarrow \mu = \frac{4y}{1 + x^2 + y^2}$$

$$\nabla_\mu \mathcal{L} = \frac{\partial \mathcal{L}}{\partial \mu} = \frac{\text{Ln}(x + 4) - y}{2} = 0 \Rightarrow y = \text{Ln}(x + 4)$$

Forma dual de la regresión

2. Lagrangiana (ejemplo)

$$\frac{2x}{1 + x^2 + \text{Ln}^2(x + 4)} + \frac{4 \text{Ln}(x + 4)}{1 + x^2 + \text{Ln}^2(x + 4)} \cdot \frac{1}{2(x + 4)} = 0$$

$$\frac{2 \left(x + \frac{\text{Ln}(x + 4)}{x + 4} \right)}{1 + x^2 + \text{Ln}^2(x + 4)} = 0$$

$$x + \frac{\text{Ln}(x + 4)}{(x + 4)} = 0$$

$$x(x + 4) + \text{Ln}(x + 4) = 0$$

Forma dual de la regresión

2. Lagrangiana (ejemplo)

$$e^{-x^2-3x} = x + 3 \Rightarrow x = -0.31$$

$$\nabla_{\mu} \mathcal{L} = \frac{\partial \mathcal{L}}{\partial \mu} = \frac{\text{Ln}(x + 4) - y}{2} = 0$$


$$y = \text{Ln}(x + 4) \Rightarrow y = 1.31$$

$$\nabla_y \mathcal{L} = \frac{\partial \mathcal{L}}{\partial y} = \frac{2y}{1 + x^2 + y^2} - \frac{\mu}{2} = 0$$

$$\mu = \frac{4y}{1 + x^2 + y^2} \Rightarrow \mu = 1.87$$

Forma dual de la regresión

2. Lagrangiana (ejemplo)



$$\min_u f(w) : g(w) \leq 0$$

Forma dual de la regresión

2. Lagrangiana (cont.)

$$\min_{w,e} \left[a\|w\|_2^2 + \sum_{i=1}^n e^{(i)2} \right] : e^{(i)} = y^{(i)} - x^{(i)}w^T, \forall i \in [1, \dots, n]$$

$$\min_{\omega} f(\omega) : g^{(i)}(\omega) = 0$$

$$f(\omega) = a\|w\|_2^2 + \sum_{i=1}^n e^{(i)2}$$

$$g^{(i)}(\omega) = y^{(i)} - x^{(i)}w^T - e^{(i)}$$

Forma dual de la regresión

2. Lagrangiana (cont.)

$$\mathcal{L}(w, e, \mu) = a \|w\|_2^2 + \sum_{i=1}^n e^{(i)2} + \sum_{i=1}^n \mu^{(i)} [y^{(i)} - x^{(i)T} w - e^{(i)}]$$

$$\mathcal{L}(w, e, \mu) = a \sum_{j=1}^d w_j^2 + \sum_{i=1}^n e^{(i)2} + \sum_{i=1}^n \mu^{(i)} \left[y^{(i)} - \left(\sum_{j=1}^d w_j x_j^{(i)} \right) - e^{(i)} \right]$$

Forma dual de la regresión

2. Lagrangiana (cont.)

$$\nabla_{w,e,\mu} \mathcal{L}(w, e, \mu) = \begin{bmatrix} \frac{\partial \mathcal{L}}{\partial w} \\ \frac{\partial \mathcal{L}}{\partial e} \\ \frac{\partial \mathcal{L}}{\partial \mu} \end{bmatrix} = 0; \quad \mu = \begin{bmatrix} \mu^{(1)} \\ \mu^{(2)} \\ \vdots \\ \mu^{(n)} \end{bmatrix}$$

$$\frac{\partial \mathcal{L}}{\partial w} = \begin{bmatrix} \frac{\partial \mathcal{L}}{\partial w_1} \\ \vdots \\ \frac{\partial \mathcal{L}}{\partial w_d} \end{bmatrix}$$

$$\frac{\partial \mathcal{L}}{\partial e} = \begin{bmatrix} \frac{\partial \mathcal{L}}{\partial e^{(1)}} \\ \vdots \\ \frac{\partial \mathcal{L}}{\partial e^{(n)}} \end{bmatrix}$$

$$\frac{\partial \mathcal{L}}{\partial \mu} = \begin{bmatrix} \frac{\partial \mathcal{L}}{\partial \mu^{(1)}} \\ \vdots \\ \frac{\partial \mathcal{L}}{\partial \mu^{(n)}} \end{bmatrix}$$

Forma dual de la optimización

- Forma dual de la regresión
 - Problema primal
 - Lagrangiana
 - Optimización de la Lagrangiana
 - Con respecto a w
 - Con respecto a e
 - Con respecto a μ
 - Predicción ante nuevos datos
- Forma dual de la SVM

Forma dual de la regresión

3.a Optimización de la Lagrangiana con respecto a w

$$\mathcal{L}(w, e, \mu) = a \sum_{j=1}^d w_j^2 + \sum_{i=1}^n e^{(i)^2} + \sum_{i=1}^n \mu^{(i)} \left[y^{(i)} - \left(\sum_{j=1}^d w_j x_j^{(i)} \right) - e^{(i)} \right]$$

$$\frac{\partial \mathcal{L}}{\partial w_j} = 2aw_j - \sum_{i=1}^n \mu^{(i)} x_j^{(i)} = 0$$

$$a \equiv \frac{1}{2C}$$

$$w_j = \frac{1}{2a} \sum_{i=1}^n \mu^{(i)} x_j^{(i)} = C \sum_{i=1}^n \mu^{(i)} x_j^{(i)}$$

Forma dual de la regresión

3.a Optimización de la Lagrangiana con respecto a w (cont.)

$$w_j = C \sum_{i=1}^n \mu^{(i)} x_j^{(i)}$$

$$w^T = \begin{bmatrix} w_1 \\ \vdots \\ w_d \end{bmatrix} = C \begin{bmatrix} \mu^{(1)} x_1^{(1)} + \mu^{(2)} x_1^{(2)} + \dots + \mu^{(n)} x_1^{(n)} \\ \vdots \\ \mu^{(1)} x_d^{(1)} + \mu^{(2)} x_d^{(2)} + \dots + \mu^{(n)} x_d^{(n)} \end{bmatrix}$$

$$w^T = CX^T \mu$$

$$w = C(X^T \mu)^T = C\mu^T X$$

Forma dual de la regresión

3.a Optimización de la Lagrangiana con respecto a w (cont.)

$$a \sum_{j=1}^d w_j^2 = \frac{a}{4a^2} \sum_{j=1}^d \left[\left(\sum_{i=1}^n \mu^{(i)} x_j^{(i)} \right) \left(\sum_{i=1}^n \mu^{(i)} x_j^{(i)} \right) \right]$$

$$a \sum_{j=1}^d w_j^2 = \frac{1}{4a} \sum_{j=1}^d \left[\sum_{r=1}^n \sum_{s=1}^n \mu^{(r)} \mu^{(s)} x_j^{(r)} x_j^{(s)} \right]$$

Forma dual de la regresión

3.a Optimización de la Lagrangiana con respecto a w (cont.)

$$a \sum_{j=1}^d w_j^2 = \frac{a}{4a^2} \sum_{r=1}^n \sum_{s=1}^n \mu^{(r)} \mu^{(s)} \sum_{j=1}^d x_j^{(r)} x_j^{(s)}$$

$$a \sum_{j=1}^d w_j^2 = \frac{1}{4a} \sum_{r=1}^n \sum_{s=1}^n \mu^{(r)} \mu^{(s)} \left\langle x_j^{(r)} x_j^{(s)} \right\rangle$$

Forma dual de la regresión

3.a Optimización de la Lagrangiana con respecto a w (cont.)

$$\sum_{i=1}^n \mu^{(i)} \left(\sum_{j=1}^d w_j x_j^{(i)} \right) = \frac{1}{2a} \sum_{i=1}^n \mu^{(i)} \left(\sum_{j=1}^d \left[\sum_{k=1}^n \mu^{(k)} x_j^{(k)} \right] x_j^{(i)} \right)$$

$$\sum_{i=1}^n \mu^{(i)} \left(\sum_{j=1}^d w_j x_j^{(i)} \right) = \frac{1}{2a} \sum_{i=1}^n \mu^{(i)} \left(\sum_{k=1}^n \sum_{j=1}^d \mu^{(k)} x_j^{(k)} x_j^{(i)} \right)$$

Forma dual de la regresión

3.a Optimización de la Lagrangiana con respecto a w (cont.)

$$\sum_{i=1}^n \mu^{(i)} \left(\sum_{j=1}^d w_j x_j^{(i)} \right) = \frac{1}{2a} \sum_{i=1}^n \mu^{(i)} \left(\sum_{k=1}^n \mu^{(k)} \langle x^{(i)} x^{(k)} \rangle \right)$$

$$\sum_{i=1}^n \mu^{(i)} \left(\sum_{j=1}^d w_j x_j^{(i)} \right) = \frac{1}{2a} \sum_{r=1}^n \sum_{s=1}^n \mu^{(r)} \mu^{(s)} \langle x^{(r)} x^{(s)} \rangle$$

Forma dual de la regresión

3.a Optimización de la Lagrangiana con respecto a w (cont.)

$$\mathcal{L}(w, e, \mu) = \frac{1}{4a} \sum_{r=1}^n \sum_{s=1}^n \mu^{(r)} \mu^{(s)} \left\langle x_j^{(r)} x_j^{(s)} \right\rangle + \sum_{i=1}^n e^{(i)^2} + \sum_{i=1}^n \mu^{(i)} y^{(i)} - \frac{1}{2a} \sum_{r=1}^n \sum_{s=1}^n \mu^{(r)} \mu^{(s)} \left\langle x_j^{(r)} x_j^{(s)} \right\rangle - \sum_{i=1}^n \mu^{(i)} e^{(i)}$$

$$\mathcal{L}(w, e, \mu) = \frac{-1}{4a} \sum_{r=1}^n \sum_{s=1}^n \mu^{(r)} \mu^{(s)} \left\langle x_j^{(r)} x_j^{(s)} \right\rangle + \sum_{i=1}^n e^{(i)^2} + \sum_{i=1}^n \mu^{(i)} y^{(i)} - \sum_{i=1}^n \mu^{(i)} e^{(i)}$$

Forma dual de la optimización

- Forma dual de la regresión
 - Problema primal
 - Lagrangiana
 - Optimización de la Lagrangiana
 - Con respecto a w
 - Con respecto a e
 - Con respecto a μ
 - Predicción ante nuevos datos
- Forma dual de la SVM

Forma dual de la regresión

3.b Optimización de la Lagrangiana con respecto a e

$$\frac{\partial \mathcal{L}}{\partial e^{(i)}} = 2e^{(i)} - \mu^{(i)} = 0$$

$$e^{(i)} = \frac{\mu^{(i)}}{2}$$

$$\mathcal{L}(w, e, \mu) = \frac{-1}{4a} \sum_{r=1}^n \sum_{s=1}^n \mu^{(r)} \mu^{(s)} \left\langle x_j^{(r)} x_j^{(s)} \right\rangle + \sum_{i=1}^n \frac{\mu^{(i)^2}}{4} +$$
$$\sum_{i=1}^n \mu^{(i)} y^{(i)} - \sum_{i=1}^n \mu^{(i)} \frac{\mu^{(i)}}{2}$$

Forma dual de la regresión

3.b Optimización de la Lagrangiana con respecto a e (cont.)

$$\mathcal{L}(w, e, \mu) = \frac{-1}{4a} \sum_{r=1}^n \sum_{s=1}^n \mu^{(r)} \mu^{(s)} \left\langle x_j^{(r)} x_j^{(s)} \right\rangle - \frac{1}{4} \sum_{i=1}^n \mu^{(i)^2} + \sum_{i=1}^n \mu^{(i)} y^{(i)}$$

$$\mathcal{L}(w, e, \mu) = \frac{-1}{4a} \sum_{r=1}^n \left(\left\langle \mu^{(r)} x^{(r)} \cdot \sum_{s=1}^n \mu^{(s)} x^{(s)} \right\rangle \right) - \frac{1}{4} \sum_{i=1}^n \mu^{(i)^2} + \sum_{i=1}^n \mu^{(i)} y^{(i)}$$

Forma dual de la optimización

- Forma dual de la regresión
 - Problema primal
 - Problema dual
 - Lagrangiana
 - Optimización de la Lagrangiana
 - Con respecto a w
 - Con respecto a e
 - Con respecto a μ
 - Predicción ante nuevos datos
- Forma dual de la SVM

Forma dual de la regresión

3.c Optimización de la Lagrangiana con respecto a μ

$$\frac{\partial \mathcal{L}}{\partial \mu^{(i)}} = 0$$

$$\frac{\partial \mathcal{L}}{\partial \mu^{(i)}} = \frac{-1}{4a} \sum_{r=1}^n \frac{\partial}{\partial \mu^{(i)}} \left[\left\langle \mu^{(r)} x^{(r)} \cdot \sum_{s=1}^n \mu^{(s)} x^{(s)} \right\rangle \right] - \frac{1}{4} 2\mu^{(i)} + y^{(i)}$$

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \mu^{(i)}} = \frac{-1}{4a} \sum_{r=1}^n \left\langle x^{(r)} \cdot \left[\frac{\partial \mu^{(r)}}{\partial \mu^{(i)}} \sum_{s=1}^n \mu^{(s)} x^{(s)} + \mu^{(r)} \frac{\partial}{\partial \mu^{(i)}} \sum_{s=1}^n \mu^{(s)} x^{(s)} \right] \right\rangle \\ - \frac{\mu^{(i)}}{2} + y^{(i)} \end{aligned}$$

Forma dual de la regresión

3.c Optimización de la Lagrangiana con respecto a μ (cont.)

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \mu^{(i)}} = & \frac{-1}{4a} \left[\sum_{r=1}^n \left\langle x^{(r)} \cdot \frac{\partial \mu^{(r)}}{\partial \mu^{(i)}} \sum_{s=1}^n \mu^{(s)} x^{(s)} \right\rangle \right] - \\ & \frac{1}{4a} \left[\sum_{r=1}^n \left\langle x^{(r)} \cdot \mu^{(r)} \frac{\partial}{\partial \mu^{(i)}} \sum_{s=1}^n \mu^{(s)} x^{(s)} \right\rangle \right] - \frac{\mu^{(i)}}{2} + y^{(i)} \end{aligned}$$

Forma dual de la regresión

3.c Optimización de la Lagrangiana con respecto a μ (cont.)

$$\frac{\partial \mathcal{L}}{\partial \mu^{(i)}} = \frac{-1}{4a} \left\langle x^{(i)} \cdot \sum_{s=1}^n \mu^{(s)} x^{(s)} \right\rangle - \frac{1}{4a} \sum_{r=1}^n \langle x^{(r)} \cdot \mu^{(r)} x^{(i)} \rangle - \frac{\mu^{(i)}}{2} + y^{(i)}$$

$$\frac{\partial \mathcal{L}}{\partial \mu^{(i)}} = -\frac{1}{2a} \sum_{r=1}^n \mu^{(r)} \langle x^{(i)} \cdot x^{(r)} \rangle - \frac{\mu^{(i)}}{2} + y^{(i)}$$

Forma dual de la regresión

3.c Optimización de la Lagrangiana con respecto a μ (cont.)

$$X = \begin{matrix} (n \times d) \\ \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \cdots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(n)} & x_2^{(n)} & \cdots & x_d^{(n)} \end{bmatrix} \end{matrix}; \quad X^T = \begin{matrix} (d \times n) \\ \begin{bmatrix} x_1^{(1)} & x_1^{(2)} & \cdots & x_1^{(n)} \\ x_2^{(1)} & x_2^{(2)} & \cdots & x_2^{(n)} \\ \vdots & \vdots & \ddots & \vdots \\ x_d^{(1)} & x_d^{(2)} & \cdots & x_d^{(n)} \end{bmatrix} \end{matrix}$$

Matriz de Gramm

$$G \equiv \begin{matrix} (n \times n) \\ XX^T = \begin{bmatrix} g^{(1,1)} & g^{(1,2)} & \cdots & g^{(1,n)} \\ g^{(2,1)} & g^{(2,2)} & \cdots & g^{(2,n)} \\ \vdots & \vdots & \ddots & \vdots \\ g^{(n,1)} & g^{(n,2)} & \cdots & g^{(n,n)} \end{bmatrix} \end{matrix}$$

$$g^{(u,v)} = x_1^{(u)} x_1^{(v)} + x_2^{(u)} x_d^{(v)} + \cdots + x_d^{(u)} x_d^{(v)} = \langle x^{(u)} \cdot x^{(v)} \rangle$$

Forma dual de la regresión

3.c Optimización de la Lagrangiana con respecto a μ (cont.)

$$\frac{\partial \mathcal{L}}{\partial \mu^{(i)}} = -\frac{1}{2a} \sum_{r=1}^n \mu^{(r)} g^{(i,r)} - \frac{\mu^{(i)}}{2} + y^{(i)}$$

$$\frac{\partial \mathcal{L}}{\partial \mu} \equiv \begin{bmatrix} \frac{\partial \mathcal{L}}{\partial \mu^{(1)}} \\ \vdots \\ \frac{\partial \mathcal{L}}{\partial \mu^{(n)}} \end{bmatrix} = \begin{bmatrix} -\frac{1}{2a} \sum_{r=1}^n \mu^{(r)} g^{(1,r)} - \frac{\mu^{(1)}}{2} + y^{(1)} \\ \vdots \\ -\frac{1}{2a} \sum_{r=1}^n \mu^{(r)} g^{(n,r)} - \frac{\mu^{(n)}}{2} + y^{(n)} \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$$

Forma dual de la regresión

3.c Optimización de la Lagrangiana con respecto a μ (cont.)

$$\frac{\partial \mathcal{L}}{\partial \mu} = \begin{bmatrix} -\frac{1}{2a} \sum_{r=1}^n \mu^{(r)} g^{(1,r)} \\ \vdots \\ -\frac{1}{2a} \sum_{r=1}^n \mu^{(r)} g^{(n,r)} \end{bmatrix} - \begin{bmatrix} \frac{\mu^{(1)}}{2} + y^{(1)} \\ \vdots \\ \frac{\mu^{(n)}}{2} + y^{(n)} \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$$

Forma dual de la regresión

3.c Optimización de la Lagrangiana con respecto a μ (cont.)

$$\frac{\partial \mathcal{L}}{\partial \mu} = -\frac{1}{2a} \begin{bmatrix} \sum_{r=1}^n \mu^{(r)} g^{(1,r)} \\ \vdots \\ \sum_{r=1}^n \mu^{(r)} g^{(1,r)} \end{bmatrix} - \frac{1}{2} \mu + y = 0$$

Forma dual de la regresión

3.c Optimización de la Lagrangiana con respecto a μ (cont.)

$$G\mu = \begin{matrix} (n \times 1) & \begin{bmatrix} g^{(1,1)} & g^{(1,2)} & \dots & g^{(1,n)} \\ g^{(2,1)} & g^{(2,2)} & \dots & g^{(2,n)} \\ \vdots & \vdots & \ddots & \vdots \\ g^{(n,1)} & g^{(n,2)} & \dots & g^{(n,n)} \end{bmatrix} & \begin{bmatrix} \mu^{(1)} \\ \mu^{(2)} \\ \vdots \\ \mu^{(n)} \end{bmatrix} \\ & (n \times n) & (n \times 1) \end{matrix}$$

$$G\mu = \begin{bmatrix} \mu^{(1)} g^{(1,1)} + \mu^{(2)} g^{(1,2)} + \dots + \mu^{(n)} g^{(1,n)} \\ \mu^{(1)} g^{(2,1)} + \mu^{(2)} g^{(2,2)} + \dots + \mu^{(n)} g^{(2,n)} \\ \vdots \\ \mu^{(1)} g^{(n,1)} + \mu^{(2)} g^{(n,2)} + \dots + \mu^{(n)} g^{(n,n)} \end{bmatrix}$$

Forma dual de la regresión

3.c Optimización de la Lagrangiana con respecto a μ (cont.)

$$G\mu = \begin{bmatrix} \sum_{r=1}^n \mu^{(r)} g^{(1,r)} \\ \sum_{r=1}^n \mu^{(r)} g^{(2,r)} \\ \vdots \\ \sum_{r=1}^n \mu^{(r)} g^{(n,r)} \end{bmatrix}$$

Forma dual de la regresión

3.c Optimización de la Lagrangiana con respecto a μ (cont.)

$$\frac{\partial \mathcal{L}}{\partial \mu} = -\frac{1}{2a} G\mu - \frac{\mu}{2} + y = 0$$

$$-G\mu - a\mu + 2ay = 0$$

$$\mu(G + aI_n) = 2ay$$

$$a = n\lambda$$

$$\mu = 2a(G + aI_n)^{-1}y$$

$$\alpha \equiv \frac{\mu}{2a} = \frac{\mu}{2n\lambda}$$

$$\alpha = (G + n\lambda I_n)^{-1}y$$

Forma dual de la optimización

- Forma dual de la regresión
 - Problema primal
 - Lagrangiana
 - Optimización de la Lagrangiana
 - Con respecto a w
 - Con respecto a e
 - Con respecto a μ
 - Predicción ante nuevos datos
- Forma dual de la SVM

Forma dual de la regresión

4. Predicción ante nuevos datos

$$y^{[t]} = x^{[t]} w^T = \sum_{j=1}^d w_j x_j^{[t]}$$

$$w_j = \frac{1}{2a} \sum_{i=1}^n \mu^{(i)} x_j^{(i)} = \sum_{i=1}^n \alpha^{(i)} x_j^{(i)}$$

$$y^{[t]} = \sum_{j=1}^d \left(\sum_{i=1}^n \alpha^{(i)} x_j^{(i)} \right) x_j^{[t]}$$

Forma dual de la regresión

4. Predicción ante nuevos datos (cont.)

$$y^{[t]} = \sum_{i=1}^n \left(\sum_{j=1}^d \alpha^{(i)} x_j^{(i)} x_j^{[t]} \right)$$

$$y^{[t]} = \sum_{i=1}^n \left[\alpha^{(i)} \left(\sum_{j=1}^d x_j^{[t]} x_j^{(i)} \right) \right]$$

$$y^{[t]} = \sum_{i=1}^n \left[\alpha^{(i)} \langle x^{[t]} \cdot x^{(i)} \rangle \right]$$

Forma dual de la regresión

4. Predicción ante nuevos datos (cont.)

$$y^{[t]} = \sum_{i=1}^n \alpha^{(i)} g^{[t,i]}$$

$$(1 \times n) \quad g^{[t]} \equiv [g^{[t,1]} \quad \dots \quad g^{[t,n]}] = x^{[t]} X^T$$

$$(1 \times 1) \quad y^{[t]} = g^{[t]} \alpha$$

$$(n \times 1) \quad \alpha = \underbrace{(G + n\lambda I_n)}_{(n \times n)}^{-1} y \quad (n \times 1)$$

Forma dual de la regresión

4. Predicción ante nuevos datos (cont.)

$$y^{[t]} = \frac{1}{2a} g^{[t]} [2a(G + aI_n)^{-1} y]$$

$$y^{[t]} = g^{[t]} (G + aI_n)^{-1} y$$

$$G = XX^T$$

$$a \equiv \frac{1}{2C} = n\lambda$$

$$g^{[t]} = x^{[t]} X^T$$

$$\begin{matrix} & (1 \times n) & (n \times d) & (d \times n) & \\ (1 \times 1) y^{[t]} = g^{[t]} (& & & &)^{-1} y \\ & & (n \times n) & & \end{matrix}$$

Forma dual de la regresión

4. Predicción ante nuevos datos (resumen)

Problema primal

$$\overset{(1 \times 1)}{y^{[t]}} = \overset{(1 \times d)}{x^{[t]}} \overset{(d \times 1)}{w^T} = \overset{(1 \times n)}{y^T} \overset{(n \times d)}{X} \underset{(d \times d)}{\overset{(d \times n)}{(X^T X + n\lambda I_d)^{-1}}} \overset{(n \times d)}{x^{[t]T}}$$

Problema dual

$$\overset{(1 \times 1)}{y^{[t]}} = \overset{(1 \times n)}{g^{[t]}} \overset{(n \times 1)}{\alpha} = \overset{(1 \times n)}{g^{[t]}} \underset{(n \times n)}{\overset{(n \times d)}{(X X^T + n\lambda I_n)^{-1}}} \overset{(d \times 1)}{y}$$

$$g^{[t]} = x^{[t]} X^T$$

Forma dual de la regresión

4. Predicción ante nuevos datos (resumen)

Problema primal

$$y^{[t]} = \overset{\text{Training target}}{y^T} \overset{\text{Design matrix}}{X} \overset{\text{Covarianza}}{(X^T X + n\lambda I_d)}^{-1} \overset{\text{Features}}{x^{[t]T}}$$

Problema dual


$$y^{[t]} = \overset{\text{Dual features}}{g^{[t]}} \overset{\text{Gramm}}{(X X^T + n\lambda I_n)}^{-1} \overset{\text{Training target}}{y}$$

$$g^{[t]} = x^{[t]} X^T$$


Forma dual de la regresión

Introducción

Modelado




Predicción



Forma dual de la regresión

Introducción





Forma dual de la regresión

Resumen

Primal	Features	$x^{(i)}$
	Modelo óptimo	$w = y^T X C_r^{-1}$
	Predicción	$y^{[t]} = x^{[t]} w^T$
Dual	Features	$g^{(i)} = x^{(i)} X^T = [\langle x^{(i)} x^{(1)} \rangle, \langle x^{(i)} x^{(2)} \rangle, \dots, \langle x^{(i)} x^{(n)} \rangle]$
	Modelo óptimo	$\alpha = G_r^{-1} y$
	Predicción	$y^{[t]} = g^{[t]} \alpha$

Forma dual de la regresión

4. Predicción ante nuevos datos (resumen)



Tiempo de cálculo de la NE: $O(n \times d^2)$

Tiempo de cálculo de la SVD: $O(n \times d)$

Tiempo de cálculo de la NE dual: $O(n^2 \times d)$

Forma dual de la optimización

- Forma dual de la regresión
- Forma dual de la SVM
 - Problema primal
 - Lagrangiana generalizada
 - Optimización de la Lagrangiana con respecto a ξ
 - Optimización de la Lagrangiana con respecto a b
 - Optimización primal de la Lagrangiana
 - Optimización dual de la Lagrangiana
 - Predicción ante nuevos datos

Forma dual de la SVM

1. Problema primal

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n \max(0, 1 - y^{(i)} z^{(i)}) + \lambda \|w\|_2^2$$

$$y^{(i)} \equiv 2y^{(i)} - 1$$


$$z^{(i)} \equiv x^{(i)} w^T + b$$

$$x \equiv [x_1 \quad x_2 \quad \cdots \quad x_d] \quad (1 \times d)$$


$$w \equiv [w_1 \quad w_2 \quad \cdots \quad w_d] \quad (1 \times d)$$

Forma dual de la SVM

1. Problema primal



Función de coste



Gradiente de la
función de coste

Forma dual de la SVM

1. Problema primal


$$w^*, b^* \equiv \arg \min_{w, b} \left[\frac{1}{n} \sum_{i=1}^n \max \left(0, 1 - y^{(i)} (x^{(i)} w^T + b) \right) + \lambda \|w\|_2^2 \right]$$

- El gradiente de la función de coste es discontinuo
 - La optimización por Gradient Descent es inestable
 - Problemas de convergencia
- Optimización avanzada
 - Por ejemplo: método de Powell
 - <http://mathfaculty.fullerton.edu/mathews/n2003/PowellMethodMod.html>

Forma dual de la SVM

1. Problema primal

$$\lambda = 0.005$$



$$\begin{aligned} b^* &= -22.1 \\ w_1^* &= 0.261 \\ w_2^* &= 0.170 \end{aligned}$$

$$w^*, b^* \equiv \arg \min_{w, b} \left[\frac{1}{n} \sum_{i=1}^n \max \left(0, 1 - y^{(i)} (x^{(i)} w^T + b) \right) + \lambda \|w\|_2^2 \right]$$

Forma dual de la SVM

1. Problema primal (cont.)

Alternativa: Optimización con restricciones

Slack (holgura) $\xi^{(i)} \equiv \max(0, 1 - y^{(i)} z^{(i)})$

$$\xi^{(i)} = \begin{cases} \max(0, 1 - z^{(i)}), \forall y^{(i)} = +1 \\ \max(0, 1 + z^{(i)}), \forall y^{(i)} = -1 \end{cases}$$

$$\xi^{(i)} \equiv \max\left(0, 1 - y^{(i)}(x^{(i)} w^T + b)\right)$$

Forma dual de la SVM

1. Problema primal (cont.)


Alternativa: Optimización con restricciones

$$c = \max(a, b) \Rightarrow \left\{ \begin{array}{l} a > b \rightarrow c = a > b \\ a = b \rightarrow c = a = b \\ b > a \rightarrow c = b > a \end{array} \right\} \Rightarrow \left\{ \begin{array}{l} c \geq a \\ c \geq b \end{array} \right.$$

$$\xi^{(i)} \equiv \max \left(0, 1 - y^{(i)} (x^{(i)} w^T + b) \right) \Rightarrow \left\{ \begin{array}{l} \xi^{(i)} \geq 0 \\ \xi^{(i)} \geq 1 - y^{(i)} (x^{(i)} w^T + b) \end{array} \right.$$

Forma dual de la SVM

1. Problema primal (cont.)



Slack

$$\xi^{(i)} \equiv \max(0, 1 - y^{(i)} z^{(i)})$$

Forma dual de la SVM

1. Problema primal (cont.)

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n \max(0, 1 - y^{(i)} z^{(i)}) + \lambda \|w\|_2^2$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n \xi^{(i)} + \lambda \|w\|_2^2$$

$$J_h(h_w(x), y) \equiv \frac{1}{2\lambda} J(h_w(x), y) = \frac{1}{2n\lambda} \sum_{i=1}^n \xi^{(i)} + \frac{1}{2} \|w\|_2^2$$

$$C \equiv \frac{1}{2n\lambda} \quad J_h(h_w(x), y) = \frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^n \xi^{(i)}$$

Forma dual de la SVM

1. Problema primal (cont.)

$$w^*, b^* \equiv \arg \min_{w, b} J = \arg \min_{w, b} J_h$$

$$w^*, b^* = \arg \min_{w, b} \left(\frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^n \xi^{(i)} \right)$$

s.t.: $\xi^{(i)} \geq 1 - y^{(i)}(x^{(i)} w^T + b); \xi^{(i)} \geq 0$

El efecto de introducir el slack (holgura) es sustituir:

- una función no lineal $\max(0, 1 - y^{(i)}(x^{(i)} w^T + b))$
- por $2n$ restricciones $\xi^{(i)} \geq 1 - y^{(i)}(x^{(i)} w^T + b); \xi^{(i)} \geq 0$

Forma dual de la SVM

1. Problema primal (cont.)

$$\min_{\omega} f(\omega) : g_u(\omega) \leq 0, u = 1, \dots, r_g$$

$$f(w, \xi) = \frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^n \xi^{(i)}$$

$$g_u(w, b, \xi) : \begin{cases} 1 - y^{(i)}(x^{(i)}w^T + b) - \xi^{(i)} \leq 0, \forall u = 1, \dots, n \\ -\xi^{(i)} \leq 0, \forall u = n + 1, \dots, 2n \end{cases}$$


$$\xi^{(i)} \equiv \max(0, 1 - y^{(i)}x^{(i)}w^T)$$

$$\omega : (w, b, \xi)$$

Forma dual de la SVM

1. Problema primal (cont.)

$$C = 1$$



$$b^* = -22.7$$

$$w_1^* = 0.226$$

$$w_2^* = 0.227$$

$$w^*, b^* = \arg \min_{w, b} \left(\frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^n \xi^{(i)} \right)$$

Forma dual de la optimización

- Forma dual de la regresión
- **Forma dual de la SVM**
 - Problema primal
 - **Lagrangiana generalizada**
 - Optimización de la Lagrangiana con respecto a ξ
 - Optimización de la Lagrangiana con respecto a b
 - Optimización primal de la Lagrangiana
 - Optimización dual de la Lagrangiana
 - Predicción ante nuevos datos

Forma dual de la SVM

2. Lagrangiana generalizada

$$\min_{\omega} f(\omega) :$$

$$g_u(\omega) \leq 0, u = 1, \dots, r_g$$

$$h_v(\omega) = 0, v = 1, \dots, r_h$$

Lagrangiana

$$\mathcal{L}(\omega, \eta, \beta) \equiv f(\omega) + \sum_{u=1}^{r_g} \eta_u g_u(\omega) + \sum_{v=1}^{r_h} \beta_v h_v(\omega)$$

η_u, β_v : Multiplicadores de Lagrange

Forma dual de la SVM

2. Lagrangiana generalizada (cont.)

Primal


$$\omega^* = \arg \min_{\omega} \left[\max_{\eta, \beta: \eta_u \geq 0} \mathcal{L}(\omega, \eta, \beta) \right]$$

Dual

$$\eta^*, \beta^* = \arg \max_{\eta, \beta: \eta_u \geq 0} \left[\min_{\omega} \mathcal{L}(\omega, \eta, \beta) \right]$$

Forma dual de la SVM

2. Lagrangiana generalizada (ejemplo)



$$f(\omega) = \omega^2 + 1; g(\omega) = 1 - \omega \leq 0$$

Forma dual de la SVM

2. Lagrangiana generalizada (ejemplo)


$$\mathcal{L}(\omega, \eta, \beta) \equiv f(\omega) + \sum_{u=1}^{r_g} \eta_u g_u(\omega) + \sum_{v=1}^{r_h} \beta_v h_v(\omega)$$

$$f(\omega) = \omega^2 + 1; g(\omega) = 1 - \omega \leq 0$$

$$\mathcal{L}(\omega, \eta) = (\omega^2 + 1) + \eta(1 - \omega)$$

Forma dual de la SVM

2. Lagrangiana generalizada (ejemplo)




$$\theta_P(\omega) \equiv \max_{\eta: \eta_u \geq 0} \mathcal{L}(\omega, \eta)$$

$$\theta_D(\eta) \equiv \min_{\omega} \mathcal{L}(\omega, \eta)$$

$$\mathcal{L}(\omega, \eta) = (\omega^2 + 1) + \eta(1 - \omega)$$

Forma dual de la SVM

2. Lagrangiana generalizada (ejemplo)



$$\theta_P^* \equiv \min_{\omega} \theta_P(\omega)$$


$$\omega^* \equiv \arg \min_{\omega} \theta_P(\omega)$$

$$\theta_D^* \equiv \max_{\eta: \eta_u \geq 0} \theta_D(\eta)$$

$$\eta^* \equiv \arg \max_{\eta: \eta_u \geq 0} \theta_D(\eta)$$

Forma dual de la SVM


2. Lagrangiana generalizada (ejemplo)



$$f(\omega) = \omega^4 - 5\omega^2 + 3\omega; g(\omega) = 1 - \omega \leq 0$$

Forma dual de la SVM

2. Lagrangiana generalizada (ejemplo)




$$\theta_P(\omega) \equiv \max_{\eta: \eta_u \geq 0} \mathcal{L}(\omega, \eta)$$

$$\theta_D(\eta) \equiv \min_{\omega} \mathcal{L}(\omega, \eta)$$

Forma dual de la SVM

2. Lagrangiana generalizada (ejemplo)



$$\theta_P^* \equiv \min_{\omega} \theta_P(\omega)$$

$$\omega^* \equiv \arg \min_{\omega} \theta_P(\omega)$$

$$\theta_D^* \equiv \max_{\eta: \eta_u \geq 0} \theta_D(\eta)$$

$$\eta \equiv \arg \max_{\eta: \eta_u \geq 0} \theta_D(\eta)$$

Forma dual de la SVM

2. Lagrangiana generalizada (cont.)

Karush-Kuhn-Tucker (KKT) conditions

Duality gap nulo

$$1. \frac{\partial}{\partial \omega_j} \mathcal{L}(\omega^*, \eta^*, \beta^*) = 0, \forall j = 1, \dots, p$$

$$2. \frac{\partial}{\partial \beta_v} \mathcal{L}(\omega^*, \eta^*, \beta^*) = 0, \forall v = 1, \dots, r_h$$

Mismas condiciones que la Lagrangiana no generalizada (restricciones con igualdades)

Forma dual de la SVM

2. Lagrangiana generalizada (cont.)

Karush-Kuhn-Tucker (KKT) conditions

$$3. g_u(\omega^*) \leq 0, \forall u = 1, \dots, r_g$$

Se cumplen las restricciones con inecuaciones

$$4. \eta_u^* \geq 0, \forall u = 1, \dots, r_g$$

Los multiplicadores de Lagrange de las inecuaciones son positivos

$$5. \eta_u^* g_u(\omega^*) = 0, \forall u = 1, \dots, r_g$$

Cuando una inecuación se cumple sin igualdad su multiplicador de Lagrange es nulo

Forma dual de la SVM

2. Lagrangiana generalizada (cont.)

$$\mathcal{L}(\omega, \eta, \beta) \equiv f(\omega) + \sum_{u=1}^{r_g} \eta_u g_u(\omega) + \sum_{v=1}^{r_h} \beta_v h_v(\omega)$$

$$f(w, \xi) = \frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^n \xi^{(i)}$$

$$g_i(w, b, \xi): \begin{cases} g_1^{(i)}: 1 - y^{(i)}(x^{(i)} w^T + b) - \xi^{(i)} \leq 0, \forall i = 1, \dots, n \\ g_2^{(i)}: -\xi^{(i)} \leq 0, \forall i = 1, \dots, n \end{cases}$$

$$h_v(\omega): 0$$

$$\omega: (w, b, \xi)$$

Forma dual de la SVM

2. Lagrangiana generalizada (cont.)

$$\mathcal{L}(w, b, \xi, \alpha, \gamma) = \frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^n \xi^{(i)} + \sum_{i=1}^n \alpha^{(i)} (1 - y^{(i)} (x^{(i)} w^T + b) - \xi^{(i)}) + \sum_{i=1}^n \gamma^{(i)} (-\xi^{(i)})$$

$$\alpha^{(i)} \equiv \eta_u, u = 1, \dots, n$$

$$\gamma^{(i)} \equiv \eta_u, u = n + 1, \dots, 2n$$

$$\alpha^{(i)} \geq 0; \gamma^{(i)} \geq 0$$

Forma dual de la SVM

2. Lagrangiana generalizada (cont.)

Primal

$$w^*, b^*, \xi^* = \arg \min_{w, b, \xi} \left[\max_{\alpha, \gamma: \alpha^{(i)} \geq 0, \gamma^{(i)} \geq 0} \mathcal{L}(w, b, \xi, \alpha, \gamma) \right]$$

Dual

$$\eta^*, \beta^* = \arg \max_{\alpha, \gamma: \alpha^{(i)} \geq 0, \gamma^{(i)} \geq 0} \left[\min_{w, b, \xi} \mathcal{L}(w, b, \xi, \alpha, \gamma) \right]$$

Forma dual de la SVM

2. Lagrangiana generalizada (cont.)

Karush-Kuhn-Tucker (KKT) conditions

$$1. \frac{\partial}{\partial \omega_k} \mathcal{L}(\omega^*, \eta^*, \beta^*) = 0, \forall k = 1, \dots, p$$

$$1. a. \frac{\partial}{\partial w_j} \mathcal{L}(w, b, \xi, \alpha, \gamma) = 0, \forall j = 1, \dots, d$$

$$1. b. \frac{\partial}{\partial b} \mathcal{L}(w, b, \xi, \alpha, \gamma) = 0$$

$$1. c. \frac{\partial}{\partial \xi^{(i)}} \mathcal{L}(w, b, \xi, \alpha, \gamma) = 0, \forall i = 1, \dots, n$$

Forma dual de la SVM

2. Lagrangiana generalizada (cont.)

Karush-Kuhn-Tucker (KKT) conditions

$$2. \frac{\partial}{\partial \beta_v} \mathcal{L}(\omega^*, \eta^*, \beta^*) = 0, \forall v = 1, \dots, r_h$$

No aplica

$$3. g_u(\omega^*) \leq 0, \forall u = 1, \dots, r_g$$

$$3. a. 1 - y^{(i)}(x^{(i)} w^{*T} + b^*) - \xi^{*(i)} \leq 0, \forall i = 1, \dots, n$$

$$3. b. -\xi^{*(i)} \leq 0, \forall i = 1, \dots, n$$

Forma dual de la SVM

2. Lagrangiana generalizada (cont.)

Karush-Kuhn-Tucker (KKT) conditions

$$4. \eta_u^* \geq 0, \forall u = 1, \dots, r_g$$

$$4. a. \alpha^{*(i)} \geq 0, \forall i = 1, \dots, n$$

$$4. b. \gamma^{*(i)} \geq 0, \forall i = 1, \dots, n$$

$$5. \eta_u^* g_u(\omega^*) = 0, \forall u = 1, \dots, r_g$$

$$5. a. \alpha^{*(i)} \left[1 - y^{(i)} (x^{(i)} w^{*T} + b^*) - \xi^{*(i)} \right] = 0, \forall i = 1, \dots, n$$

$$5. b. \gamma^{*(i)} \xi^{*(i)} = 0, \forall i = 1, \dots, n$$

Forma dual de la optimización

- Forma dual de la regresión
- **Forma dual de la SVM**
 - Problema primal
 - Lagrangiana generalizada
 - **Optimización de la Lagrangiana con respecto a ξ**
 - Optimización de la Lagrangiana con respecto a b
 - Optimización primal de la Lagrangiana
 - Optimización dual de la Lagrangiana
 - Predicción ante nuevos datos

Forma dual de la SVM

3. Optimización de la Lagrangiana con respecto a ξ

$$\mathcal{L}(w, b, \xi, \alpha, \gamma) = \frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^n \xi^{(i)} + \sum_{i=1}^n \alpha^{(i)} (1 - y^{(i)} (x^{(i)} w^T + b) - \xi^{(i)}) + \sum_{i=1}^n \gamma^{(i)} (-\xi^{(i)})$$

$$\frac{\partial \mathcal{L}(w, b, \xi, \alpha, \gamma)}{\partial \xi^{(i)}} = C - \alpha^{(i)} - \gamma^{(i)} = 0$$

$$\gamma^{(i)} = C - \alpha^{(i)}$$

$$\alpha^{(i)} \geq 0; \gamma^{(i)} \geq 0 \Rightarrow 0 \leq \alpha^{(i)} \leq C$$

Forma dual de la SVM

3. Optimización de la Lagrangiana con respecto a ξ (cont.)

$$\mathcal{L}(w, b, \xi, \alpha) = \frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^n \xi^{(i)} + \sum_{i=1}^n \alpha^{(i)} (1 - y^{(i)} (x^{(i)} w^T + b) - \xi^{(i)}) - \sum_{i=1}^n (C - \alpha^{(i)}) \xi^{(i)}$$

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} \sum_{j=1}^d w_j^2 + \sum_{i=1}^n \alpha^{(i)} (1 - y^{(i)} (x^{(i)} w^T + b))$$

$$\text{s.t.: } \xi^{(i)} = \max \left(0, 1 - y^{(i)} (x^{(i)} w^T + b) \right) \geq 0;$$

$$0 \leq \alpha^{(i)} \leq C$$

Forma dual de la optimización

- Forma dual de la regresión
- **Forma dual de la SVM**
 - Problema primal
 - Lagrangiana generalizada
 - Optimización de la Lagrangiana con respecto a ξ
 - **Optimización de la Lagrangiana con respecto a b**
 - Optimización primal de la Lagrangiana
 - Optimización dual de la Lagrangiana
 - Predicción ante nuevos datos

Forma dual de la SVM

3. Optimización de la Lagrangiana con respecto a b

$$\frac{\partial \mathcal{L}(w, b, \alpha)}{\partial b} = - \sum_{i=1}^n \alpha^{(i)} y^{(i)} = 0$$

$$\begin{aligned} \mathcal{L}(w, b, \alpha) = & \frac{1}{2} \sum_{j=1}^d w_j^2 + \sum_{i=1}^n \alpha^{(i)} (1 - y^{(i)} x^{(i)} w^T) \\ & - b \sum_{i=1}^n \alpha^{(i)} y^{(i)} \end{aligned}$$

Forma dual de la SVM

3. Optimización de la Lagrangiana con respecto a b (cont.)

$$\mathcal{L}(w, \alpha) = \frac{1}{2} \sum_{j=1}^d w_j^2 + \sum_{i=1}^n \alpha^{(i)} (1 - y^{(i)} x^{(i)} w^T)$$

$$\text{s.t.: } \xi^{(i)} = \max \left(0, 1 - y^{(i)} (x^{(i)} w^T + b) \right) \geq 0;$$

$$0 \leq \alpha^{(i)} \leq C; \sum_{i=1}^n \alpha^{(i)} y^{(i)} = 0$$

Forma dual de la optimización

- Forma dual de la regresión
- **Forma dual de la SVM**
 - Problema primal
 - Lagrangiana generalizada
 - Optimización de la Lagrangiana con respecto a ξ
 - Optimización de la Lagrangiana con respecto a b
 - **Optimización primal de la Lagrangiana**
 - Optimización dual de la Lagrangiana

Forma dual de la SVM

4. Optimización primal de la Lagrangiana

$$w^* = \arg \min_w \left[\max_{\alpha: \alpha^{(i)} \geq 0} \mathcal{L}(w, \alpha) \right]$$

$$w^* = \arg \min_w [\theta_P(w)]$$

$$\theta_P(w) \equiv \max_{\alpha: \alpha^{(i)} \geq 0} \mathcal{L}(w, \alpha)$$

$$\mathcal{L}(w, \alpha) = \frac{1}{2} \sum_{j=1}^d w_j^2 + \sum_{i=1}^n \alpha^{(i)} (1 - y^{(i)} x^{(i)} w^T)$$

$$\text{s.t.: } \max \left(0, 1 - y^{(i)} (x^{(i)} w^T + b) \right) \geq 0;$$

$$0 \leq \alpha^{(i)} \leq C; \sum_{i=1}^n \alpha^{(i)} y^{(i)} = 0$$

Forma dual de la SVM

4. Optimización primal de la Lagrangiana (cont.)

Objetivo: a partir de $\nabla_{\alpha} \mathcal{L}(w, \alpha) = 0$

1. Obtener $\alpha^* = \alpha(w)$
2. Obtener $\theta_P(w) = \mathcal{L}(w, \alpha^*) = \mathcal{L}(w, \alpha(w))$
3. Minimizar $\theta_P(w)$

$$\frac{\partial \mathcal{L}(w, \alpha)}{\partial \alpha^{(i)}} = 1 - y^{(i)} x^{(i)} w^T = 0$$

No permite obtener $\alpha^* = \alpha(w)$

Alternativa: Solución numérica del primal reducido

$$w^* = \arg \min_w \left[\max_{\alpha: \alpha^{(i)} \geq 0} \mathcal{L}(w, \alpha) \right]$$

Forma dual de la optimización

- Forma dual de la regresión
- **Forma dual de la SVM**
 - Problema primal
 - Lagrangiana generalizada
 - Optimización de la Lagrangiana con respecto a ξ
 - Optimización de la Lagrangiana con respecto a b
 - Optimización primal de la Lagrangiana
 - **Optimización dual de la Lagrangiana**
 - Predicción ante nuevos datos

Forma dual de la SVM

5. Optimización dual de la Lagrangiana

$$\alpha^* = \arg \max_{\alpha: \alpha^{(i)} \geq 0} \left[\min_w \mathcal{L}(w, \alpha) \right]$$

$$\alpha^* = \max_{\alpha: \alpha^{(i)} \geq 0} [\theta_D(\alpha)]$$

$$\theta_D(\alpha) \equiv \min_w \mathcal{L}(w, \alpha)$$

$$\mathcal{L}(w, \alpha) = \frac{1}{2} \sum_{j=1}^d w_j^2 + \sum_{i=1}^n \alpha^{(i)} (1 - y^{(i)} x^{(i)} w^T)$$

$$\text{s.t.: } \max \left(0, 1 - y^{(i)} (x^{(i)} w^T + b) \right) \geq 0;$$

$$0 \leq \alpha^{(i)} \leq C; \sum_{i=1}^n \alpha^{(i)} y^{(i)} = 0$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

Objetivo: a partir de $\nabla_w \mathcal{L}(w, \alpha) = 0$

1. Obtener $w^* = w(\alpha)$
2. Obtener $\theta_D(\alpha) = \mathcal{L}(w^*, \alpha) = \mathcal{L}(w(\alpha), \alpha)$
3. Maximizar $\theta_D(\alpha)$

$$\mathcal{L}(w, \alpha) = \frac{1}{2} \sum_{j=1}^d w_j^2 + \sum_{i=1}^n \alpha^{(i)} (1 - y^{(i)} x^{(i)} w^T)$$

$$\mathcal{L}(w, \alpha) = \frac{1}{2} \sum_{j=1}^d w_j^2 + \sum_{i=1}^n \alpha^{(i)} - \sum_{i=1}^n \alpha^{(i)} \sum_{j=1}^d y^{(i)} x_j^{(i)} w_j$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$\mathcal{L}(w, \alpha) = \frac{1}{2} \sum_{j=1}^d w_j^2 + \sum_{i=1}^n \alpha^{(i)} - \sum_{i=1}^n \alpha^{(i)} \sum_{j=1}^d y^{(i)} x_j^{(i)} w_j$$

$$\frac{\partial \mathcal{L}(w, \alpha)}{\partial w_j} = w_j - \sum_{i=1}^n \alpha^{(i)} y^{(i)} x_j^{(i)} = 0$$

$$w_j^* = w_j(\alpha^*) = \sum_{i=1}^n \alpha^{*(i)} y^{(i)} x_j^{(i)}$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$\mu^{(i)} \equiv \alpha^{(i)} y^{(i)}; \quad \mu \equiv \begin{bmatrix} \mu^{(1)} \\ \mu^{(2)} \\ \vdots \\ \mu^{(n)} \end{bmatrix}$$

$$w_j^* = \sum_{i=1}^n \alpha^{(i)} y^{(i)} x_j^{(i)} = \sum_{i=1}^n \mu^{(i)} x_j^{(i)}$$

$$w_j^* = \mu^T X$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$\theta_D(\alpha) = \mathcal{L}(w^*, \alpha) = \mathcal{L}(w^*(\alpha), \alpha)$$

$$\mathcal{L}(w, \alpha) = \frac{1}{2} \sum_{j=1}^d w_j^2 + \sum_{i=1}^n \alpha^{(i)} - \sum_{i=1}^n \alpha^{(i)} \sum_{j=1}^d y^{(i)} x_j^{(i)} w_j$$

$$\theta_D(\alpha) = \frac{1}{2} \sum_{j=1}^d w_j^{*2} + \sum_{i=1}^n \alpha^{(i)} - \sum_{i=1}^n \alpha^{(i)} \sum_{j=1}^d y^{(i)} x_j^{(i)} w_j^*$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$w_j^* = \sum_{i=1}^n \alpha^{(i)} y^{(i)} x_j^{(i)}$$

$$\frac{1}{2} \sum_{j=1}^d w_j^{*2} = \frac{1}{2} \sum_{j=1}^d \left[\left(\sum_{i=1}^n \alpha^{(i)} y^{(i)} x_j^{(i)} \right) \left(\sum_{i=1}^n \alpha^{(i)} y^{(i)} x_j^{(i)} \right) \right]$$

$$\frac{1}{2} \sum_{j=1}^d w_j^{*2} = \frac{1}{2} \sum_{j=1}^d \left[\sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} \alpha^{(s)} y^{(r)} y^{(s)} x_j^{(r)} x_j^{(s)} \right]$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$\frac{1}{2} \sum_{j=1}^d w_j^{*2} = \frac{1}{2} \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} \alpha^{(s)} y^{(r)} y^{(s)} \sum_{j=1}^d x_j^{(r)} x_j^{(s)}$$

$$\frac{1}{2} \sum_{j=1}^d w_j^{*2} = \frac{1}{2} \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} \alpha^{(s)} y^{(r)} y^{(s)} \left\langle x_j^{(r)} x_j^{(s)} \right\rangle$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$\psi \equiv \sum_{i=1}^n \alpha^{(i)} \sum_{j=1}^d y^{(i)} x_j^{(i)} w_j^* \qquad w_j^* = \sum_{i=1}^n \alpha^{(i)} y^{(i)} x_j^{(i)}$$

$$\psi = \sum_{i=1}^n \alpha^{(i)} y^{(i)} \sum_{j=1}^d x_j^{(i)} \left(\sum_{k=1}^n \alpha^{(k)} y^{(k)} x_j^{(k)} \right)$$

$$\psi = \sum_{i=1}^n \alpha^{(i)} y^{(i)} \left(\sum_{k=1}^n \sum_{j=1}^d \alpha^{(k)} y^{(k)} x_j^{(i)} x_j^{(k)} \right)$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$\psi = \sum_{i=1}^n \alpha^{(i)} y^{(i)} \left(\sum_{k=1}^n \alpha^{(k)} y^{(k)} \langle x^{(i)} x^{(k)} \rangle \right)$$

$$\psi = \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} y^{(r)} \alpha^{(s)} y^{(s)} \langle x^{(r)} x^{(s)} \rangle$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$\theta_D(\alpha) = \frac{1}{2} \sum_{j=1}^d w_j^{*2} + \sum_{i=1}^n \alpha^{(i)} - \sum_{i=1}^n \alpha^{(i)} \sum_{j=1}^d y^{(i)} x_j^{(i)} w_j^*$$

$$\frac{1}{2} \sum_{j=1}^d w_j^{*2} = \frac{1}{2} \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} \alpha^{(s)} y^{(r)} y^{(s)} \left\langle x_j^{(r)} x_j^{(s)} \right\rangle$$

$$\psi = \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} y^{(r)} \alpha^{(s)} y^{(s)} \langle x^{(r)} x^{(s)} \rangle$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$\begin{aligned}\theta_D(\alpha) = & \frac{1}{2} \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} \alpha^{(s)} y^{(r)} y^{(s)} \left\langle x_j^{(r)} x_j^{(s)} \right\rangle \\ & + \sum_{i=1}^n \alpha^{(i)} - \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} y^{(r)} \alpha^{(s)} y^{(s)} \left\langle x^{(r)} x^{(s)} \right\rangle\end{aligned}$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$\theta_D(\alpha) = \sum_{i=1}^n \alpha^{(i)} - \frac{1}{2} \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} y^{(r)} \alpha^{(s)} y^{(s)} \langle x^{(r)} x^{(s)} \rangle$$

$$\text{s.t.: } \max \left(0, 1 - y^{(i)} (x^{(i)} w^T + b) \right) \geq 0;$$

$$0 \leq \alpha^{(i)} \leq C; \sum_{i=1}^n \alpha^{(i)} y^{(i)} = 0$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$\theta_D(\alpha) = \sum_{i=1}^n \alpha^{(i)} - \frac{1}{2} \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} y^{(r)} \alpha^{(s)} y^{(s)} \langle x^{(r)} x^{(s)} \rangle$$

Depende del **producto escalar** de los pares de datos

$$\alpha^* = \arg \max_{\alpha: \alpha_k \geq 0} [\theta_D(\alpha)]$$

$$w_j^* = \sum_{i=1}^n \alpha^{*(i)} y^{(i)} x_j^{(i)}$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

Obtención de b^*

$$\text{Vimos que, } \forall i : \begin{cases} 0 \leq \alpha^{(i)} \leq C \\ \gamma^{(i)} = C - \alpha^{(i)} \end{cases}$$

Consideremos el conjunto $\mathcal{S} \equiv \{x^{(i)}\} : 0 < \alpha^{(i)} < C$

$$\forall s \in \mathcal{S} : \gamma^{(s)} = C - \alpha^{(s)} > 0$$

$$\text{De la KKT 5. b.: } \gamma^{*(s)} \xi^{*(s)} = 0 \Rightarrow \xi^{*(s)} = 0$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

De la KKT 5. a.: $\alpha^{*(i)} \left[1 - y^{(i)} (x^{(i)} w^{*T} + b^*) - \xi^{*(i)} \right] = 0$

$$\forall s \in \mathcal{S}: \begin{cases} \alpha^{*(s)} > 0 \\ \xi^{*(s)} = 0 \end{cases} \Rightarrow 1 - y^{(s)} (x^{(s)} w^{*T} + b^*) = 0$$

$$x^{(s)} w^{*T} + b^* = \frac{1}{y^{(s)}} = y^{(s)}$$

$$b^* = y^{(s)} - x^{(s)} w^{*T}$$

Mejora
numérica:

$$b^* = \frac{1}{n_{\mathcal{S}}} \sum_{s \in \mathcal{S}} y^{(s)} - x^{(s)} w^{*T}$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$x^{[k]} w^{*T} = \sum_{j=1}^d x_j^{[k]} w_j^*$$

$$w_j^* = \sum_{i=1}^n \alpha^{*(i)} y^{(i)} x_j^{(i)}$$

$$x^{[k]} w^{*T} = \sum_{j=1}^d x_j^{[k]} \sum_{i=1}^n \alpha^{*(i)} y^{(i)} x_j^{(i)}$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$x^{[k]} w^{*T} = \sum_{i=1}^n \alpha^{*(i)} y^{(i)} \sum_{j=1}^d x_j^{[k]} x_j^{(i)}$$

$$x^{[k]} w^{*T} = \sum_{i=1}^n \alpha^{*(i)} y^{(i)} \langle x^{(k)} x^{(i)} \rangle$$


$$b^* = \frac{1}{n_S} \sum_{s \in \mathcal{S}} \left(y^{(s)} - \sum_{i=1}^n \alpha^{*(i)} y^{(i)} \langle x^{(s)} x^{(i)} \rangle \right)$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

Por la KKT 5.b ($\xi \cdot \gamma = 0$)

para $y = 1$:

$$\longrightarrow \xi > 0; \gamma = 0; \alpha = C \quad \xi = 0; \gamma > 0; \alpha < C; 0 \leq \alpha < C$$


Por la KKT 5.a

$$g_1 \cdot \alpha = 0$$

para $y = 1$:


$$\begin{aligned} g_1 &< 0 \\ \alpha &= 0 \\ y &= 1 \end{aligned}$$

$$g_1^{(i)}(w): 1 - y^{(i)}(x^{(i)}w^T + b) - \xi^{(i)} \leq 0$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$$C = 1$$



$$b^* = -22.6$$

$$w_1^* = 0.225$$


$$w_2^* = 0.227$$

$$\alpha^* = \arg \max_{\alpha: \alpha_k \geq 0} [\theta_D(\alpha)]$$

Forma dual de la SVM

5. Optimización dual de la Lagrangiana (cont.)

$C = 1$



$$\alpha^* = \arg \max_{\alpha: \alpha_k \geq 0} [\theta_D(\alpha)]$$

Forma dual de la optimización

- Forma dual de la regresión
- **Forma dual de la SVM**
 - Problema primal
 - Lagrangiana generalizada
 - Optimización de la Lagrangiana con respecto a ξ
 - Optimización de la Lagrangiana con respecto a b
 - Optimización primal de la Lagrangiana
 - Optimización dual de la Lagrangiana
 - **Predicción ante nuevos datos**

Forma dual de la SVM

6. Predicción ante nuevos datos

$$y^{[r]} = \text{sign}(x^{[r]}w^{*T} + b^*)$$

$$x^{[r]}w^{*T} = \sum_{i=1}^n \alpha^{*(i)} y^{(i)} \langle x^{(r)} x^{(i)} \rangle$$

$$b^* = \frac{1}{n_{\mathcal{S}}} \sum_{s \in \mathcal{S}} \left(y^{(s)} - \sum_{i=1}^n \alpha^{*(i)} y^{(i)} \langle x^{(s)} x^{(i)} \rangle \right)$$

Forma dual de la SVM

6. Predicción ante nuevos datos (resumen)

Problema primal

$$w^* = \arg \min_w \left[\max_{\alpha: \alpha^{(i)} \geq 0} \left\{ \frac{1}{2} \sum_{j=1}^d w_j^2 + \sum_{i=1}^n \alpha^{(i)} \left(1 - y^{(i)} \sum_{j=1}^d x_j^{[i]} w_j \right) \right\} \right]$$

$$O(n \times d)$$

$$y^{[t]} = \text{sign} \left(\left(\sum_{j=1}^d x_j^{[t]} w_j^* \right) + b^* \right)$$

$$O(d)$$

Forma dual de la SVM

6. Predicción ante nuevos datos (resumen)

Problema dual

$$\alpha^* = \arg \max_{\alpha: \alpha^{(i)} \geq 0} \left[\sum_{i=1}^n \alpha^{(i)} - \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} y^{(r)} \alpha^{(s)} y^{(s)} \langle x^{(r)} x^{(s)} \rangle \right]$$

$$\sim O(n^2)$$

n_s : Número de vectores soporte ($\alpha^{*(i)} \neq 0$)

$$n_s \ll n$$

Forma dual de la SVM

6. Predicción ante nuevos datos

Problema dual

$$y^{[t]} = \text{sign} \left(\sum_{i=1}^n \alpha^{*(i)} y^{(i)} \langle x^{(t)} x^{(i)} \rangle + \frac{1}{n_S} \sum_{s \in \mathcal{S}} \left(y^{(s)} - \sum_{i=1}^n \alpha^{*(i)} y^{(i)} \langle x^{(s)} x^{(i)} \rangle \right) \right)$$

Conjunto de vectores soporte: $\mathcal{S} \equiv \{x^{(i)}\}: \alpha^{(i)} > 0$

$$y^{[t]} = \text{sign} \left(\sum_{s \in \mathcal{S}} \left[\alpha^{*(s)} y^{(s)} \langle x^{(t)} x^{(s)} \rangle + \frac{1}{n_S} \left(y^{(s)} - \sum_{u \in \mathcal{S}} \alpha^{*(u)} y^{(u)} \langle x^{(s)} x^{(u)} \rangle \right) \right] \right)$$

$$\sim O(n_S)$$

Forma dual de la regresión

6. Resumen

1. Formulación del problema de la regresión lineal

$$- w^* = \arg \min_w \left[\frac{1}{n} (Xw^T - y)^T (Xw^T - y) + \lambda \|w\|_2^2 \right]$$

en forma de optimización sujeta a restricciones

$$- \arg \min_{w, e} \left[a \|w\|_2^2 + \sum_{i=1}^n e^{(i)^2} \right]$$

$$\bullet \text{ s.t.: } y^{(i)} - x^{(i)} w^T - e^{(i)} = 0$$

2. Formulación del problema en forma de lagrangiana

$$- \mathcal{L}(w, e, \mu) = a \|w\|_2^2 + \sum_{i=1}^n e^{(i)^2} + \sum_{i=1}^n \mu^{(i)} [y^{(i)} - x^{(i)} w^T - e^{(i)}]$$

3. Estudio de la lagrangiana

– En el óptimo los gradientes de f (la función a optimizar) y g (las restricciones) son paralelos

– En el óptimo se cumplen las restricciones impuestas por la función g

4. Optimización primal y dual de la lagrangiana

– El vector de coeficientes óptimos duales α^* se calcula en función del producto escalar de los features $\langle x^{(i)} x^{(j)} \rangle$

Forma dual de la regresión

Resumen

Primal	Features	$x^{(i)}$
	Modelo óptimo	$w^* = y^T X C_r^{-1}$
	Predicción	$y^{[t]} = x^{[t]} w^{*T}$
Dual	Features	$g^{(i)} = x^{(i)} X^T = [\langle x^{(i)} x^{(1)} \rangle, \langle x^{(i)} x^{(2)} \rangle, \dots, \langle x^{(i)} x^{(n)} \rangle]$
	Modelo óptimo	$\alpha^* = G_r^{-1} y$
	Predicción	$y^{[t]} = g^{[t]} \alpha^*$

Forma dual de la SVM

6. Resumen

1. Formulación del problema de la SVM

$$- w^*, b^* \equiv \arg \min_{w, b} \left[\frac{1}{n} \sum_{i=1}^n \max(0, 1 - y^{(i)} z^{(i)}) + \lambda \|w\|_2^2 \right]$$

en forma de optimización sujeta a restricciones

$$- w^*, b^* = \arg \min_{w, b} \left(\frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^n \xi^{(i)} \right); \xi^{(i)} \equiv \max(0, 1 - y^{(i)} z^{(i)})$$

- s.t.: $\xi^{(i)} \geq 1 - y^{(i)} (x^{(i)} w^T + b); \xi^{(i)} \geq 0$

2. Formulación del problema en forma de lagrangiana generalizada (restricciones con inecuaciones)

$$- \mathcal{L}(w, b, \xi, \alpha, \gamma) = \frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^n \xi^{(i)} + \sum_{i=1}^n \alpha^{(i)} (1 - y^{(i)} (x^{(i)} w^T + b) - \xi^{(i)}) + \sum_{i=1}^n \gamma^{(i)} (-\xi^{(i)})$$

3. Estudio de la lagrangiana generalizada

– Concepto de gap dual y condiciones de Karush–Kuhn–Tucker

4. Optimización primal y dual de la lagrangiana

– No hay solución analítica

– El vector de coeficientes óptimos duales α^* depende de $\langle x^{(i)} x^{(j)} \rangle$

– El vector de coeficientes óptimos duales α^* es disperso (sparse)



Forma dual de la SVM

Resumen

Primal	Features	$x^{(i)}$
	Modelo óptimo	$w^*, b^* \equiv \arg \min_{w,b} \left[\frac{1}{n} \sum_{i=1}^n \max \left(0, 1 - y^{(i)} (x^{(i)} w^T + b) \right) + \lambda \ w\ _2^2 \right]$
	Predicción	$y^{[t]} = \text{sign} \left[\left(\sum_{j=1}^d x_j^{[t]} w_j^* \right) + b^* \right]$
Dual	Features	$g^{(i)} = x^{(i)} X^T = [\langle x^{(i)} x^{(1)} \rangle, \langle x^{(i)} x^{(2)} \rangle, \dots, \langle x^{(i)} x^{(n)} \rangle]$
	Modelo óptimo	$\alpha^* = \arg \max_{\alpha: \alpha^{(i)} \geq 0} \left[\sum_{i=1}^n \alpha^{(i)} - \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} y^{(r)} \alpha^{(s)} y^{(s)} \langle x^{(r)} x^{(s)} \rangle \right]$ $b^* = \frac{1}{n_S} \sum_{s \in S} \left(y^{(s)} - \sum_{i=1}^n \alpha^{*(i)} y^{(i)} \langle x^{(s)} x^{(i)} \rangle \right)$
	Predicción	$y^{[t]} = \text{sign} \left(\sum_{s \in S} \alpha^{*(s)} y^{(s)} \langle x^{[t]} x^{(s)} \rangle + b^* \right)$

Forma dual de la SVM

6. Predicción ante nuevos datos (resumen)



Tiempo de cálculo de la SVM primal: $\sim O(n \times d)$

Tiempo de cálculo de la SVM dual: $\sim O(n^2)$

Forma dual de la SVM

6. Resumen

- Ventajas de la solución dual vs. primal
 - Mayor rapidez (si el número de features es grande)
 - En la optimización cuando $d > n$
 - En la predicción cuando $d > n_s$
 - Extensión inmediata al uso de kernels
 - La solución dual depende del producto escalar de los elementos $\langle x^{(u)} x^{(v)} \rangle$
 - En el caso de la SVM
 - La solución dual es dispersa (predicción más rápida)