

Fundamentos del aprendizaje automático

(Machine learning)

Joaquín Luque

Contenido

1. Introducción
2. Regresión
 - a) Regresión univariable
 - b) Regresión multivariable
3. Clasificación
 - a) Regresión logística
 - b) Máquinas de vectores soporte (SVM)
 - Forma dual de la optimización (regresión y SVM)
 - c) **Funciones Kernel**
 - d) Clasificación multiclase
4. Segmentación
5. Reducción de dimensionalidad
6. Deep learning (introducción)

Funciones Kernel

- Similitud entre elementos
 - Funciones de base radial
 - Kernel polinómico
- Aplicaciones
 - Frontera no lineal
 - El truco Kernel

Funciones Kernel


2. Determinación de *features*

			f	φ	K	X
Rule-based systems		$y = f(X)$	Manual	-	-	Manual
Machine Learning	Basic ML	$y = f(X)$	Automatic	-	-	Manual
	Feature-based ML	$y = f[\varphi(X)]$	Automatic	Manual	-	Raw
	Kernel-based ML	$y = f[K(X)]$	Automatic	Automatic	Manual	Raw
	Deep Learning	$y = f(\varphi(X))$	Automatic	Automatic	-	Raw

Los features $\varphi(X)$ son contruidos de manera automática (no explícita) mediante el uso de funciones kernel $K(X)$ elegidas de forma manual a partir de los datos originales disponibles X


Forma dual de la optimización

Introducción



Forma dual de la optimización

Introducción



Funciones Kernel

2. Determinación de *features*

Hipótesis
(SVM)

$$\begin{cases} y^{(i)} = 1, \forall z^{(i)} = x^{(i)} w^T + b \geq 0 \\ y^{(i)} = 0, \forall z^{(i)} = x^{(i)} w^T + b < 0 \end{cases}$$

$$y^{(i)} = \frac{1 + \text{sign}(x^{(i)} w^T + b)}{2} \Rightarrow y^{(i)} \in \{0, 1\}$$

$$y^{(i)} \equiv 2y^{(i)} - 1 = \text{sign}(z^{(i)}) = \text{sign}(x^{(i)} w^T + b)$$
$$y^{(i)} \in \{-1, 1\}$$

$$x^{(i)} \equiv [x_1^{(i)} \quad x_2^{(i)} \quad \cdots \quad x_d^{(i)}] \quad w \equiv [w_1 \quad w_2 \quad \cdots \quad w_d]$$

Funciones Kernel

2. Determinación de *features*

Función de coste bisagra (hinge loss)

$$L(h_w(x^{(i)}), y^{(i)}) = \max(0, 1 - y^{(i)}(x^{(i)}w^T + b))$$

$$J(h_w(x^{(i)}), y^{(i)}) = \frac{1}{n} \sum_{i=1}^n L(h_w(x^{(i)}), y^{(i)}) + \lambda \|w\|_2^2$$

$$w^* = \arg \min_w [J(h_w(x^{(i)}), y^{(i)})]$$

Funciones Kernel

2. Determinación de *features*

Formulación con features alternativos

$$y^{(i)} = \text{sign}(\chi^{(i)} w^T + b)$$

$$L(h_w(\chi^{(i)}), y^{(i)}) = \max(0, 1 - y^{(i)}(\chi^{(i)} w^T + b))$$

$$J(h_w(\chi^{(i)}), y^{(i)}) = \frac{1}{n} \sum_{i=1}^n L(h_w(\chi^{(i)}), y^{(i)}) + \lambda \|w\|_2^2$$

$$w^* = \arg \min_w [J(h_w(\chi^{(i)}), y^{(i)})]$$

Funciones Kernel

2. Determinación de *features*

Formulación con features alternativos

$$\chi^{(i)} \equiv [\chi_1^{(i)} \quad \chi_2^{(i)} \quad \cdots \quad \chi_m^{(i)}]$$

$$\chi_j^{(i)} \equiv \text{sim}(x^{(i)}, x^{(j)}) = K(x^{(i)}, x^{(j)})$$

K : Función Kernel

$$K(x^{(i)}, x^{(j)}) = \langle \varphi(x^{(i)}), \varphi(x^{(j)}) \rangle$$


φ : Función de mapeo

Funciones Kernel

- Similitud entre elementos
 - Funciones de base radial
 - Kernel polinómico
- Aplicaciones
 - Frontera no lineal
 - El truco Kernel

Funciones Kernel


2. Determinación de *features*



Ejemplo de similitud: distancia entre puntos
Función de base radial (RBF)

Funciones Kernel


2. Determinación de *features*



Ejemplo de similitud: distancia entre puntos
Normalizado

Funciones Kernel

2. Determinación de *features*




$$d^{(i,j)} \equiv x^{(i)} - x^{(j)}$$

$$\text{sim}(x^{(i)}, x^{(j)}) = K(x^{(i)}, x^{(j)}) = K(d^{(i,j)}) = K(\|x^{(i)} - x^{(j)}\|)$$

Funciones Kernel


2. Determinación de *features*



$$K(x^{(i)}, x^{(j)}) = \max\left(0, 1 - \frac{\|x^{(i)} - x^{(j)}\|}{c}\right)$$

Funciones Kernel



2. Determinación de *features*



$$K(x^{(i)}, x^{(j)}) = \max\left(0, 1 - \frac{\|x^{(i)} - x^{(j)}\|}{c}\right)$$

Funciones Kernel


2. Determinación de *features*



$$K(x^{(i)}, x^{(j)}) = \max\left(0, 1 - \frac{\|x^{(i)} - x^{(j)}\|}{c}\right)$$

Funciones Kernel


2. Determinación de *features*



$$K(x^{(i)}, x^{(j)}) = \max\left(0, 1 - \frac{\|x^{(i)} - x^{(j)}\|}{c}\right)$$

Funciones Kernel


2. Determinación de *features*



$$K(x^{(i)}, x^{(j)}) = e^{-\frac{\|x^{(i)} - x^{(j)}\|^2}{2\sigma^2}}$$

Funciones Kernel


2. Determinación de *features*



$$K(x^{(i)}, x^{(j)}) = e^{-\frac{\|x^{(i)} - x^{(j)}\|^2}{2\sigma^2}}$$

Funciones Kernel


2. Determinación de *features*



$$K(x^{(i)}, x^{(j)}) = e^{-\frac{\|x^{(i)} - x^{(j)}\|^2}{2\sigma^2}}$$

Funciones Kernel

2. Determinación de *features*





$$K(x^{(i)}, x^{(j)}) = e^{-\frac{\|x^{(i)} - x^{(j)}\|^2}{2\sigma^2}}$$

Funciones Kernel

2. Determinación de *features*

$$\sigma = 0.5$$




$$K(x^{(i)}, x^{(4)}) = e^{-\frac{\|x^{(i)} - x^{(4)}\|^2}{2\sigma^2}}$$

Funciones Kernel

2. Determinación de *features*

- | | |
|----------------------------|----------------------------|
| ● $x^{(4)} = (-1.8, -1.4)$ | ● $x^{(2)} = (-0.4, -1.1)$ |
| ● $x^{(11)} = (-0.6, 1.3)$ | ● $x^{(15)} = (1.0, 0.8)$ |




$$\sigma = 0.5$$

$$K(x^{(i)}, x^{(j)}) = e^{-\frac{\|x^{(i)} - x^{(j)}\|^2}{2\sigma^2}}$$

Funciones Kernel

2. Determinación de *features*



$$\sigma = 0.5$$

$$K(x^{(i)}, x^{(j)}) = e^{-\frac{\|x^{(i)} - x^{(j)}\|^2}{2\sigma^2}}$$

Funciones Kernel

2. Determinación de *features*

Cliente	Ingresos (m€) $x_1^{(i)}$	Edad (años) $x_2^{(i)}$	Vehículo $y^{(i)}$
1	97.17	26.6	S
2	44.67	32.3	N
3	46.64	26.7	N
4	33.84	23.7	N
5	79.35	27.0	S
⋮	⋮	⋮	⋮

Funciones Kernel

Gaussiana

2. Determinación de *features*

$$\sigma = 1$$
[illegible]

Funciones Kernel

2. Determinación de *features*

Formulación con features alternativos

$$y^{(i)} = h_w(\chi^{(i)}) = \text{sign}(\chi^{(i)} w^T + b)$$


$$L(h_w(\chi^{(i)}), y^{(i)}) = \max(0, 1 - y^{(i)}(\chi^{(i)} w^T + b))$$

$$J(h_w(\chi^{(i)}), y^{(i)}) = \frac{1}{n} \sum_{i=1}^n L(h_w(\chi^{(i)}), y^{(i)}) + \lambda \|w\|_2^2$$

$$w^* = \arg \min_w [J(h_w(\chi^{(i)}), y^{(i)})]$$

Funciones Kernel


5. Optimización del coste



$$w^* = \arg \min_w [J(h_w(\chi^{(i)}), y^{(i)})]$$

Funciones Kernel

3. Formulación de hipótesis



Funciones Kernel

6. Evaluación del resultado

Matriz de confusión

		Clase calculada		Elementos
		<i>P</i>	<i>N</i>	
Clase real	<i>P</i>	398	38	436
	<i>N</i>	151	398	549
Estimaciones		549	436	985

$$n_{train} = 15$$

Funciones Kernel


6. Evaluación del resultado

Nombre	Acrónimo	Expresión	Valor
Sensitivity	SNS	$\frac{TP}{TP + FN}$	0.9128
Specificity	SPC	$\frac{TN}{TN + FP}$	0.7250
Precision	PRC	$\frac{TP}{TP + FP}$	0.7250
Negative Predictive Value	NPV	$\frac{TN}{TN + FN}$	0.9128
Accuracy	ACC	$\frac{TP + TN}{TP + TN + FP + FN}$	0.8081
F ₁ Score	F ₁	$2 \frac{SNS \cdot PRC}{SNS + PRC}$	0.8081
Geometric Mean	GM	$\sqrt{SNS \cdot SPC}$	0.8135

$$n_{train} = 15$$

Funciones Kernel

6. Evaluación del resultado




Curva de aprendizaje
Accuracy

Funciones Kernel

- Similitud entre elementos
 - Funciones de base radial
 - Kernel polinómico
- Aplicaciones
 - Frontera no lineal
 - El truco Kernel

Funciones Kernel

2. Determinación de *features*



Ejemplo de similitud: Producto escalar
Normalizado

Funciones Kernel

2. Determinación de *features*

$$d^{(i,j)} \equiv \langle x^{(i)}, x^{(j)} \rangle = x^{(i)T} x^{(j)}$$

$$\text{sim}(x^{(i)}, x^{(j)}) = K(x^{(i)}, x^{(j)}) = K(d^{(i,j)})$$

$$\text{sim}(x^{(i)}, x^{(j)}) = K(\langle x^{(i)}, x^{(j)} \rangle)$$



Kernel polinómico

$$\text{sim}(x^{(i)}, x^{(j)}) = (\langle x^{(i)}, x^{(j)} \rangle + c)^r = (x^{(i)T} x^{(j)} + c)^r$$

Funciones Kernel

2. Determinación de *features*


$$c = 0, r = 1$$



$$K(x^{(i)}, x^{(j)}) = \left(x^{(i)T} x^{(j)} + c \right)^r$$

Funciones Kernel


2. Determinación de *features*



$$K(x^{(i)}, x^{(j)}) = \left(x^{(i)T} x^{(j)} + c \right)^r$$

Funciones Kernel

2. Determinación de *features*




$c = \text{variable}$
 $r = 2$

$$K(x^{(i)}, x^{(j)}) = \left(x^{(i)T} x^{(j)} + c \right)^r$$


Funciones Kernel

5. Optimización del coste

$c = 0, r = 1$



$c = 5, r = 2$




$$K(x^{(i)}, x^{(j)}) = \left(x^{(i)T} x^{(j)} + c \right)^r$$


Funciones Kernel

6. Evaluación del resultado

$$c = 0, r = 1$$



$$c = 5, r = 2$$




Curva de aprendizaje
Accuracy

Funciones Kernel

- Similitud entre elementos
 - Funciones de base radial
 - Kernel polinómico
- Aplicaciones
 - Frontera no lineal
 - El truco Kernel


Funciones Kernel

3. Formulación de hipótesis



Funciones Kernel

5. Optimización del coste



$$w_0^* = -52.1$$

$$w_1^* = -0.019$$


$$w_2^* = 0.920$$

$$m^* = 0.920$$

Gradient Descent

Funciones Kernel

3. Formulación de hipótesis



$$w_0^* = -52.1$$

$$w_1^* = -0.019$$

$$w_2^* = 0.920$$

$$m^* = 0.920$$


Frontera

$$r_f: x_{2b} = \frac{-w_1}{w_2} x_{1b} + \frac{-w_0}{w_2}$$

$$m = \frac{1}{\sqrt{w_1^2 + w_2^2}}$$

Funciones Kernel

3. Formulación de hipótesis



Funciones Kernel

3. Formulación de hipótesis

Kernel lineal

$$K(u, v) \equiv \langle u, v \rangle + c = u^T v + c$$

$$u \equiv [u_1 \quad u_2 \quad \cdots \quad u_d]; \quad v \equiv [v_1 \quad v_2 \quad \cdots \quad v_d]$$

$$K(u, v) = u_1 v_1 + u_2 v_2 + \cdots + u_d v_d + c$$

$$\begin{aligned} \varphi(u) &\equiv [u_1 \quad u_2 \quad \cdots \quad u_d \quad \sqrt{c}] \\ \varphi(v) &\equiv [v_1 \quad v_2 \quad \cdots \quad v_d \quad \sqrt{c}] \end{aligned}$$

$$K(u, v) = \langle \varphi(u), \varphi(v) \rangle$$

$$\varphi(x) = x, \forall c = 0$$

Proyección
de u sobre v

Funciones Kernel

3. Formulación de hipótesis

Kernel cuadrático

$$K(u, v) \equiv (\langle u, v \rangle + c)^2 = (u^T v + c)^2$$

$$u \equiv [u_1 \quad u_2]; \quad v \equiv [v_1 \quad v_2]$$

$$K(u, v) = (u_1 v_1 + u_2 v_2 + c)^2$$

$$K(u, v) = u_1^2 v_1^2 + u_2^2 v_2^2 + c^2 + \\ 2u_1 v_1 u_2 v_2 + 2u_1 v_1 c + 2u_2 v_2 c$$

Funciones Kernel

3. Formulación de hipótesis

Kernel cuadrático

$$K(u, v) = u_1^2 v_1^2 + u_2^2 v_2^2 + c^2 + 2u_1 v_1 u_2 v_2 + 2u_1 v_1 c + 2u_2 v_2 c$$

$$\begin{aligned}\varphi(u) &\equiv [u_1^2 & u_2^2 & \sqrt{2}u_1 u_2 & \sqrt{2}c u_1 & \sqrt{2}c u_2 & c] \\ \varphi(v) &\equiv [v_1^2 & v_2^2 & \sqrt{2}v_1 v_2 & \sqrt{2}c v_1 & \sqrt{2}c v_2 & c]\end{aligned}$$


$$K(u, v) = \langle \varphi(u), \varphi(v) \rangle$$

Mapeo de x (2D) en $\varphi(x)$ (3D o 6D)

$$\varphi(x) = [x_1^2 \quad x_2^2 \quad \sqrt{2}x_1 x_2], \forall c = 0$$

Funciones Kernel


3. Formulación de hipótesis



$$\varphi(x) = [x_1^2 \quad x_2^2 \quad \sqrt{2}x_1x_2]$$

Funciones Kernel


3. Formulación de hipótesis



$$\varphi(x) = \begin{bmatrix} x_1^2 & x_2^2 & \sqrt{2}x_1x_2 \end{bmatrix}$$

Funciones Kernel

2. Determinación de *features*





c = variable
 $r = 2$

$$K(x^{(i)}, x^{(j)}) = \left(x^{(i)T} x^{(j)} + c \right)^r$$

Funciones Kernel

2. Determinación de *features*




$$K(x^{(i)}, x^{(j)}) = \left(x^{(i)T} x^{(j)} + c \right)^r$$


Funciones Kernel

5. Optimización del coste

$c = 10, r = 1$



$c = 10, r = 2$



$$K(x^{(i)}, x^{(j)}) = \left(x^{(i)T} x^{(j)} + c \right)^r$$

Funciones Kernel

6. Evaluación del resultado

Matriz de confusión

$$n_{train} = 200$$

Kernel lineal		Clase calculada		Elementos
		P	N	
Clase real	P	372	25	397
	N	191	212	403
Estimaciones		563	237	800

Kernel cuadrático		Clase calculada		Elementos
		P	N	
Clase real	P	372	25	397
	N	37	366	403
Estimaciones		409	391	800

Funciones Kernel


6. Evaluación del resultado

Nombre	Acrónimo	Expresión	Lineal	Cuadrático
Sensitivity	SNS	$\frac{TP}{TP + FN}$	0.9370	0.9370
Specificity	SPC	$\frac{TN}{TN + FP}$	0.5261	0.9082
Precision	PRC	$\frac{TP}{TP + FP}$	0.6007	0.9095
Negative Predictive Value	NPV	$\frac{TN}{TN + FN}$	0.8945	0.9361
Accuracy	ACC	$\frac{TP + TN}{TP + TN + FP + FN}$	0.7300	0.9225
F ₁ Score	F ₁	$2 \frac{SNS \cdot PRC}{SNS + PRC}$	0.7750	0.9231
Geometric Mean	GM	$\sqrt{SNS \cdot SPC}$	0.7021	0.9225

$$n_{train} = 200$$

Funciones Kernel

6. Evaluación del resultado




$$n_{train} = 200$$


Funciones Kernel

6. Evaluación del resultado

$c = 10, r = 1$



$c = 10, r = 2$



Curva de aprendizaje
Accuracy

Funciones Kernel

2. Determinación de *features*

Kernel cuadrático

$$K(u, v) \equiv (\langle u, v \rangle + c)^2 = (u^T v + c)^2$$

$$u \equiv [u_1 \quad u_2 \quad u_3]; \quad v \equiv [v_1 \quad v_2 \quad v_3]$$

$$K(u, v) = (u_1 v_1 + u_2 v_2 + u_3 v_3 + c)^2$$

$$\begin{aligned} K(u, v) = & u_1^2 v_1^2 + u_2^2 v_2^2 + u_3^2 v_3^2 + c^2 + \\ & 2u_1 v_1 u_2 v_2 + 2u_1 v_1 u_3 v_3 + 2u_2 v_2 u_3 v_3 + \\ & 2u_1 v_1 c + 2u_2 v_2 c + 2u_3 v_3 c \end{aligned}$$

Funciones Kernel

2. Determinación de *features*

Kernel cuadrático

$$\begin{aligned}\varphi(u) &\equiv [u_1^2 \quad u_2^2 \quad u_3^2 \quad \sqrt{2}u_1u_2 \quad \sqrt{2}u_1u_3 \quad \sqrt{2}u_2u_3 \\ &\quad \sqrt{2cu_1} \quad \sqrt{2cu_2} \quad \sqrt{2cu_3} \quad c] \\ \varphi(v) &\equiv [v_1^2 \quad v_2^2 \quad v_3^2 \quad \sqrt{2}v_1v_2 \quad \sqrt{2}v_1v_3 \quad \sqrt{2}v_2v_3 \\ &\quad \sqrt{2cv_1} \quad \sqrt{2cv_2} \quad \sqrt{2cv_3} \quad c]\end{aligned}$$

$$K(u, v) = \langle \varphi(u), \varphi(v) \rangle$$

Mapeo de x (3D) en $\varphi(x)$ (6D, $\forall c = 0$, o 10D)

$$\varphi(x) \equiv [x_1^2 \quad x_2^2 \quad x_3^2 \quad \sqrt{2}x_1x_2 \quad \sqrt{2}x_1x_3 \quad \sqrt{2}x_2x_3]$$

Funciones Kernel

2. Determinación de *features*

Kernel cuadrático

$$K(u, v) \equiv (\langle u, v \rangle + c)^2 = (u^T v + c)^2$$

$$u \equiv [u_1 \quad u_2 \quad \cdots \quad u_d]; \quad v \equiv [v_1 \quad v_2 \quad \cdots \quad v_d]$$

$$K(u, v) = (u_1 v_1 + u_2 v_2 + \cdots + u_d v_d + c)^2$$

$$\begin{aligned} K(u, v) = & \sum_{j=1}^d u_j^2 v_j^2 + \sum_{j=2}^d \sum_{k=j+1}^d \sqrt{2} u_j u_k \sqrt{2} v_j v_k \\ & + \sum_{j=1}^d \sqrt{2c} u_j \sqrt{2c} v_j + c^2 \end{aligned}$$

Funciones Kernel

2. Determinación de *features*

Kernel cuadrático

$$\varphi(x) \equiv [x_1^2 \quad \cdots \quad x_d^2 \quad \sqrt{2}x_1x_2 \quad \cdots \quad \sqrt{2}x_1x_d \\ \sqrt{2}x_2x_3 \quad \cdots \quad \sqrt{2}x_2x_d \quad \cdots \quad \sqrt{2}x_{d-1}x_d \\ \sqrt{2}cx_1 \quad \cdots \quad \sqrt{2}cx_d \quad c]$$


$$K(u, v) = \langle \varphi(u), \varphi(v) \rangle$$

Mapeo de x en $\varphi(x)$

Dimensión de x	Dimensión de $\varphi(x)$	
	$D, \forall c = 0$	$D, \forall c \neq 0$
d	$\frac{d(d-1)}{2} + d$	$\frac{(d+2)(d+1)}{2}$

Funciones Kernel

2. Determinación de *features*



$$D = \binom{d + r}{r}$$

$$\forall c \neq 0$$

d : Dimensión de x

D : Dimensión de $\varphi(x)$

r : Grado del polinomio del Kernel

Funciones Kernel

2. Determinación de *features*

Kernel Gaussiano

$$K(u, v) \equiv e^{-\frac{\|u-v\|^2}{2\sigma^2}} = e^{-\gamma\|u-v\|^2}; \gamma \equiv \frac{1}{2\sigma^2}$$

$$u \equiv [u_1 \quad u_2 \quad \cdots \quad u_d]; \quad v \equiv [v_1 \quad v_2 \quad \cdots \quad v_d]$$

$$\forall d = 1, u = [u_1]; v = [v_1]$$

$$K(u, v) = e^{-\gamma(u_1-v_1)^2} = e^{-\gamma u_1^2 - \gamma v_1^2 + 2\gamma u_1 v_1}$$

Funciones Kernel

2. Determinación de *features*

Kernel Gaussiano

$$K(u, v) = e^{-\gamma u_1^2 - \gamma v_1^2 + 2\gamma u_1 v_1} = e^{-\gamma u_1^2} e^{-\gamma v_1^2} e^{2\gamma u_1 v_1}$$

$$e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!}$$

$$K(u, v) = e^{-\gamma u_1^2} e^{-\gamma v_1^2} \left(1 + \frac{2\gamma u_1 v_1}{1!} + \frac{(2\gamma u_1 v_1)^2}{2!} + \dots \right)$$

Funciones Kernel

2. Determinación de *features*

Kernel Gaussiano

$$K(u, v) = e^{-\gamma u_1^2} e^{-\gamma v_1^2} \left(1 \cdot 1 + \sqrt{\frac{2\gamma}{1!}} u_1 \sqrt{\frac{2\gamma}{1!}} v_1 + \sqrt{\frac{(2\gamma)^2}{2!}} u_1^2 \sqrt{\frac{(2\gamma)^2}{2!}} v_1^2 + \dots \right)$$

Funciones Kernel

2. Determinación de *features*

Kernel Gaussiano


$$K(u, v) = e^{-\gamma \|u-v\|^2} = \langle \varphi(u), \varphi(v) \rangle$$

Mapeo de x (1D) en $\varphi(x)$ (∞ D)

$$\varphi(x) \equiv e^{-\gamma x^2} \begin{bmatrix} 1 & \sqrt{\frac{2\gamma}{1!}} x & \sqrt{\frac{(2\gamma)^2}{2!}} x^2 & \sqrt{\frac{(2\gamma)^3}{3!}} x^3 & \dots \end{bmatrix}$$

Funciones Kernel

5. Optimización del coste




$\sigma = 0.1$

$$K(u, v) \equiv e^{-\frac{\|u-v\|^2}{2\sigma^2}}$$

Maquina de vectores soporte (SVM)


6. Evaluación del resultado



Curva de aprendizaje
Accuracy

Funciones Kernel


3. Formulación de hipótesis




Funciones Kernel

5. Optimización del coste

$c = 1, r = 1$



$c = 1, r = 2$




$$K(u, v) = (u^T v + c)^r$$


Funciones Kernel

5. Optimización del coste

$$c = 1, r = 5$$



$$\sigma = 1, \text{Gauss}$$



$$K(u, v) = (u^T v + c)^r$$

$$K(u, v) \equiv e^{-\frac{\|u-v\|^2}{2\sigma^2}}$$

Funciones Kernel

6. Evaluación del resultado

Matriz de confusión

$$n_{train} = 200$$

Kernel lineal		Clase calculada		Elementos
		P	N	
Clase real	P	379	58	437
	N	246	117	363
Estimaciones		625	175	800

Kernel cuadrático		Clase calculada		Elementos
		P	N	
Clase real	P	390	47	437
	N	239	124	363
Estimaciones		629	171	800

Funciones Kernel

6. Evaluación del resultado

Matriz de confusión

$$n_{train} = 200$$

Kernel Poly5

		Clase calculada		Elementos
		<i>P</i>	<i>N</i>	
Clase real	<i>P</i>	199	238	437
	<i>N</i>	128	235	363
Estimaciones		327	473	800

Kernel Gauss

		Clase calculada		Elementos
		<i>P</i>	<i>N</i>	
Clase real	<i>P</i>	397	40	437
	<i>N</i>	51	312	363
Estimaciones		448	352	800

Funciones Kernel

6. Evaluación del resultado


Nombre	Acrónimo	Lineal	Poly2	Poly5	Gauss
Sensitivity	SNS	0.8673	0.8924	0.4554	0.9085
Specificity	SPC	0.3223	0.3416	0.6474	0.8595
Precision	PRC	0.6064	0.6200	0.6086	0.8862
Negative Predictive Value	NPV	0.6686	0.7251	0.4968	0.8864
Accuracy	ACC	0.6200	0.6425	0.5425	0.8863
F ₁ Score	F ₁	0.7137	0.7317	0.5209	0.8972
Geometric Mean	GM	0.5287	0.5521	0.5430	0.8836

$$n_{train} = 200$$


Funciones Kernel

6. Evaluación del resultado

Poly2




Poly5



$$n_{train} = 200$$

Funciones Kernel


6. Evaluación del resultado



$$n_{train} = 50$$

Funciones Kernel


6. Evaluación del resultado



$$n_{train} = 100$$

Funciones Kernel


6. Evaluación del resultado



$$n_{train} = 200$$

Funciones Kernel


6. Evaluación del resultado



$$n_{train} = 500$$

Funciones Kernel

6. Evaluación del resultado



Curva de aprendizaje
Accuracy

Funciones Kernel

- Similitud entre elementos
 - Funciones de base radial
 - Kernel polinómico
- Aplicaciones
 - Frontera no lineal
 - El truco Kernel

Funciones Kernel

5. Optimización del coste

$$\chi^{(i)} \equiv [\chi_1^{(i)} \quad \chi_2^{(i)} \quad \cdots \quad \chi_m^{(i)}]$$

K : Función Kernel

$$\chi_j^{(i)} = K(x^{(i)}, x^{(j)})$$

φ : Función de mapeo

$$\chi_j^{(i)} = \langle \varphi(x^{(i)}), \varphi(x^{(j)}) \rangle$$

Optimización primal

$$w^* = \arg \min_w [J(h_w(\varphi(x)), y)]$$

Funciones Kernel

5. Optimización del coste

Optimización dual

$$\alpha^* = \arg \max_{\alpha: \alpha_k \geq 0} \left[\sum_{i=1}^n \alpha^{(i)} - \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} y^{(r)} \alpha^{(s)} y^{(s)} \langle \chi^{(r)}, \chi^{(s)} \rangle \right]$$


$$\alpha^* = \arg \max_{\alpha: \alpha_k \geq 0} \left[\sum_{i=1}^n \alpha^{(i)} - \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} y^{(r)} \alpha^{(s)} y^{(s)} \langle \varphi(x^{(r)}), \varphi(x^{(s)}) \rangle \right]$$

$$\alpha^* = \arg \max_{\alpha: \alpha_k \geq 0} \left[\sum_{i=1}^n \alpha^{(i)} - \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} y^{(r)} \alpha^{(s)} y^{(s)} K(x^{(r)}, x^{(s)}) \right]$$

Funciones Kernel

5. Optimización del coste


Basic ML (I)



Funciones Kernel

5. Optimización del coste


Feature-based ML (II)



Funciones Kernel

5. Optimización del coste

Kernel-based ML (III)



Funciones Kernel

5. Optimización del coste

- Kernel trick
 - Se puede optimizar la función de coste sin necesidad de calcular explícitamente los nuevos *features*
 - Usando la optimización dual
 - No es necesario calcular $\varphi(x^{(i)})$
 - Basta calcular el Kernel $K(x^{(i)}, x^{(j)})$
 - Aplicaciones
 - Frontera no lineal (Kernel no lineal)
 - Optimización más eficiente si $n < d$ (Kernel lineal)

Funciones Kernel

Resumen

Primal	Features	$\varphi(x^{(i)})$
	Modelo óptimo	$w^*, b^* = \arg \min_{w, b} \left[\frac{1}{n} \sum_{i=1}^n \max \left(0, 1 - y^{(i)} (\varphi(x^{(i)}) w^T + b) \right) + \lambda \ w\ _2^2 \right]$
	Predicción	$y^{[t]} = \text{sign} \left[\left(\sum_{j=1}^d \varphi_j(x^{[t]}) w_j^* \right) + b^* \right]$
Dual	Features	$\chi^{(i)} = [\langle \varphi(x^{(i)}) \varphi(x^{(1)}) \rangle, \langle \varphi(x^{(i)}) \varphi(x^{(2)}) \rangle, \dots, \langle \varphi(x^{(i)}) \varphi(x^{(n)}) \rangle]$ $\chi^{(i)} = [\textcolor{brown}{K}(x^{(i)}, x^{(1)}), \textcolor{brown}{K}(x^{(i)}, x^{(2)}), \dots, \textcolor{brown}{K}(x^{(i)}, x^{(n)})]$
	Modelo óptimo	$\alpha^* = \arg \max_{\alpha: \alpha^{(i)} \geq 0} \left[\sum_{i=1}^n \alpha^{(i)} - \sum_{r=1}^n \sum_{s=1}^n \alpha^{(r)} y^{(r)} \alpha^{(s)} y^{(s)} \textcolor{brown}{K}(x^{(r)}, x^{(s)}) \right]$ $b^* = \frac{1}{n_S} \sum_{s \in S} \left(y^{(s)} - \sum_{i=1}^n \alpha^{*(i)} y^{(i)} \textcolor{brown}{K}(x^{(s)}, x^{(i)}) \right)$
	Predicción	$y^{[t]} = \text{sign} \left(\sum_{s \in S} \alpha^{*(s)} y^{(s)} \textcolor{brown}{K}(x^{[t]}, x^{(s)}) + b^* \right)$

Funciones Kernel

Resumen

Models	Function	Basic ML	Feature-based ML	Kernel-based ML
Linear models	Regression	Linear Regression (LR)	Ridge Regression (RR)	Kernelized Ridge Regression (KRR)
	Classification	Logistic Regression (LR)		Kernelized Logistic Regression (KLR)
Large margin	Classification	Support Vector Machine (SVM)		
	Regression	Support Vector Regression (SVR)		
Others	Reg. & Class.	Decision tress, Gaussian Process, ...		