

Fundamentos del aprendizaje automático

(Machine learning)

Joaquín Luque

Contenido

1. Introducción
2. Regresión
 - a) Regresión univariable
 - b) Regresión multivariable
3. Clasificación
 - a) Regresión logística
 - b) Máquinas de vectores soporte (SVM)
 - Forma dual de la optimización (regresión y SVM)
 - c) Funciones Kernel
 - d) Clasificación multiclase
4. Segmentación
5. Reducción de dimensionalidad
6. Deep learning (introducción)

Segmentación

- Clasificador k -mean (k -medias)
- Problemas de la función de coste
 - Caso univariable
 - Caso multivariable
- Método del codo (elbow method)
- Evaluación de resultados
 - Silueta
 - Índice de Rand

Segmentación

Ejemplo en el sector eléctrico

- La empresa está impulsando un estudio del comportamiento energético de los ámbitos urbanos.
- Dispone de los datos de diversas ciudades
 1. Número de habitantes
 2. Renta per cápita
- Se plantea segmentar el estudio por distintos tipos de ciudades
- Debe dilucidarse cuántos tipos utilizar y qué ciudades pertenecen a cada tipo

Datos reales obtenido del estudio Urban Audit

<https://www.ine.es/jaxiT3/Tabla.htm?t=10849>

Segmentación

2. Determinación de *features*


Ciudad	Nombre	Población $x_1^{(i)}$	Ingresos (€) $x_2^{(i)}$	Segmento $y^{(i)} \in \{1 \dots K\}$
1	Albacete	172,816	10,515	?
2	Alcalá de Guadaíra	75,106	8,332	?
3	Alcalá de Henares	194,310	11,320	?
4	Alcobendas	114,864	17,417	?
5	Alcorcón	168,141	11,917	?
⋮	⋮	⋮	⋮	⋮

No existen datos de entrenamiento
(clasificación no supervisada)

Los datos necesitan normalización


Segmentación

2. Determinación de *features*




Segmentación

2. Determinación de *features*



Segmentación

2. Determinación de *features*



Segmentación

3. Formulación de hipótesis

Número de segmentos: K

Centroides

$$\mu^{(k)} \in \{1 \cdots K\}$$

K -means

$$d(x^{(i)}, \mu^{(k)}) \equiv \|x^{(i)} - \mu^{(k)}\|^2 = \sum_{j=1}^d \left(x_j^{(i)} - \mu_j^{(k)}\right)^2$$


$$\begin{aligned} x^{(i)} &= [x_1^{(i)} \quad x_2^{(i)} \quad \cdots \quad x_d^{(i)}] \\ \mu^{(k)} &= [\mu_1^{(k)} \quad \mu_2^{(k)} \quad \cdots \quad \mu_d^{(k)}] \end{aligned}$$

Hipótesis $h_\mu(x): y^{(i)} = \arg \min_k [d(x^{(i)}, \mu^{(k)})]$


Segmentación

3. Formulación de hipótesis

$$K = 2$$



Hipótesis 1



Hipótesis 2

Segmentación

4. Elección de la función de coste

$$d(x^{(i)}, \mu^{(k)}) \equiv \|x^{(i)} - \mu^{(k)}\|^2 = \sum_{j=1}^d \left(x_j^{(i)} - \mu_j^{(k)}\right)^2$$

Hipótesis $h_\mu(x): y^{(i)} = \arg \min_k [d(x^{(i)}, \mu^{(k)})]$

$$J(h_\mu(x)) \equiv \frac{1}{n} \sum_{i=1}^n \|x^{(i)} - \mu^{(y^{(i)})}\|^2$$

$$J(h_\mu(x)) = \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^d \left(x_j^{(i)} - \mu_j^{(y^{(i)})}\right)^2$$


Segmentación

- Clasificador k -mean (k -medias)
- Problemas de la función de coste
 - Caso univariable
 - Caso multivariable
- Método del codo (elbow method)
- Evaluación de resultados
 - Silueta
 - Índice de Rand

Segmentación univariable

3. Formulación de hipótesis

$K = 2$




Hipótesis en una dimensión

Segmentación univariable

4. Elección de la función de coste

Segmentos:1

Ciudades:1




Segmentación univariable

4. Elección de la función de coste

Segmentos:1

Ciudades:1




Segmentación univariable

4. Elección de la función de coste

Segmentos:1

Ciudades:1




Segmentación univariable

4. Elección de la función de coste

Segmentos:1

Ciudades:1




Segmentación univariable

4. Elección de la función de coste

Segmentos:1

Ciudades:2




Segmentación univariable

4. Elección de la función de coste

Segmentos:2

Ciudades:1

$$x^{(1)} = 0$$




Segmentación univariable

4. Elección de la función de coste

Segmentos:2

Ciudades:1




Segmentación univariable

4. Elección de la función de coste

Segmentos:2

Ciudades:1

$$x^{(1)} = 0$$



$$\mu^{(2)} = 0$$
$$\mu^{(1)} \in \mathbb{R}$$

$$\mu^{(1)} = 0$$

$$\mu^{(2)} \in \mathbb{R}$$


Segmentación univariable

4. Elección de la función de coste

Segmentos:2

Ciudades:1

$$x^{(1)} = -2$$




Segmentación univariable

4. Elección de la función de coste

Segmentos:2

Ciudades:1

$$x^{(1)} = 2$$




Segmentación univariable

4. Elección de la función de coste

Segmentos:2

Ciudades:2

$$x^{(1)} = -2$$
$$x^{(2)} = 2$$




Segmentación univariable

4. Elección de la función de coste

Segmentos:2

Ciudades:2



Segmentación univariable


4. Elección de la función de coste

Segmentos:2

Ciudades:2

$$\mu^{(1)} = -2$$

$$\mu^{(2)} = 2$$



$$\mu^{(1)} = 2$$
$$\mu^{(2)} = -2$$

$$J_{min} = 0$$

$$x^{(1)} = -2$$

$$x^{(2)} = 2$$

Segmentación univariable

4. Elección de la función de coste


Segmentos:2

Ciudades:3

$$x^{(1)} = -2$$

$$x^{(2)} = 0$$

$$x^{(3)} = 2$$




Segmentación univariable

4. Elección de la función de coste

Segmentos:2

Ciudades:3



$$J_{min} \neq 0$$

Varios mínimos locales


No convexa

Segmentación univariable

4. Elección de la función de coste

Segmentos:2

Ciudades:145




Segmentación univariable

4. Elección de la función de coste

Segmentos:2

Ciudades:145



Varios mínimos locales


No convexa

Segmentación univariable

5. Optimización del coste

Segmentos:2

Ciudades:145




$$\mu_1^* = 0.215$$
$$\mu_2^* = -0.091$$


Segmentación univariable

5. Optimización del coste

Segmentos:2 Ciudades:145



$$\begin{aligned}\mu_1^* &= 0.215 \\ \mu_2^* &= -0.091 \\ J^* &= 0.0099\end{aligned}$$




$$\begin{aligned}\mu_1^* &= -0.091 \\ \mu_2^* &= 0.215 \\ J^* &= 0.0099\end{aligned}$$

Segmentación

- Clasificador k -mean (k -medias)
- Problemas de la función de coste
 - Caso univariable
 - Caso multivariable
- Método del codo (elbow method)
- Evaluación de resultados
 - Silueta
 - Índice de Rand

Segmentación


5. Optimización del coste



Número de semillas: $n_s = 100$

Segmentación


5. Optimización del coste



Óptimos locales y global


Segmentación

5. Optimización del coste



Segmentación


5. Optimización del coste



El valor de la función de coste de un óptimo local está relacionado con su distancia al óptimo global

Segmentación


5. Optimización del coste



Son mayoritarios los óptimos locales de bajo coste

Segmentación

5. Optimización del coste




Solución óptima global


Segmentación

5. Optimización del coste

Segmentos: 3



Segmentos: 4




Número de semillas: $n_s = 100$


Segmentación

5. Optimización del coste

Segmentos: 3



Segmentos: 4




Número de semillas: $n_s = 100$


Segmentación

5. Optimización del coste

Segmentos: 3



Segmentos: 4




Número de semillas: $n_s = 100$


Segmentación

5. Optimización del coste

Segmentos: 3



Segmentos: 4




Número de semillas: $n_s = 100$


Segmentación

5. Optimización del coste

Segmentos: 3



Segmentos: 4




Número de semillas: $n_s = 100$


Segmentación

5. Optimización del coste

Segmentos: 3



Segmentos: 4




Número de semillas: $n_s = 100$

Segmentación

- Clasificador k -mean (k -medias)
- Problemas de la función de coste
 - Caso univariable
 - Caso multivariable
- Método del codo (elbow method)
- Evaluación de resultados
 - Silueta
 - Índice de Rand

Segmentación

5. Optimización del coste




Resultado
ambiguo

Determinación del número de segmentos
Método del codo (Elbow method)

Segmentación

5. Optimización del coste



Las escalas
importan

Determinación del número de segmentos
Método del codo (Elbow method)

Segmentación

5. Optimización del coste

Escalas
equilibradas

$$x_k = \frac{K_k}{K_{max}}; y_k = \frac{J_k}{J_{max}}; x_k, y_k \in [0,1]$$

$$\theta_k \equiv \arctan \frac{\Delta y_k}{\Delta x}$$


$$\Delta y_k \equiv y_k - y_{k-1}$$

Valor del codo
(elbow)

$$E_k \equiv |\Delta \theta_k| = |\theta_{k+1} - \theta_k|$$


Segmentación

5. Optimización del coste



Segmentación

5. Optimización del coste



Número óptimo de segmentos: 5

Segmentación

- Clasificador k -mean (k -medias)
- Problemas de la función de coste
 - Caso univariable
 - Caso multivariable
- Método del codo (elbow method)
- Evaluación de resultados
 - Silueta
 - Índice de Rand

Segmentación

6. Evaluación del resultado

Silueta (Silhouette)

Numero de elementos en el segmento k

$$n^{(k)} = \sum_{i, y^{(i)}=k} 1$$

Distancia acumulada de un elemento a los del segmento k

$$d^{(i,k)} = \sum_{u, y^{(u)}=k} \|x^{(i)} - x^{(u)}\|$$

Distancia media de un elemento a los demás elementos de su segmento

$$a^{(i)} = \frac{d^{(i, y^{(i)})}}{n^{(y^{(i)})} - 1}$$

Segmentación

6. Evaluación del resultado

Silueta (Silhouette)

Distancia de un elemento al segmento k

$$\bar{d}^{(i,k)} = \frac{d^{(i,k)}}{n^{(k)}}$$

Distancia de un elemento al segmento más cercano

$$b^{(i)} = \min_{k \neq y^{(i)}} \bar{d}^{(i,k)}$$

Silueta de un elemento


$$s^{(i)} = \frac{b^{(i)} - a^{(i)}}{\max(a^{(i)}, b^{(i)})}$$

Silueta de la segmentación
(valor medio de las siluetas de los elementos)

$$s = \frac{s^{(i)}}{n}$$

Segmentación


6. Evaluación del resultado



Segmentos: 5

Segmentación


6. Evaluación del resultado



Número óptimo de segmentos: 3

Segmentación

6. Evaluación del resultado




Número óptimo de segmentos: 3

Segmentación

- Clasificador k -mean (k -medias)
- Problemas de la función de coste
 - Caso univariable
 - Caso multivariable
- Método del codo (elbow method)
- Evaluación de resultados
 - Silueta
 - Índice de Rand

Segmentación

6. Evaluación del resultado



Segmentación manual

Segmentación

6. Evaluación del resultado

Índice de Rand

- S_a : Segmentación obtenida automáticamente (ML)
- S_m : Segmentación obtenida manualmente (referencia)
- a : Número de pares de elementos que están en el mismo segmento en S_a y S_m
- b : Número de pares de elementos que están en distinto segmento en S_a y S_m
- n_p : Número de pares de elementos posibles


$$n_p = \binom{n}{2} = \frac{n(n-1)}{2}$$

Índice de Rand

$$R \equiv \frac{a+b}{n_p}$$

Segmentación


6. Evaluación del resultado




Índice de Rand

Segmentación

6. Evaluación del resultado



Segmentación manual



Segmentación automática
Número de segmentos: 3