

Fundamentos del aprendizaje automático

(Machine learning)

Joaquín Luque

Contenido

1. Introducción
2. Regresión
 - a) Regresión univariable
 - b) Regresión multivariable
3. Clasificación
 - a) Regresión logística
 - b) Máquinas de vectores soporte (SVM)
 - Forma dual de la optimización (regresión y SVM)
 - c) Funciones Kernel
 - d) Clasificación multiclase
4. Segmentación
5. Reducción de dimensionalidad
6. Deep learning (introducción)

Principal Component Analysis (PCA)

- Introducción
- Análisis en 2 dimensiones
 - Notación escalar
 - Notación matricial
- Análisis multidimensional
 - Cociente de Rayleigh
- Evaluación de resultados
 - Varianza explicada

Ejemplo en el sector eléctrico

Predicción multivariable

- En otra zona en la que opera la empresa los datos disponibles de los clientes para hacer la predicción de su consumo de energía son los siguientes:
 1. Ingresos anuales (€)
 2. Número de habitantes en la vivienda (promedio anual de personas)
 3. Potencia contratada (kW)
 4. Tipo de vivienda (piso, adosado, casa)
 5. Superficie de la vivienda (m²)
 6. Horas de ocupación en invierno (horas/día)
 7. Horas de ocupación en verano (horas/día)
 8. Edad (años)
 9. Estado civil (soltero, casado, separado, viudo)
 10. Nivel de estudios alcanzado (sin estudios, primaria, secundaria, bachiller, grado, máster, doctor)


Principal Component Analysis (PCA)

Introducción

- Motivación de la reducción de dimensionalidad:
 - El tiempo de optimización y de predicción dependen del número d de variables (features)
 - Algunas variables aportan poca “información” para la predicción
 - Por tener poca influencia en la predicción
 - Por tener una cierta redundancia con la información suministrada por otras variables
 - La “comprensión” del modelo se complica cuando el número de variables es elevado
 - La representación gráfica necesita un número muy bajo de dimensiones (típicamente 2 o 3)

Principal Component Analysis (PCA)

Introducción



Ejemplo: pasar de 2 variables (features) a 1

Principal Component Analysis (PCA)

Introducción

- Intuición:
 - La predicción (regresión o clasificación) del valor objetivo $\hat{y}^{[t]}$ correspondiente a un nuevo valor $x^{[t]}$ se realiza a partir de un modelo $h(\cdot)$ obtenido mediante la optimización del coste del modelo $y = h(X)$
 - Si una variable (feature) de diseño tiene siempre el mismo valor ($x_j^{(u)} = x_j^{(v)}, \forall u, v \in [1, n]$), será inútil para realizar la predicción.
 - Si varía poco será poco útil
 - Las variables (features) más útiles serán aquellas que tengan una mayor varianza

$$V[x_j] = \frac{1}{n} \sum_{i=1}^n (x_j^{(i)} - \mu_j)^2 ; \quad \mu_j = \frac{1}{n} \sum_{i=1}^n x_j^{(i)}$$

Principal Component Analysis (PCA)

2. Determinación de *features*

Si las variables están normalizadas por zscore,
tienen todas la misma varianza (y es = 1)

$$E[\bar{x}_j] = E\left[\frac{x_j - \mu_j}{\sigma_j}\right] = \frac{E[x_j - \mu_j]}{\sigma_j} = \frac{E[x_j] - \mu_j}{\sigma_j} = 0$$

$$var[\bar{x}_j] = E\left[(\bar{x}_j - E[\bar{x}_j])^2\right] = E\left[(\bar{x}_j)^2\right] = E\left[\left(\frac{x_j - \mu_j}{\sigma_j}\right)^2\right]$$

$$var[\bar{x}_j] = \frac{E\left[(x_j - \mu_j)^2\right]}{\sigma_j^2} = \frac{\sigma_j^2}{\sigma_j^2} = 1$$

Principal Component Analysis (PCA)

2. Determinación de *features*

Si las variables están normalizadas por (algún tipo de) rango,
tienen parecida varianza (pero $\neq 1$)

$$E[\bar{x}_j] = E\left[\frac{x_j - \mu_j}{R_j}\right] = \frac{E[x_j - \mu_j]}{R_j} = \frac{E[x_j] - \mu_j}{R_j} = 0$$

$$var[\bar{x}_j] = E\left[(\bar{x}_j - E[\bar{x}_j])^2\right] = E\left[(\bar{x}_j)^2\right] = E\left[\left(\frac{x_j - \mu_j}{R_j}\right)^2\right]$$


$$var[\bar{x}_j] = \frac{E\left[(x_j - \mu_j)^2\right]}{R_j^2} = \frac{\sigma_j^2}{R_j^2} \neq 1$$

Principal Component Analysis (PCA)

- Introducción
- **Análisis en 2 dimensiones**
 - Notación escalar
 - Notación matricial
- Análisis multidimensional
 - Cociente de Rayleigh
- Evaluación de resultados
 - Varianza explicada

Principal Component Analysis (PCA)

3. Formulación de hipótesis




Selección de la variable “ingresos”

Proyección horizontal

Principal Component Analysis (PCA)


3. Formulación de hipótesis



Selección de una variable combinación de “ingresos” y “habitantes”
Proyección diagonal

Principal Component Analysis (PCA)


3. Formulación de hipótesis



Proyección planos variables


Principal Component Analysis (PCA)

3. Formulación de hipótesis



Principal Component Analysis (PCA)

3. Formulación de hipótesis



Principal Component Analysis (PCA)

3. Formulación de hipótesis

Análisis en caso de 2 dimensiones

$$\begin{cases} x_1 = x'_1 \cos \theta - x'_2 \sin \theta \\ x_2 = x'_1 \sin \theta + x'_2 \cos \theta \end{cases}$$

$$\begin{cases} x_1 \cos \theta = x'_1 \cos^2 \theta - x'_2 \sin \theta \cos \theta \\ x_2 \sin \theta = x'_1 \sin^2 \theta + x'_2 \cos \theta \sin \theta \end{cases}$$

$$x_1 \cos \theta + x_2 \sin \theta = x'_1 \quad h_\theta(x_1) = x'_1$$

$$\begin{cases} x_1 \sin \theta = x'_1 \cos \theta \sin \theta - x'_2 \sin^2 \theta \\ x_2 \cos \theta = x'_1 \sin \theta \cos \theta + x'_2 \cos^2 \theta \end{cases}$$

$$x_2 \cos \theta - x_1 \sin \theta = x'_2$$

Principal Component Analysis (PCA)

4. Elección de la función de coste

$$E[x'_1] = \frac{1}{n} \sum_i^n x'^{(i)}_1 = \frac{1}{n} \sum_i^n \left(x^{(i)}_1 \cos \theta + x^{(i)}_2 \operatorname{sen} \theta \right)$$

$$E[x'_1] = \cos \theta \frac{1}{n} \sum_i^n x^{(i)}_1 + \operatorname{sen} \theta \frac{1}{n} \sum_i^n x^{(i)}_2$$

$$E[x'_1] = \cos \theta E[x_1] + \operatorname{sen} \theta E[x_2]$$

$$E[x'_1] = 0$$

Principal Component Analysis (PCA)

4. Elección de la función de coste

$$V[x'_1] = E[(x'_1 - E[x'_1])^2] = E[x_1'^2]$$

$$V[x'_1] = \frac{1}{n} \sum_i^n x_1'^{(i)2} = \frac{1}{n} \sum_i^n \left(x_1^{(i)} \cos \theta + x_2^{(i)} \operatorname{sen} \theta \right)^2$$

$$V[x'_1] = \frac{1}{n} \sum_i^n \left(x_1^{(i)2} \cos^2 \theta + x_2^{(i)2} \operatorname{sen}^2 \theta + 2x_1^{(i)} x_2^{(i)} \operatorname{sen} \theta \cos \theta \right)$$

Principal Component Analysis (PCA)

4. Elección de la función de coste

$$V[x'_1] = \cos^2 \theta \left(\frac{1}{n} \sum_i^n x_1^{(i)2} \right) + \sin^2 \theta \left(\frac{1}{n} \sum_i^n x_2^{(i)2} \right) + 2 \sin \theta \cos \theta \left(\frac{1}{n} \sum_i^n x_1^{(i)} x_2^{(i)} \right)$$

$$V[x'_1] = V[x_1] \cos^2 \theta + V[x_2] \sin^2 \theta + \text{cov}[x_1 x_2] \sin 2\theta$$

$$J = -V[x'_1]$$

Principal Component Analysis (PCA)

5. Optimización del coste

$$\frac{dJ}{d\theta} = \frac{-dV[x'_1]}{d\theta} = -V[x_1]2 \cos \theta (-\sin \theta) - \\ -V[x_2]2 \sin \theta \cos \theta - \text{cov}[x_1 x_2]2 \cos 2\theta = 0$$

$$-V[x_1] \sin 2\theta + V[x_2] \sin 2\theta + 2\text{cov}[x_1 x_2] \cos 2\theta = 0$$

$$-(V[x_1] - V[x_2]) \sin 2\theta + 2\text{cov}[x_1 x_2] \cos 2\theta = 0$$

$$(V[x_1] - V[x_2]) \sin 2\theta = 2\text{cov}[x_1 x_2] \cos 2\theta$$

$$\theta = \frac{1}{2} \text{atan} \frac{2\text{cov}[x_1 x_2]}{V[x_1] - V[x_2]}$$

Principal Component Analysis (PCA)

5. Optimización del coste

Si las varianzas son iguales:

$$\theta = \frac{1}{2} \operatorname{atan} \frac{2 \operatorname{cov}[x_1 x_2]}{V[x_1] - V[x_2]}$$

$$\theta = \frac{1}{2} \operatorname{atan} \frac{2 \operatorname{cov}[x_1 x_2]}{0} = \frac{1}{2} \operatorname{atan} \infty$$

$$\theta = \frac{1}{2} \left(\frac{\pi}{2} \right) = \frac{\pi}{4} = \pm 45^\circ$$

Principal Component Analysis (PCA)

- Introducción
- **Análisis en 2 dimensiones**
 - Notación escalar
 - Notación matricial
- Análisis multidimensional
 - Cociente de Rayleigh
- Evaluación de resultados
 - Varianza explicada

Principal Component Analysis (PCA)

3. Formulación de hipótesis

Notación matricial en 2 dimensiones

$$\begin{aligned}x_1'^{(i)} &= x_1^{(i)} \cos \theta + x_2^{(i)} \operatorname{sen} \theta \\x_2'^{(i)} &= -x_1^{(i)} \operatorname{sen} \theta + x_2^{(i)} \cos \theta\end{aligned}$$

$$\begin{bmatrix} x_1'^{(i)} & x_2'^{(i)} \end{bmatrix} = \begin{bmatrix} x_1^{(i)} & x_2^{(i)} \end{bmatrix} \underbrace{\begin{bmatrix} \cos \theta & -\operatorname{sen} \theta \\ \operatorname{sen} \theta & \cos \theta \end{bmatrix}}$$

Matriz de rotación

Principal Component Analysis (PCA)

3. Formulación de hipótesis

$$r_1 = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}; \quad r_2 = \begin{bmatrix} -\sin \theta \\ \cos \theta \end{bmatrix}$$

$$R = [r_1 \quad r_2] = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

$$x'^{(i)} = [x_1'^{(i)} \quad x_2'^{(i)}]; \quad x^{(i)} = [x_1^{(i)} \quad x_2^{(i)}]$$

$$x'^{(i)} = x^{(i)} R$$

$$X' = XR$$

Principal Component Analysis (PCA)

4. Elección de la función de coste

$$E[x'_1] = \frac{1}{n} \sum_i^n x'^{(i)}_1 = \frac{1}{n} \sum_i^n x^{(i)} r_1$$

$$E[x'_1] = \left(\frac{1}{n} \sum_i^n x^{(i)} \right) r_1$$

$$E[x'_1] = E[x] r_1$$

$$E[x'_1] = 0$$

Principal Component Analysis (PCA)

4. Elección de la función de coste

$$V[x'_1] = E[(x'_1 - E[x'_1])^2] = E[x'^2_1]$$

$$V[x'_1] = \frac{1}{n} \sum_i^n x'^2_{1(i)} \propto \sum_i^n x'^2_{1(i)} = \sum_i^n (x^{(i)} r_1)^2$$

$$V[x'_1] \propto \sum_i^n \left(\begin{bmatrix} x^{(i)}_1 & x^{(i)}_2 \end{bmatrix} \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix} \right)^2$$

$$V[x'_1] \propto \sum_i^n \left(\begin{bmatrix} x^{(i)}_1 & x^{(i)}_2 \end{bmatrix} \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix} \right)^2$$

Principal Component Analysis (PCA)

4. Elección de la función de coste

$$X = \begin{matrix} (n \times d) \\ \begin{bmatrix} x_1^{(1)} & x_2^{(1)} \\ x_1^{(2)} & x_2^{(2)} \\ \vdots & \vdots \\ x_1^{(n)} & x_2^{(n)} \end{bmatrix} \end{matrix} \quad X^T = \begin{matrix} \begin{bmatrix} x_1^{(1)} & x_1^{(2)} & \dots & x_1^{(n)} \\ x_2^{(1)} & x_2^{(2)} & \dots & x_2^{(n)} \end{bmatrix} \\ (d \times n) \end{matrix}$$

$$X^T X = \begin{matrix} (d \times d) \\ \begin{bmatrix} x_1^{(1)2} + \dots + x_1^{(n)2} & x_1^{(1)}x_2^{(1)} + \dots + x_1^{(1)}x_2^{(1)} \\ x_1^{(1)}x_2^{(1)} + \dots + x_1^{(1)}x_2^{(1)} & x_2^{(1)2} + \dots + x_2^{(n)2} \end{bmatrix} \end{matrix}$$

Principal Component Analysis (PCA)

4. Elección de la función de coste

$$C \equiv X^T X = \begin{matrix} (d \times d) \end{matrix} \begin{bmatrix} \sum_i^n x_1^{(i)2} & \sum_i^n x_1^{(i)} x_2^{(i)} \\ \sum_i^n x_1^{(i)} x_2^{(i)} & \sum_i^n x_2^{(i)2} \end{bmatrix} = nK \quad \begin{matrix} \text{Matriz de} \\ \text{covarianza} \end{matrix} \quad r_1 = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix} \quad \begin{matrix} (d \times 1) \end{matrix}$$

$$(X^T X)r_1 = \begin{matrix} (d \times 1) \end{matrix} \begin{bmatrix} \cos \theta \sum_i^n x_1^{(i)2} + \sin \theta \sum_i^n x_1^{(i)} x_2^{(i)} \\ \cos \theta \sum_i^n x_1^{(i)} x_2^{(i)} + \sin \theta \sum_i^n x_2^{(i)2} \end{bmatrix}$$

Principal Component Analysis (PCA)

4. Elección de la función de coste

$$(1 \times d) \quad r_1^T = [\cos \theta \quad \text{sen } \theta]$$

$$\begin{aligned} (1 \times 1) \quad r_1^T (X^T X) r_1 &= \cos^2 \theta \sum_i^n x_1^{(i)2} + \text{sen } \theta \cos \theta \sum_i^n x_1^{(i)} x_2^{(i)} + \\ &+ \text{sen } \theta \cos \theta \sum_i^n x_1^{(i)} x_2^{(i)} + \text{sen}^2 \theta \sum_i^n x_2^{(i)2} \end{aligned}$$

$$r_1^T (X^T X) r_1 = \sum_i^n \left(x_1^{(i)} \cos \theta + x_2^{(i)} \text{sen } \theta \right)^2 = nV[x'_1]$$

Principal Component Analysis (PCA)

4. Elección de la función de coste

$$V[x'_1] = \frac{1}{n} r_1^T (X^T X) r_1$$

$$\theta_1 = \arg \max_{\theta} V[x'_1]$$

$$r_{pr_1} = \arg \max_{r_1} \left[\frac{1}{n} r_1^T (X^T X) r_1 \right]$$

$$r_{pr_1} = \arg \max_{r_1} [r_1^T (X^T X) r_1]$$

Principal Component Analysis (PCA)

4. Elección de la función de coste

$$r_1 = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix} \quad r_1^T = [\cos \theta \quad \sin \theta]$$

$(d \times 1)$ $(1 \times d)$

$$r_1^T r_1 = \cos^2 \theta + \sin^2 \theta = 1$$

$$r_{pr_1} = \arg \max_{r_1} \left[\underbrace{\frac{r_1^T (X^T X) r_1}{r_1^T r_1}} \right] = \arg \max_{r_1} [R_q(X^T X, r_1)]$$

Cociente de Rayleigh

$$J = -R_q(C, r_1)$$

Principal Component Analysis (PCA)

- Introducción
- Análisis en 2 dimensiones
 - Notación escalar
 - Notación matricial
- **Análisis multidimensional**
 - Cociente de Rayleigh
- Evaluación de resultados
 - Varianza explicada

Principal Component Analysis (PCA)

5. Optimización del coste

$$r_{pr_1} = \arg \max_{r_1} \left[\frac{r_1^T (X^T X) r_1}{r_1^T r_1} \right]$$


$$(X^T X)v = \lambda v = \begin{cases} \lambda_1 v_1 \\ \vdots \\ \lambda_d v_d \end{cases} \quad \text{Autovalores y autovectores}$$

$$j_{max} = \arg \max_j \lambda_j$$

$$r_{pr_1} = v_{j_{max}}$$

Principal Component Analysis (PCA)

5. Optimización del coste



Principal Component Analysis (PCA)

5. Optimización del coste

Cociente de Rayleigh

$$\begin{matrix} (d \times d) & C = X^T X \\ & \begin{matrix} (d+n) \\ (n+d) \end{matrix} \end{matrix}$$

$$R_q(C, r) \equiv \frac{r^T C r}{r^T r} \quad \begin{matrix} (d+1) \end{matrix}$$

$$\begin{matrix} (d+d) & C v = \lambda v, \|v\| = 1 \\ \begin{matrix} (d+1) \\ (d+1) \end{matrix} & \end{matrix}$$

Autovalores y
autovectores

Principal Component Analysis (PCA)

5. Optimización del coste

1. Los autovalores son no-negativos: $\lambda_i \geq 0, \forall i$

$$Cv_i = X^T X v_i = \lambda_i v_i, \|v_i\| = 1$$

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$$

$$v_i^T X^T X v_i = v_i^T \lambda_i v_i \quad A^T B^T = (AB)^T$$

$$\overset{(1 \times 1)}{(Xv_i)^T} \overset{(n \times 1)}{(Xv_i)} = \lambda_i \overset{(1 \times d)}{v_i^T} \overset{(d \times 1)}{v_i}$$

$$\overset{(n+d)}{(n+d+1)} \quad \overset{(1+d)}{(1+d+1)}$$

$$\|Xv_i\|^2 = \lambda_i \|v_i\|^2 \Rightarrow \lambda_i = \frac{\|Xv_i\|^2}{\|v_i\|^2} \geq 0$$

Principal Component Analysis (PCA)

5. Optimización del coste

2. Los autovectores son ortogonales: $v_i \cdot v_j = v_j^T v_i = 0, \forall i \neq j$

$$C v_i = \lambda_i v_i$$

$$v_j^T C v_i = v_j^T \lambda_i v_i$$

$$A^T B^T = (AB)^T$$

$$(C v_j)^T v_i = \lambda_i v_j^T v_i$$

$$C v_j = \lambda_j v_j$$

$$\lambda_j v_j^T v_i = \lambda_i v_j^T v_i$$

$$(\lambda_j - \lambda_i) v_j^T v_i = 0$$

$$v_j^T v_i = v_i \cdot v_j = 0$$

Principal Component Analysis (PCA)

5. Optimización del coste

3. Expresión de r en la base ortogonal de los autovectores v_i

$$(d \times 1) \quad r = \sum_{i=1}^d \alpha_i v_i$$

$$\|r\|^2 = \sum_{i=1}^d \alpha_i^2 \|v_i\|^2 = \sum_{i=1}^d \alpha_i^2$$

$$\sum_{i=1}^d \frac{\alpha_i^2}{\|r\|^2} = 1$$

Principal Component Analysis (PCA)

5. Optimización del coste

3. Expresión de r en la base ortogonal de los autovectores v_i

$$\|r\|^2 = \sum_{i=1}^d \alpha_i^2 = \alpha_i^2 + \sum_{\substack{j=1 \\ j \neq i}}^d \alpha_j^2$$

$$\alpha_i^2 = \|r\|^2 - \sum_{\substack{j=1 \\ j \neq i}}^d \alpha_j^2$$

$$\alpha_i^2 \leq \|r\|^2$$

Principal Component Analysis (PCA)

5. Optimización del coste

4. El cociente de Rayleigh es constante al escalar $r \rightarrow kr$

$$R_q(C, kr) = \frac{(kr)^T C (kr)}{(kr)^T (kr)}$$

$$R_q(C, kr) = \frac{kr^T C kr}{kr^T kr} = \frac{r^T C r}{r^T r}$$

$$R_q(C, kr) = R_q(C, r)$$

Principal Component Analysis (PCA)

5. Optimización del coste

5. El cociente de Rayleigh es máximo para el autovector correspondiente al máximo autovalor

$$R_q(C, r) \equiv \frac{r^T C r}{r^T r} = \frac{1}{\|r\|^2} r^T C r$$

$$R_q(C, r) = \frac{1}{\|r\|^2} \left(\sum_{j=1}^d \alpha_j v_j \right)^T C \left(\sum_{i=1}^d \alpha_i v_i \right)$$

$$R_q(C, r) = \frac{1}{\|r\|^2} \left(\sum_{j=1}^d \alpha_j v_j^T \right) \left(\sum_{i=1}^d \alpha_i C v_i \right)$$

Principal Component Analysis (PCA)

5. Optimización del coste

5. El cociente de Rayleigh es máximo para el autovector correspondiente al máximo autovalor (cont.)

$$R_q(C, r) = \frac{1}{\|r\|^2} \left(\sum_{j=1}^d \alpha_j v_j^T \right) \left(\sum_{i=1}^d \alpha_i \lambda_i v_i \right) \quad C v_i = \lambda_i v_i$$

$$R_q(C, r) = \frac{1}{\|r\|^2} \sum_{j=1}^d \left(\alpha_j v_j^T \sum_{i=1}^d \alpha_i \lambda_i v_i \right)$$

$$R_q(C, r) = \frac{1}{\|r\|^2} \sum_{j=1}^d \sum_{i=1}^d \alpha_j v_j^T \alpha_i \lambda_i v_i$$

Principal Component Analysis (PCA)

5. Optimización del coste

5. El cociente de Rayleigh es máximo para el autovector correspondiente al máximo autovalor (cont.)

$$R_q(C, r) = \frac{1}{\|r\|^2} \sum_{j=i}^d \sum_{i=1}^d \alpha_j \alpha_i \lambda_i v_j^T v_i + \sum_{j=1}^d \sum_{\substack{i=1 \\ j \neq i}}^d \alpha_j \alpha_i \lambda_i v_j^T v_i$$

$$v_j^T v_i = 0, \forall i \neq j$$

Ortogonalidad de
los autovectores v_i

$$R_q(C, r) = \frac{1}{\|r\|^2} \sum_{i=1}^d \alpha_i^2 \lambda_i v_i^T v_i = \sum_{i=1}^d \frac{\alpha_i^2 \|v_i\|^2}{\|r\|^2} \lambda_i = \sum_{i=1}^d \beta_i \lambda_i$$

Principal Component Analysis (PCA)

5. Optimización del coste

5. El cociente de Rayleigh es máximo para el autovector correspondiente al máximo autovalor (cont.)

$$\beta_i \equiv \frac{\alpha_i^2 \|v_i\|^2}{\|r\|^2} = \frac{\alpha_i^2}{\|r\|^2} \quad \|v_i\| = 1$$

$$\alpha_i^2 \leq \|r\|^2 \Rightarrow \beta_i \in [0,1]$$

$$\sum_{i=1}^d \frac{\alpha_i^2}{\|r\|^2} = 1 \Rightarrow \sum_{i=1}^d \beta_i = 1$$

Principal Component Analysis (PCA)

5. Optimización del coste

5. El cociente de Rayleigh es máximo para el autovector correspondiente al máximo autovalor (cont.)

$$R_q(C, r) = \sum_{i=1}^d \beta_i \lambda_i$$

$$\beta_i \in [0,1]; \sum_{i=1}^d \beta_i = 1$$

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$$

$$\max \left(R_q(C, r) \right) \Rightarrow \beta_1 = 1; \beta_i = 0, \forall i \neq 1$$

Principal Component Analysis (PCA)

5. Optimización del coste

5. El cociente de Rayleigh es máximo para el autovector correspondiente al máximo autovalor (cont.)

$$\max_{r=r_{max}} R_q(C, r) = \lambda_1$$

$$\beta_i = \frac{\alpha_i^2}{\|r\|^2} \Rightarrow \alpha_i = \pm \frac{1}{\|r\|} \beta_i$$

$$\alpha_1 = \pm \frac{1}{\|r\|}; \alpha_i = 0, \forall i \neq 1$$

Principal Component Analysis (PCA)

5. Optimización del coste

5. El cociente de Rayleigh es máximo para el autovector correspondiente al máximo autovalor (cont.)

$$r_{max} = \sum_{i=1}^d \alpha_i v_i = \pm \frac{1}{\|r\|} v_1$$

$$R_q(C, r_{max}) = R_q(C, kr_{max})$$

$$r_{pr_1} = \pm \|r\| r_{max} = v_1$$

Principal Component Analysis (PCA)

5. Optimización del coste

6. El cociente de Rayleigh ortogonal al primer autovector es máximo para el autovector correspondiente al segundo autovalor

$$r = \sum_{i=1}^d \alpha_i v_i$$

$$r_{\max_1} \Rightarrow \alpha_1 = \pm \frac{1}{\|r\|}; \alpha_i = 0, \forall i \neq 1$$

$$r_{\max_2} \Rightarrow \alpha_1 = 0 \Rightarrow \beta_1 = 0$$

$$r_{\max_1} \cdot r_{\max_2} = 0$$

Principal Component Analysis (PCA)

5. Optimización del coste

6. El cociente de Rayleigh ortogonal al primer autovector es máximo para el autovector correspondiente al segundo autovalor (cont.)

$$R_q(C, r) = \sum_{i=1}^d \beta_i \lambda_i$$

$$\beta_i \in [0,1]; \sum_{i=1}^d \beta_i = 1; \beta_1 = 0$$

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$$

$$\max \left(R_q(C, r) \right) \Rightarrow \beta_2 = 1; \beta_i = 0, \forall i \neq 1$$

Principal Component Analysis (PCA)

5. Optimización del coste

6. El cociente de Rayleigh ortogonal al primer autovector es máximo para el autovector correspondiente al segundo autovalor (cont.)

$$\max_{r=r_{max_2}} R_q(C, r) = \lambda_2$$

$$\alpha_2 = \pm \frac{1}{\|r\|}; \alpha_i = 0, \forall i \neq 1$$

$$r_{max_2} = \sum_{i=1}^d \alpha_i v_i = \pm \frac{1}{\|r\|} v_2$$

$$r_{pr_2} = \pm \|r\| r_{max_2} = v_2$$

Principal Component Analysis (PCA)

5. Optimización del coste

7. El cociente de Rayleigh ortogonal a los p primeros autovectores es máximo para el autovector correspondiente al $p + 1$ autovalor

$$r = \sum_{i=1}^d \alpha_i v_i$$

$$\forall j \leq p: r_{\max_j} \Rightarrow \alpha_j = \pm \frac{1}{\|r\|}; \alpha_i = 0, \forall i \neq j$$

$$r_{\max_{p+1}} \Rightarrow \alpha_j = 0 \Rightarrow \beta_j = 0, \forall j \leq p$$

$$r_{\max_{p+1}} \cdot r_{\max_j} = 0, \forall j \leq p$$

Principal Component Analysis (PCA)

5. Optimización del coste

7. El cociente de Rayleigh ortogonal a los p primeros autovectores es máximo para el autovector correspondiente al $p + 1$ autovalor (cont.)

$$R_q(C, r) = \sum_{i=1}^d \beta_i \lambda_i$$

$$\beta_i \in [0,1]; \sum_{i=1}^d \beta_i = 1; \beta_j = 0, \forall j \leq p$$

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$$

$$\max \left(R_q(C, r) \right) \Rightarrow \beta_{p+1} = 1; \beta_i = 0, \forall i \neq p + 1$$

Principal Component Analysis (PCA)

5. Optimización del coste

7. El cociente de Rayleigh ortogonal a los p primeros autovectores es máximo para el autovector correspondiente al $p + 1$ autovalor (cont.)

$$\max_{r=r_{max_{p+1}}} R_q(C, r) = \lambda_{p+1}$$

$$\alpha_{p+1} = \pm \frac{1}{\|r\|}; \alpha_i = 0, \forall i \neq p + 1$$

$$r_{max_{p+1}} = \sum_{i=1}^d \alpha_i v_i = \pm \frac{1}{\|r\|} v_{p+1}$$

$$r_{pr_{p+1}} = \pm \|r\| r_{max_{p+1}} = v_{p+1}$$

Principal Component Analysis (PCA)

5. Optimización del coste

8. Conclusión: la matriz de rotación coincide con la matriz de autovectores de la covarianza (ordenada por valores decrecientes de autovalores)

Rotación del espacio
de coordenadas

$$X' = XR$$

Matriz de covarianza

$$C = X^T X$$

Autovalores y autovectores
de la matriz de covarianza

$$CV = \Lambda V$$

Matriz de rotación

$$R = V$$

Principal Component Analysis (PCA)

Ejemplo


Matriz de
rotación

R

		PCA Component														
		1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Feature	1	0.330	0.063	-0.006	-0.025	-0.047	-0.074	0.003	0.038	-0.006	-0.057	-0.005	0.029	0.934	0.000	0.000
	2	-0.285	0.158	-0.090	-0.019	0.173	0.585	0.325	0.554	-0.187	-0.230	-0.050	0.011	0.105	0.000	0.000
	3	0.317	0.064	0.005	-0.013	-0.050	-0.112	0.068	0.208	-0.743	0.489	-0.073	-0.160	-0.107	0.000	0.000
	4	-0.284	0.148	0.172	0.052	-0.478	-0.280	0.266	0.089	-0.029	-0.058	-0.004	0.006	0.038	-0.201	0.658
	5	0.208	-0.394	-0.268	-0.026	0.546	0.060	0.004	-0.054	0.000	0.009	0.007	0.000	-0.014	-0.191	0.622
	6	0.186	0.482	0.175	-0.058	-0.082	0.480	-0.579	-0.083	0.062	0.106	-0.006	-0.013	-0.052	-0.094	0.307
	7	0.321	0.061	-0.006	-0.032	-0.060	-0.109	-0.027	0.128	-0.180	-0.326	0.117	0.821	-0.182	0.000	0.000
	8	-0.320	-0.058	0.011	0.033	0.059	0.098	-0.021	-0.043	-0.032	0.447	0.769	0.249	0.154	0.000	0.000
	9	-0.319	-0.072	-0.003	0.043	0.051	0.094	-0.005	-0.139	0.043	0.467	-0.620	0.485	0.145	0.000	0.000
	10	0.077	0.099	-0.010	0.988	0.085	0.007	-0.005	0.007	0.005	-0.022	0.004	-0.002	-0.004	0.000	0.000
	11	-0.260	0.296	-0.270	-0.034	0.244	-0.381	-0.312	0.200	-0.050	-0.049	-0.025	-0.016	0.042	0.621	0.190
	12	0.096	-0.487	0.544	0.055	-0.132	0.217	-0.038	0.095	-0.016	-0.024	-0.009	-0.002	0.009	0.588	0.180
	13	0.196	0.026	-0.602	0.014	-0.418	0.304	0.280	-0.288	0.066	0.084	0.038	0.012	-0.056	0.375	0.115
	14	0.153	0.455	0.358	-0.083	0.402	-0.025	0.539	-0.349	0.076	0.063	0.030	0.031	-0.050	0.205	0.063
	15	0.315	0.058	-0.020	-0.026	-0.030	-0.110	0.122	0.583	0.601	0.389	0.004	0.026	-0.124	0.000	0.000


Principal Component Analysis (PCA)

Ejemplo



Principal Component Analysis (PCA)

Ejemplo



Principal Component Analysis (PCA)

Ejemplo

Matriz de
rotación


R_p

$$X' = XR_p$$

		PCA Component	
		1	2
Feature	1	0.330	0.063
	2	-0.285	0.158
	3	0.317	0.064
	4	-0.284	0.148
	5	0.208	-0.394
	6	0.186	0.482
	7	0.321	0.061
	8	-0.320	-0.058
	9	-0.319	-0.072
	10	0.077	0.099
	11	-0.260	0.296
	12	0.096	-0.487
	13	0.196	0.026
	14	0.153	0.455
	15	0.315	0.058

Principal Component Analysis (PCA)

Ejemplo



Biplot

Principal Component Analysis (PCA)

- Introducción
- Análisis en 2 dimensiones
 - Notación escalar
 - Notación matricial
- Análisis multidimensional
 - Cociente de Rayleigh
- Evaluación de resultados
 - Varianza explicada

Principal Component Analysis (PCA)

6. Evaluación del resultado

Varianza de los datos

$$V[X] \equiv V[x_1] + V[x_2] + \cdots + V[x_d]$$

$$V[X] \equiv \sum_{j=1}^d V[x_j] = \sum_{j=1}^d \frac{1}{n} \sum_{i=1}^n x_j^{(i)2} = \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^d x_j^{(i)2}$$

$$V[X] = \frac{1}{n} \sum_{i=1}^n \|x^{(i)}\|^2 = \frac{1}{n} \sum_{i=1}^n \|x'^{(i)}\|^2 = V[X']$$

$$V[X'] \equiv V[x'_1] + V[x'_2] + \cdots + V[x'_d]$$

Principal Component Analysis (PCA)

6. Evaluación del resultado

Varianza de los datos

Varianza relativa $\varrho_j[X] \equiv \frac{V[x_j]}{V[X]}$

$$V[X] = \sum_{j=1}^d V[x_j] = \sum_{j=1}^d (\varrho_j[X] V[X]) = V[X] \sum_{j=1}^d \varrho_j[X]$$

$$\sum_{j=1}^d \varrho_j[X] = 1$$

Principal Component Analysis (PCA)

6. Evaluación del resultado

Varianza de los datos

$$r_j = v_j$$

$$V[x'_j] = \frac{1}{n} \sum_{i=1}^n x_j'^{(i)2} = \frac{1}{n} \sum_{i=1}^n \left(x_j^{(i)} r_j \right)^2 = \frac{1}{n} \sum_{i=1}^n \left(x_j^{(i)} v_j \right)^2$$

$$V[x'_j] = \frac{1}{n} (X v_j)^T (X v_j) = \frac{1}{n} v_j^T X^T X v_j = \frac{1}{n} v_j^T C v_j$$

$$V[x'_j] = \frac{1}{n} v_j^T \lambda_j v_j = \frac{1}{n} \lambda_j v_j^T v_j = \frac{1}{n} \lambda_j \|v_j\|^2$$

$$V[x'_j] = \frac{1}{n} \lambda_j \quad \|v_j\|^2 = 1$$

Principal Component Analysis (PCA)

6. Evaluación del resultado

Varianza de los datos

$$V[X] = V[X'] = \sum_{j=1}^d V[x'_j] = \sum_{j=1}^d \frac{1}{n} \lambda_j = \frac{1}{n} \sum_{j=1}^d \lambda_j$$


$$\varrho_j[X'] \equiv \frac{V[x'_j]}{V[X']} = \frac{\frac{1}{n} \lambda_j}{\frac{1}{n} \sum_{j=1}^d \lambda_j} = \frac{\lambda_j}{\sum_{j=1}^d \lambda_j}$$

Varianza
relativa
acumulada


$$\eta_p[X'] \equiv \sum_{j=1}^p \varrho_j[X'] = \frac{\sum_{j=1}^p \lambda_j}{\sum_{j=1}^d \lambda_j}$$

Principal Component Analysis (PCA)

6. Evaluación del resultado



Normalización z-score



Normalización por rango

Principal Component Analysis (PCA)

Resumen

1. Normalizar la matriz de diseño X
 - Media nula y varianza igual o en el mismo rango
2. Calcular la matriz de covarianza $C = X^T X$
3. Calcular los d pares (λ_j, v_j) de autovalores y autovectores de C
4. Ordenar los pares (λ_j, v_j) de mayor a menor valor de los autovalores λ_j
5. Determinar la varianza relativa ϱ_j correspondiente al par (λ_j, v_j)
6. Para distintos $p < d$, calcular la varianza relativa acumulada η_p
7. Elegir el valor de p que “explique” una proporción de varianza adecuada para la aplicación deseada
8. Formar la matriz de rotación R_p con los p primeros autovectores
9. Obtener la matriz de diseño transformada de acuerdo con $X' = X R_p$

Principal Component Analysis (PCA)

Resumen

		$h^{(i)}$	J	Eval.
Regression	RR	$x^{(i)} w^T$	$\frac{1}{n} \sum_{i=1}^n (y^{(i)} - h^{(i)})^2 + \lambda \ w\ _2^2$	RMSE
	KRR	$K[x^{(i)} X^T] \alpha$	$\frac{1}{n} \sum_{i=1}^n (y^{(i)} - h^{(i)})^2 + \lambda \ w\ _2^2$	
Classification	LogR	$x^{(i)} w^T + b$	$\frac{1}{n} \sum_{i=1}^n [-y^{(i)} \text{Ln}(h^{(i)}) - (1 - y^{(i)}) \text{Ln}(1 - h^{(i)})] + \lambda \ w\ _2^2$	Confusion matrix, ACC, ...
	SVM	$\sum_{s \in \mathcal{S}} \alpha^{(s)} y^{(s)} K(x^{(i)}, x^{(s)}) + b$	$\frac{1}{n} \sum_{i=1}^n \max(0, 1 - y^{(i)} h^{(i)}) + \lambda \ w\ _2^2$	
Cluster.	kNN	$\arg \min_k [d(x^{(i)}, \mu^{(k)})]$	$\frac{1}{n} \sum_{i=1}^n \ x^{(i)} - \mu^{(h^{(i)})}\ ^2$	Silhouette, Rand, ...
DimR	PCA	$x^{(i)} [r_1 \ \cdots \ r_p]$	$-R_q(X^T X, r_j), \forall j \in [1, p]$	Explained variance