


Análisis Exploratorio de Datos (o EDA)

- Engloba un conjunto de técnicas para poder **comprender/resumir** las características más importantes de un conjunto de datos o **dataset**.
- Ayuda a seleccionar la herramienta adecuada para el preprocesamiento/análisis.
- Esta metodología fue impulsada por el estadístico John Tukey.
- Se basa principalmente en dos criterios: Las **estadísticas de resumen** y la **visualización de datos**.
- En esta clase se verán ambos tipos de técnicas, además de su aplicación en **R** para datasets conocidos.

R y Studio

- R es un ambiente de programación estadístico totalmente gratuito: <http://www.r-project.org/>
- Permite manipular y almacenar datos de manera efectiva.
- Es un lenguaje de programación completo: variables, loop, condiciones, funciones.
- Provee muchas librerías para realizar distintos tipos de análisis sobre colecciones de datos, ej: visualización de datos, análisis de series temporales, análisis de grafos, análisis de texto.
- Rstudio es un IDE que ofrece un entorno amigable para trabajar con R.



El dataset Iris

Trabajaremos con un dataset muy conocido en análisis de datos llamado **Iris**.

- El dataset se compone de 150 observaciones de flores de la planta iris.
- Existen tres tipos de clases de flores iris: **virginica**, **setosa** y **versicolor**.
- Hay 50 observaciones de cada una.
- Las variables o atributos que se miden de cada flor son:
 - El **tipo de flor** como variable categórica.
 - El **largo y el ancho del pétalo** en cm como variables numéricas.
 - El **largo y el ancho del sépalo** en cm como variables numéricas.



El dataset Iris



Virginica



Setosa



Versicolor

- El dataset se encuentra disponible en R:

```
> data(iris) #carga el dataset al workspace
```

```
> str(iris) #ver los atributos de un dataset
```

```
'data.frame':  150 obs. of  5 variables:
 $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
 $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
 $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
 $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
 $ Species      : Factor w/ 3 levels "setosa","versicolor",...: 1 1 1 1 1 1 1 1 1 1 ...
```

```
> attach(iris) #pasa las variables del dataframe al ambiente
```

Estadísticas de Resumen

- Las estadísticas de resumen son valores que explican propiedades de los datos.
- Algunas de estas propiedades incluyen: frecuencias, medidas de tendencia central y dispersión.
- Ejemplos:
 - **Tendencia central:** media, mediana, moda.
 - **Dispersión:** miden la variabilidad de los datos, como la desviación estándar, el rango, etc..
- La mayor parte de las estadísticas de resumen se pueden calcular haciendo una sola pasada por los datos.
- Su uso está sujeto al tipo de atributo. Por ejemplo, cuando son categóricos, generalmente hacemos estadísticas basadas en conteo.

Frecuencia

- La frecuencia de un valor de atributo es el porcentaje de veces que éste es observado.
- En R podemos contar las frecuencias de aparición de cada valor distinto de un vector usando el comando *table*:

```
> table(iris$Species)
  setosa versicolor virginica 
    50         50         50
```

- **Ejercicio:** Calcular las frecuencias porcentuales de iris\$Species.

```
> table(iris$Species) / length(iris$Species)
  setosa versicolor virginica 
0.3333333 0.3333333 0.3333333
```

Medidas de Tendencia Central

Estas medidas tratan de resumir los valores observados en único valor asociado al valor localizado en el centro.

Media

- La media es la medida más común de tendencia central para una variable numérica.
- Si tenemos m observaciones se calcula como la media aritmética o promedio.

$$\text{mean}(x) = \bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

Medidas de Tendencia Central

- Es una medida muy sensible a *outliers* o valores atípicos.

```
#crea vector con distribución normal, rnorm(n, mean, sd)
> vec <- rnorm(10, 20, 10)
> mean(vec)
[1] 16.80036
```

```
> vec.ruid <- c(vec, rnorm(1, 300, 100))
> mean(vec.ruid)
[1] 35.36422
```


Medidas de Tendencia Central

- Podemos robustecer la media eliminando una fracción de los valores extremos usando la **media truncada** o **trimmed mean**.
- En R podemos darle un segundo parámetro a la función *mean* llamado *trim* que define la fracción de elementos extremos a descartar.

Ejemplo: Descartamos el 10% de los valores extremos en el ejemplo anterior:

```
> mean(vec, trim=0.1)
[1] 17.78799
```

```
> mean(vec.ruid, trim=0.1)
[1] 19.51609 # Mucho más robusto
```

Medidas de Tendencia Central

Mediana

- La mediana representa la posición central de la variable que separa la mitad inferior y la mitad superior de las observaciones.
- Intuitivamente, consiste en el valor donde para una mitad de las observaciones todos los valores son mayores que ésta, y para la otra mitad todos son menores.

$$\text{median}(x) = \begin{cases} x_{r+1} & \text{Si } m \text{ es impar con } m = 2r + 1 \\ \frac{1}{2}(x_r + x_{r+1}) & \text{Si } m \text{ es par con } m = 2r \end{cases}$$

- Para el ejemplo anterior, vemos que la mediana es más robusta al ruido que la media:

```
> median(vec)
[1] 17.64805
> median(vec.ruid)
[1] 17.64839
```

Medidas de Tendencia Central

Moda


- La moda de un atributo es el valor más frecuente observado.
- No existe la función moda directamente en R, pero es fácil de calcular usando `table` y `max`:

```
my_mode <- function(var) {  
    frec.var <- table(var)  
    valor <- which(frec.var==max(frec.var))  
    names(valor)  
}
```

```
> my_mode(iris$Sepal.Length)  
[1] "5"
```

- Generalmente usamos la frecuencia y la moda para estudiar variables categóricas.

Comparación entre la moda, la mediana y la media



Percentiles o Cuantiles

- El k-ésimo percentil de una variable numérica es un valor tal que el k% de las observaciones se encuentran debajo del percentil y el $(100 - k)$ % se encuentran sobre este valor.
- En estadística se usan generalmente los cuantiles que son equivalentes a los percentiles expresados en fracciones en vez de porcentajes.


En R se calculan con el comando `quantile`:

```
# Todos los percentiles  
quantile(Sepal.Length, seq(0, 1, 0.01))
```

Percentiles o Cuantiles

Además es muy común hablar de los **cuantiles** que son tres percentiles específicos:

- El **primer cuartil Q1** (lower quartile) es el percentil con **k = 25**.
- El **segundo cuartil Q2** es con **k = 50** que equivale a la mediana.
- El **tercer cuartil Q3** (upper quartile) es con **k = 75**.



<https://clauswilke.com/dataviz/>

Gráficos de cajas (boxplots): La caja muestra los cuantiles del conjunto de datos, mientras que los bigotes se extienden para mostrar el resto de la distribución.


Percentiles o Cuantiles

El mínimo, los tres cuartiles y el máximo

```
> quantile(Sepal.Length, seq(0, 1, 0.25))
```

0%	25%	50%	75%	100%
----	-----	-----	-----	------

4.3	5.1	5.8	6.4	7.9
-----	-----	-----	-----	-----



Resumiendo un Data Frame

- En R podemos obtener varias estadísticas de resumen de una variable o de un *data.frame* (tabla en R) usando el comando *summary*.
- Para las **variables numéricas** nos entrega el mínimo, los cuartiles, la media y el máximo.
- Para las **variables categóricas** nos entrega la tabla de frecuencias.

> `summary(iris)` #estadísticas básicas del dataframe

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min. :4.300	Min. :2.000	Min. :1.000	Min. :0.100
1st Qu.:5.100	1st Qu.:2.800	1st Qu.:1.600	1st Qu.:0.300
Median :5.800	Median :3.000	Median :4.350	Median :1.300
Mean :5.843	Mean :3.057	Mean :3.758	Mean :1.199
3rd Qu.:6.400	3rd Qu.:3.300	3rd Qu.:5.100	3rd Qu.:1.800
Max. :7.900	Max. :4.400	Max. :6.900	Max. :2.500

Species
setosa :50
versicolor:50
virginica :50

Ejercicio

- Usando el comando `tapply` analice la media, la mediana y los cuartiles para las tres especies de Iris para las cuatro variables.
- ¿Nota alguna diferencia en las distintas especies?

Respuesta:

```
tapply(iris$Petal.Length, iris$Species, summary)
tapply(iris$Petal.Width, iris$Species, summary)
tapply(iris$Sepal.Length, iris$Species, summary)
tapply(iris$Sepal.Width, iris$Species, summary)
```

Medidas de Dispersión

- Estas medidas nos dicen qué tan distintas o similares tienden a ser las observaciones respecto a un valor particular.
- Generalmente este valor particular se refiere a alguna medida de tendencia central.
- El **rango** es la diferencia entre el valor máximo y el mínimo:

```
> max(Sepal.Length) - min(Sepal.Length)  
[1] 3.6
```

Medidas de Dispersión

- La **desviación estándar** es la raíz cuadrada de la varianza que mide las diferencias cuadráticas promedio de las observaciones con respecto a la media.

$$\text{var}(x) = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})^2$$

$$\text{sd}(x) = \sqrt{\text{var}(x)}$$

```
> var(Sepal.Length)
[1] 0.6856935
```

```
> sd(Sepal.Length)
[1] 0.8280661
```

Medidas de Dispersión

- Al igual que la media, la desviación estándar es sensible a outliers.
- Las medidas más robustas se basan generalmente en la mediana.
- Sea $m(x)$ una medida de tendencia central de x (usualmente la mediana), se define la **desviación absoluta promedio** o **average absolute deviation (AAD)** como:

$$AAD(x) = \frac{1}{m} \sum_{i=1}^m |x_i - m(x)|$$

Ejercicio: Función AAD, recibe un vector x y una función de media central fun .

```
aad <- function(x, fun=median)
  {mean(abs(x-fun(x))) }
```

```
> aad(Sepal.Length)
[1] 0.6846667
> aad(Sepal.Length, mean)
[1] 0.6875556
```

Medidas de Dispersión

- Sea b una constante de escala se define la **desviación media absoluta** o **median absolute deviation** como:

$$\text{MAD}(x) = b \times \text{median}(|x_i - m(x)|)$$

- En R se calcula con el comando `mad` con los parámetros `center` como una función que mide la tendencia central de la variable y `constant` como la constante b . Por defecto se usa la mediana y el valor 1,482.

```
> mad(Sepal.Length)
[1] 1.03782
```

- Finalmente, se define el **rango intercuartil (IQR)** como la diferencia entre el tercer y el primer cuartil ($Q3 - Q1$).

```
IQR(Sepal.Length)
[1] 1.3
```


Estadísticas de Resumen Multivariadas

- Para comparar cómo varía una variable respecto a otra, usamos medidas multivariadas.
- La covarianza $\text{cov}(x, y)$ mide el grado de variación lineal conjunta de un par de variables x, y :

$$\text{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

- Donde $\text{cov}(x, x) = \text{var}(x)$
- En R se calcula con el comando `cov`:

```
> cov(Sepal.Length, Sepal.Width)
[1] -0.042434
```


Estadísticas de Resumen Multivariadas

- Para datasets de varias columnas numéricas uno puede calcular una matriz de covarianza.
- Cada celda i,j de esta matriz contiene la covarianza entre los atributos i y j .
- Esta matriz es simétrica.
- En R esta matriz se obtiene al aplicar el comando `cov` a una matriz o un `data.frame` de variables numéricas:

```
> cov(iris[,1:4])
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Sepal.Length	0.6856935	-0.0424340	1.2743154	0.5162707
Sepal.Width	-0.0424340	0.1899794	-0.3296564	-0.1216394
Petal.Length	1.2743154	-0.3296564	3.1162779	1.2956094
Petal.Width	0.5162707	-0.1216394	1.2956094	0.5810063

Estadísticas de Resumen

Multivariadas


- Si dos variables son independientes entre sí, su covarianza es cero.
- Para tener una medida de relación que no dependa de la escala de cada variable, usamos la **correlación lineal**.
- Se define a la correlación lineal o coeficiente de correlación de **Pearson** $r(x, y)$ como:

$$r(x, y) = \frac{cov(x, y)}{sd(x)sd(y)}$$


La correlación lineal varía entre -1 a 1 .

- Un valor cercano a 1 indica que mientras una variable crece la otra también lo hace en una proporción lineal.
- Un valor cercano a -1 indica una relación inversa (una crece la otra decrece).


Estadísticas de Resumen Multivariadas



Positive
Correlation



Negative
Correlation



No
Correlation

Estadísticas de Resumen Multivariadas

- Una correlación cercana a 0 no implica que no pueda haber una relación no-lineal entre las variables.
- La correlación lineal se calcula en R con el comando `cor`.
- Podemos usarla de forma análoga a la covarianza para obtener una matriz de correlaciones.

```
> cor(iris[,1:4])
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Sepal.Length	1.0000000	-0.1175698	0.8717538	0.8179411
Sepal.Width	-0.1175698	1.0000000	-0.4284401	-0.3661259
Petal.Length	0.8717538	-0.4284401	1.0000000	0.9628654
Petal.Width	0.8179411	-0.3661259	0.9628654	1.0000000

¡Hay que interpretar con cuidado las correlaciones!

Tablas de Contingencia

- Para analizar la relación entre variables de naturaleza categórica usamos **tablas de contingencia**.
- La tabla se llena con las frecuencias de co-ocurrencia de todos los pares de valores entre dos variables categóricas.
- En R se crean usando el comando `table` que usábamos para frecuencias, pero aplicado sobre dos vectores:

```
sexo<-c("Hombre", "Hombre", "Mujer", "Hombre", "Mujer", "Mujer")
estudios<-c("universitario", "secundario", "secundario",
            "postgrado", "secundario", "universitario")
```

```
> table(sexo, estudios)
```

	estudios		
sexo	postgrado	secundario	universitario
Hombre	1	1	1
Mujer	0	2	1