


Visualización de Datos

- La visualización de datos es la transformación de un dataset a un formato visual que permita a las personas identificar las características y las relaciones entre sus elementos (columnas y filas).
- La visualización permite que las personas reconozcan patrones o tendencias en base a su criterio o conocimiento en el dominio de aplicación.



Representación

- Se entiende por representación como el mapeo que se hace a partir de los datos hacia un formato visual.
- Se traducen los datos, sus atributos y relaciones a elementos gráficos como puntos, líneas, formas y colores.
- Los objetos son usualmente representados como puntos.
- Los valores de atributos se representan como la posición de los puntos o las características de los puntos, ej: color, tamaño y forma.
- Cuando se usa la posición para representar los valores es simple detectar si es que se forman grupos de objetos o la presencia de objetos atípicos.

Variables visuales

Permiten codificar información. [Ward, Grinstein, & Keim \(2010\)](#) destacan ocho variables visuales:

1. Posición

2. Marca

3. Tamaño (longitud, área/volumen);

4. Brillo


5. Color



6. Orientación



7. Textura



8. Movimiento

Graficando en R


- En R la función de visualización más frecuente es `plot`. Es una función genérica cuyo resultado depende de la naturaleza de las variables usadas.
- A los gráficos les podemos agregar parámetros adicionales como: `main` para el título, `xlab` e `ylab` para el nombre de los ejes.
- Otras propiedades son `col` para definir el color, `type` para definir el tipo de gráfico: (p) para puntos o (l) para líneas.
- Además podemos agregar nuevas capas a un gráfico con el comando `lines`.
- Para grabar una imagen en un archivo podemos usar el botón **export** de Rstudio.
- Para hacerlo de la línea de comandos en R:

```
png("imagen.png")  
plot(1:10)  
dev.off()
```

Graficando en R

Ejemplo:


```
plot(rnorm(15,10,5),col="red",type="l")  
lines(rnorm(15,10,5),col="blue",type="p",pch=1)  
lines(rnorm(15,10,5),col="green",type="b",pch=2)  
title(main="Mi gráfico")  
legend('topright', c("lineas", "puntos", "ambos"),  
lty=1:3, col=c("red", "blue", "green"), bty='n', cex=.75)
```



Graficando en R

Una librería muy popular para hacer visualizaciones en R es **ggplot2**. Se basa en la idea de descomponer el gráfico en componentes semánticos como escalas y capas.

```
> install.packages("ggplot2")  
> library(ggplot2)
```



<https://ggplot2.tidyverse.org/>

Visualizar cantidades

Gráficos de barras

Muestra la relación entre una variable numérica y una categórica. Cada entidad de la variable categórica se representa como una barra. El tamaño de la barra representa su valor numérico. Es por eso que las barras deben empezar en cero, de modo que la longitud de la barra sea proporcional a la cantidad mostrada.

Consideraciones:

- Si las barras representan categorías ordinales, respetar el orden.
- Si las barras representan categorías nominales, ordenarlas (ascendente/descendentemente).

Visualizar cantidades


Gráficos de barras

```
# Calculamos el promedio por especie
```

```
df <- aggregate(iris[,1:4], by = list(iris$Species),  
FUN = mean)
```

##	Group.1	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
## 1	setosa	5.006	3.428	1.462	0.246
## 2	versicolor	5.936	2.770	4.260	1.326
## 3	virginica	6.588	2.974	5.552	2.026

```
barplot(Petal.Length~Group.1, data=df,  
xlab=c('Species'), ylab=c('Petal Length'))
```




Visualizar cantidades

Gráficos de barras

Lo mismo usando ggplot2:

```
ggplot(df, aes(x = Group.1, y = Petal.Length)) +  
  geom_bar(stat="identity") +  
  xlab('Species') + ylab('Petal Length')
```




Visualizar proporciones

Tenemos opciones como los **Gráficos de barras**, **Treemaps**, **Gráficos de Torta o Pie Charts**, entre otros.

Gráficos de Torta

- Los gráficos de torta, gráficos circulares o pie charts representan la frecuencia de los elementos en un círculo.
- Cada elemento tiene una participación proporcional a su frecuencia relativa.
- Se usan generalmente para variables categóricas.
- **No se recomienda mucho su uso, pues pueden entregar información engañosa. Preferible usar gráfico de barras.**

```
> pie(table(iris$Species))
```




Visualizar distribuciones

Histogramas

Representa la distribución de una o más variables mediante el recuento del número de observaciones que caen dentro de intervalos distintos (contenedores o bins).

- La altura de cada barra indica el número de elementos o frecuencia del contenedor.

```
> hist(Sepal.Length)
```




Visualizar distribuciones


Histogramas

- Es fundamental probar diferentes anchos de intervalo. En R se puede definir esa cantidad con el parámetro `nclass`.
 - Intervalos demasiado grandes, pueden borrar características importantes.
 - Intervalos demasiado pequeños pueden estar dominados por la variabilidad aleatoria, ocultando la forma de la verdadera distribución.

```
> hist(Sepal.Length, nclass=100)
```



```
> hist(Sepal.Length, nclass=4)
```



Visualizar distribuciones

Densidad

Es una versión suavizada del histograma y nos permite determinar más claramente si los datos observados se comportan como una densidad conocida (ej: normal).


- Se calculan usando técnicas estadísticas no paramétricas llamadas estimación de densidad de **kernel** (ej: gaussiano).
- Las curvas de densidad se suelen escalar de forma que el área bajo la curva sea igual a uno.

En R se crean con el comando `density`, para luego visualizarlas con el comando `plot`.

Visualizar distribuciones

Densidad

```
> plot(density(iris$Sepal.Length), main="Densidad  
de Sepal.Length")
```




Visualizar distribuciones

Gráficos de cajas (boxplots)

Muestra la distribución de los datos cuantitativos de forma que facilita las comparaciones entre variables o entre niveles de una variable categórica.

- La altura del rectángulo es el rango intercuartil RIC ($Q3 - Q1$).
- La mediana es una línea que divide el rectángulo.
- Cada extremo del rectángulo se extiende con una recta o brazos de largo $Q1 - 1,5 \cdot RIC$ para la recta inferior y $Q3 + 1,5 \cdot RIC$ para la recta superior.
- Los valores más extremos que el largo de los brazos son considerados atípicos.
- El boxplot nos entrega información sobre la simetría de la distribución de los datos.
- Si la mediana no está en el centro del rectángulo, la distribución no es simétrica.
- Son útiles para ver la presencia de valores atípicos u outliers.

Gráficos de cajas (boxplots)




Fuente:

<http://commons.wikimedia.org/wiki/File:Boxplot.svg>

Gráficos de cajas (boxplots)


El largo de los brazos así como el criterio para identificar valores atípicos se basa en el comportamiento de una normal.



Visualizar distribuciones

Gráficos de cajas (boxplots)

```
> boxplot(Sepal.Length, main="Boxplot Sepal.Length")
```




Visualizar distribuciones

Gráficos de cajas (boxplots)

Si tenemos una variable factor podemos crear un boxplot para cada categoría de la siguiente manera:

```
> boxplot(Sepal.Length~Species, ylab="Sepal.Length")
```




Visualizar distribuciones

Gráficos de cajas (boxplots)

También podemos comparar varios boxplots en un mismo gráfico:

```
> boxplot(x=iris[,1:4], main="Boxplots Iris")
```




Visualizar distribuciones

Gráficos de cajas (boxplots)

Ahora usando ggplot2:

```
> ggplot(iris, aes(x = Species, y = Sepal.Length,  
  fill = Species)) + geom_boxplot()
```



Visualizar relaciones

Gráficos de dispersión (o scatter plots)

Permiten visualizar las asociaciones entre dos o más variables cuantitativas.

- Usan coordenadas cartesianas para mostrar los valores de dos variables numéricas del mismo largo.
- Los valores de los atributos determinan la posición de los elementos.
- Otros atributos pueden codificarse mediante el tamaño, la forma o el color de los objetos.
- En R podemos graficar un scatterplot de dos variables numéricas usando el comando `plot(x, y)`, que sería y vs x .
- También se pueden definir fórmulas $f(x) = y$ usando la notación $y \sim x$.
- De esta manera, `plot(y ~ x)` es equivalente a `plot(x, y)`.
- Si tenemos un `data.frame` o matriz numérica podemos ver los scatterplots de todos los pares usando el comando `pairs(x)`.

Visualizar relaciones

Gráficos de dispersión (o scatter plots)


```
# El ancho del sépalo vs el largo del sépalo  
plot(Sepal.Width~Sepal.Length, col=Species)
```

```
# Equivalente
```

```
plot(Sepal.Length, Sepal.Width, col=Species,  
     pch=as.numeric(Species))
```

```
# Le agregamos una leyenda
```

```
legend('topright', levels(Species), lty=1, col=1:3, bty='n')
```




Visualizar relaciones

Gráficos de dispersión (o scatter plots)

Lo mismo usando ggplot2:

```
ggplot(iris, aes(x=Sepal.Length,  
y=Sepal.Width, color=Species)) +  
geom_point(size=3, shape=4)
```




Visualizar relaciones

Gráficos de dispersión (o scatter plots)

Ahora grafiquemos todos los pares de las 4 variables del dataset iris usando un color y un carácter distinto para cada especie:

```
pairs(iris[,1:4], pch=as.numeric(iris$Species), col=iris$Species)
```



Galería de visualizaciones (con código)

- <https://r-graph-gallery.com/index.html>
- <https://plotly.com/r/>
- <https://www.data-to-viz.com/>
- <https://datavizcatalogue.com/>
- <https://datavizproject.com/>