

Tanagra: herramienta de Machine Learning

Minería de datos



Sebastian Manrique

Universidad Distrital Francisco José de Caldas

30 de octubre de 2023

- 1 Introducción
- 2 Hablemos sobre Tanagra
 - ¿Qué es Tanagra?
 - Su historia
- 3 ¿Cómo se ve?
 - Interfaz
- 4 ¿Para qué sirve?
 - Listado de usos de Tanagra
- 5 Tanagra vs. scikit-learn
 - El dataset y el modelo
 - Parámetros del modelo
 - Visualización de los datos
 - Métricas
- 6 Analicemos Tanagra
 - Ventajas y desventajas
- 7 Conclusiones

Introducción



En la era moderna, el Machine Learning ha revolucionado la inteligencia artificial al permitir que las máquinas aprendan y tomen decisiones basadas en datos. Tanagra, una plataforma de código abierto, es una herramienta esencial en este campo. Esta exposición se adentra en las capacidades de Tanagra y explora ejemplos de su aplicación en diversos dominios, resaltando su contribución al impulso del Machine Learning en la resolución de problemas complejos y la toma de decisiones basada en datos.

Hablemos sobre Tanagra



Tanagra es un destacado conjunto de herramientas de Machine Learning, diseñado para fines académicos y de investigación, desarrollado por Ricco Rakotomalala en la Universidad Lumière de Lyon, Francia. Esta plataforma brinda soporte a diversas tareas estándar en el campo de la minería de datos, abarcando desde visualización, estadísticas descriptivas, hasta regresión, análisis factorial y más. Tanagra se ha convertido en un pilar en el ámbito académico y se utiliza ampliamente en universidades de habla francesa, desempeñando un papel esencial en estudios reales y comparativos de software en el campo del aprendizaje automático.

El desarrollo de Tanagra comenzó en junio de 2003, y la primera versión se distribuyó en diciembre de ese mismo año. Tanagra surgió como el sucesor de Sipina, otra herramienta gratuita de minería de datos diseñada específicamente para tareas de aprendizaje supervisado, especialmente la construcción interactiva y visual de árboles de decisión. Sipina aún está disponible en línea y se encuentra bajo mantenimiento continuo. Tanagra se considera un proyecto de código abierto, lo que permite a los investigadores acceder al código fuente y agregar sus propios algoritmos, siempre que cumplan con la licencia de distribución de software.

[illegible]

Figura: Captura de pantalla de Tanagra versión 1.4.50

A partir de 2006, Ricco Rakotomalala se centró en la documentación de Tanagra, creando numerosos tutoriales publicados en un sitio web dedicado. Estos tutoriales describen métodos estadísticos y de aprendizaje automático, junto con su implementación en Tanagra en estudios de casos reales. También se incluye información sobre el uso de otras herramientas gratuitas de minería de datos en los mismos problemas. Esta comparación entre herramientas ayuda a comprender las posibles diferencias en la presentación de resultados.

¿Cómo se ve?







Figura: Vista general de la interfaz de Tanagra



TANAGRA 1.6.41 - JC-RT Regression tree 1

File Diagram Component @Indow Help

dataseting

- Dataset (DataRegression150.xls)
 - Define status 1
 - CRT Regression tree 1
 - Regression tree 1
 - Define status 2
 - Multiple linear regression 1
 - Define status 3
 - Supervised Learning 1 (PLM)
 - View dataset 1
 - View multiple scatterplot 1
 - Scatterplot 1

Report Chart

CRT Regression tree 1

Parameters

| Tree Parameters | |
|------------------------|--------|
| Max Number of leaves | 100 |
| Min. size for split | 5 |
| Max. depth | 10 |
| n/G Ratio | 1,0000 |
| Pruning set size | 33 % |
| Show all tree sequence | 0 |
| Node generator | 1 |

Results

Global results

| Endogenous attribute | instances |
|----------------------|-----------|
| Examples | 1000 |
| R ² | 0.4821 |

Trees sequence (# 56) -- Mean Squared Error

| R ² | # Leaves | mse (growing) | mse (pruning) | se (mse) | x |
|----------------|----------|---------------|---------------|----------|---------|
| 56 | 1 | 0.6415 | 1.7432 | 0.1779 | 46.5861 |
| 57 | 8 | 0.2316 | 0.2304 | 0.0098 | 0.8455 |
| 58 | 12 | 0.2024 | 0.2024 | 0.0180 | 0.0000 |
| 1 | 100 | 0.0768 | 0.3157 | 0.0201 | - |

Tree description

| | |
|------------------|----|
| Number of nodes | 15 |
| Number of leaves | 8 |

Tree

- ingress = 45,2114
 - ingress = 21,0290
 - ingress = 11,5638 then angletadok = 5,1731 (std dev = 0,4382, with 104 example (11,5231))

Components:

- Data visualization
- Statistics
- Nonparametric statistics
- Association
- Instance selection
- Feature construction
- Feature selection
- Regression
- Factorial analysis
- PLS
- Clustering
- Svm learning
- Meta-svm learning

[Data visualization](#)
[Statistics](#)
[Nonparametric statistics](#)
[Association](#)
[Instance selection](#)
[Feature construction](#)
[Feature selection](#)
[Regression](#)
[Factorial analysis](#)
[PLS](#)
[Clustering](#)
[Svm learning](#)
[Meta-svm learning](#)

[Correlation scatterplot](#)
[View multiple scatterplot](#)
[Export dataset](#)
[Scatterplot](#)
[Scatterplot with label](#)
[View dataset](#)

Figura: Menú principal de Tanagra




Figura: Visualización de los datos en Tanagra




Figura: Árbol de algoritmos en Tanagra




Figura: Cinta de herramientas o componentes en Tanagra




Figura: Panel de configuración de parámetros en Tanagra




Figura: Salida de los datos, métricas y modelos en Tanagra

¿Para qué sirve?



Tanagra es una herramienta versátil que se utiliza en una amplia variedad de aplicaciones relacionadas con la minería de datos y el aprendizaje automático. Aquí te presentamos algunos de los usos más comunes de Tanagra:

1. **Análisis Exploratorio de Datos (EDA):**

Tanagra es ideal para realizar un análisis exploratorio de datos. Los usuarios pueden cargar conjuntos de datos, visualizar distribuciones, identificar relaciones entre variables y detectar valores atípicos de manera intuitiva.

2. Construcción de modelos de Machine Learning:

Tanagra proporciona una amplia selección de algoritmos de aprendizaje automático. Los usuarios pueden construir modelos de clasificación, regresión, clustering y más con facilidad. Además, la herramienta ofrece una interfaz gráfica para configurar y entrenar modelos.

3. Evaluación de modelos:

Tanagra permite evaluar el rendimiento de los modelos mediante métricas y técnicas de validación cruzada. Esto es esencial para garantizar que los modelos sean precisos y generalicen bien.

4. **Análisis estadístico:**

Tanagra también incluye una variedad de herramientas estadísticas para llevar a cabo análisis detallados de datos. Esto puede ser útil en investigaciones científicas, análisis de mercado y más.

5. **Comparación de algoritmos:**

Tanagra facilita la comparación de diferentes algoritmos de aprendizaje automático en conjuntos de datos específicos. Los usuarios pueden determinar cuál es el algoritmo más adecuado para una tarea particular.

6. Enseñanza y aprendizaje:

Tanagra es ampliamente utilizado en entornos académicos para enseñar conceptos de minería de datos y aprendizaje automático. Los estudiantes pueden beneficiarse de su interfaz amigable y tutoriales disponibles en línea.

7. Investigación:

Investigadores y científicos de datos utilizan Tanagra en sus investigaciones. La capacidad de personalización y la posibilidad de agregar algoritmos propios hacen que sea una herramienta valiosa para proyectos de investigación.


Tanagra vs. scikit-learn



Se usó el dataset `iris.csv` en el cual se empleó el algoritmo de clasificación **k-NN** (*k-Neighbors Nearest*). Este algoritmo fue aplicado tanto en Tanagra como en Jupyter usando las librerías de la comunidad de `scikit-learn`.

| | Sepal_Length | Sepal_Width | Petal_Length | Petal_Width | Species |
|-----|--------------|-------------|--------------|-------------|----------------|
| 0 | 5.1 | 3.5 | 1.4 | 0.2 | Iris-setosa |
| 1 | 4.9 | 3.0 | 1.4 | 0.2 | Iris-setosa |
| 2 | 4.7 | 3.2 | 1.3 | 0.2 | Iris-setosa |
| 3 | 4.6 | 3.1 | 1.5 | 0.2 | Iris-setosa |
| ... | ... | ... | ... | ... | ... |
| 146 | 6.3 | 2.5 | 5.0 | 1.9 | Iris-virginica |
| 147 | 6.5 | 3.0 | 5.2 | 2.0 | Iris-virginica |
| 148 | 6.2 | 3.4 | 5.4 | 2.3 | Iris-virginica |
| 149 | 5.9 | 3.0 | 5.1 | 1.8 | Iris-virginica |

Cuadro: Visualización de los datos del dataset `iris.csv`



```
kNN-Iris.py

# Librerías usadas:

# Manejo del dataset
import pandas as pd
# Manejo de operaciones matemáticas entre otros
import numpy as np
# Manejo de gráficos
import matplotlib.pyplot as plt
import matplotlib.patches as mpatches
# Librerías de la comunidad scikit-learn
from sklearn import datasets
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import confusion_matrix,
ConfusionMatrixDisplay, classification_report, accuracy_score

---

# Modelo usado junto a sus parámetros:
knn = KNeighborsClassifier(n_neighbors=3)
```

Figura: Parámetros del modelo en Tanagra junto a su rendimiento

Figura: Parámetros del modelo en Jupyter junto a las librerías usadas




Figura: Visualización de datos en Tanagra




Figura: Visualización de datos en Jupyter usando matplotlib




Figura: Exportación de las métricas en Tanagra

Classification Report

Average Accuracy: 0.9600

| | precision | recall | f1-score | support |
|-----------------|-----------|----------|----------|---------|
| Iris-setosa | 1.000000 | 1.000000 | 1.000000 | 10.50 |
| Iris-versicolor | 0.927020 | 0.927854 | 0.920383 | 8.90 |
| Iris-virginica | 0.933578 | 0.952697 | 0.940634 | 10.60 |

| | | | | |
|--------------|----------|----------|----------|-------|
| accuracy | 0.960000 | | | 0.96 |
| macro avg | 0.953533 | 0.960184 | 0.953672 | 30.00 |
| weighted avg | 0.964630 | 0.960000 | 0.960198 | 30.00 |

| <i>i</i> | Accuracy Scores |
|----------|-----------------|
| 1 | 0.9667 |
| 2 | 1.0000 |
| 3 | 0.9667 |
| 4 | 0.9333 |
| 5 | 0.9667 |
| 6 | 0.9667 |
| 7 | 0.9333 |
| 8 | 0.9333 |
| 9 | 1.0000 |
| 10 | 0.9333 |

Cuadro: Visualización de las métricas en Jupyter usando **sklearn**




Figura: Matriz de confusión en Jupyter usando sklearn

Analicemos Tanagra



| Ventajas | Desventajas |
|--|--|
| <p>Gratuito y de código abierto:</p> <p>Tanagra es una herramienta de aprendizaje automático de código abierto y gratuita. Esto permite un fácil acceso para estudiantes, investigadores y entusiastas de la minería de datos sin costos adicionales.</p> | <p>Enfoque académico:</p> <p>Tanagra, en su origen, se creó como una herramienta académica. Aunque es útil para la educación y la investigación, puede carecer de algunas características avanzadas que las herramientas comerciales podrían ofrecer.</p> |

| Ventajas | Desventajas |
|---|---|
| Interfaz de usuario amigable:
Tanagra cuenta con una interfaz de usuario intuitiva y fácil de usar que permite a los usuarios trabajar en proyectos de minería de datos sin necesidad de conocimientos avanzados en programación. | Menos soporte comunitario:
En comparación con herramientas populares como scikit-learn en Python, Tanagra puede tener menos usuarios y, por lo tanto, un menor soporte y recursos de la comunidad en línea. |

| Ventajas | Desventajas |
|--|--|
| Tareas de minería de datos:
Tanagra es capaz de manejar una amplia gama de tareas de minería de datos, incluyendo visualización de datos, estadísticas descriptivas, selección de características, construcción de modelos, y más. | Curva de aprendizaje:
Aunque su interfaz de usuario es amigable, los usuarios que no están familiarizados con la minería de datos aún pueden enfrentar una curva de aprendizaje al utilizar Tanagra. |

Conclusiones



Tanagra se destaca como una plataforma sólida y accesible, especialmente dirigida a estudiantes, investigadores y amantes de la minería de datos. Su enfoque académico y su disponibilidad gratuita lo convierten en una herramienta poderosa para aquellos que deseen aprender, experimentar y realizar investigaciones en el ámbito del aprendizaje automático. No obstante, al evaluar su idoneidad, es fundamental considerar las necesidades específicas de cada proyecto y los recursos disponibles.

La elección entre Tanagra y scikit-learn depende de tus necesidades y experiencia en aprendizaje automático. Tanagra es ideal para entornos académicos e investigativos, gracias a su gratuidad y enfoque académico. Scikit-learn, por otro lado, ofrece mayor control y personalización, siendo más adecuado para aplicaciones comerciales, pero con una curva de aprendizaje más pronunciada. Ambas opciones tienen sus ventajas y desventajas como ya se vieron previamente.



¡Gracias!

UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS